

医学统计学的几个基本概念

医学统计学：是运用数理统计学的原理和方法，研究医学研究中的设计、资料的收集、整理、分析以研究医学领域中随机现象客观规律的一门应用学科。

一、**统计学研究对象**：具有变异的事物，其变异为同质基础上的变异

1 **同质**：观察单位间被研究指标的影响因素**相同或相近**

(对研究指标影响较大的、可以控制的主要因素相同或基本相同)

2 **变异**：在同质基础上各观察单位间某观察指标的差异 Eg：2010 年济南男性（同质）的身高（变异）

二、**总体 (population) 与样本 (sample)**

1 **总体**：根据研究目的所确定的**同质**观察单位的全体。

根据研究目的，总体可分为：**有限总体、无限总体**

→两者往往不采用一一考核的方法，常常采用抽样研究 ↓ ↓

2 **样本 (样本量常用 $n=?$ 来表示)**：从总体中随机抽取的具有代表性的个体的集合。

3 **抽样研究**：从总体中抽取样本，通过对样本的**定量或定性测量**结果推断总体

要求：①样本含量（样本含量指样本所包含的观察单位数<样本例数>）大

②随机抽样原则（单纯随机抽样、系统随机抽样、分层抽样、整群抽样 or 多阶段抽样<多种方法>）

③样本的构成分布应基本上与总体构成分布一致，即样本的频率分布与总体一致

5 欲研究某地成年男性血红蛋白的参考值范围，现随机调查了该地12000名健康成年男性的血红蛋白，那么本次调查的总体是（ ）

- A、该地所有成年男性
- B、该地所有成年男性的血红蛋白值
- C、该地所有健康成年男性的血红蛋白值
- D、抽取的这12000名健康成年男性
- E、抽取的这12000名健康成年男性的血红蛋白值

学生答题： B

6 某医生对200名糖尿病患者采用某新疗法进行治疗，该研究的总体是（ ）

- A、全院收治的糖尿病患者的血糖值
- B、该医生收治的所有糖尿病患者的血糖值
- C、接受该新疗法的所有糖尿病患者的血糖值
- D、所有糖尿病患者的血糖值
- E、这200名糖尿病患者的血糖值

学生答题： C

三、**参数 (总体) 与统计量 (样本)**

1 **参数**：反映**总体**的统计指标，**固定的常数**，但一般未知

如 μ （总体标准差）， σ （总体标注差）， Π （总体率）

2 **统计量**：反映**样本**的统计指标，如 $\bar{X}$ （样本均数），S（样本标准差），P（样本率）

△根据所测数据直接得出的是统计量，不能下“总体”的结论！

△那如何获得参数？总体参数是事物固有不变的，只能用统计量分布的规律，如小样本均数服从 t 分布，大样本均数服从正态分布等规律来统计推断总体参数。

四、**误差**：观察值与真实值之差 以及 样本统计量与总体参数之差

1 **非随机误差** (1)：非系统误差：过失误差，偶然失误而造成的误差，**可以避免**

(2)：系统 误差：收集测量中仪器不准、标准不规范等原因造成的误差，**可以避免**

2 随机误差【△测量误差和抽样误差不可避免!】

(1) 随机**测量误差**: 非人为的偶然因素使得结果或大或小, 如测量一个人身高: 178.12, 178.09, 178.15cm **不可避免**

(2) 随机抽样误差: 简称抽样误差 (sample error) 是由于①随机抽样引起的样本**统计量与总体参数**间的差异 (抽样研究) 以及②各样本统计量之间的差异 (个体差异) 所引起
抽样误差虽**不可避免**, 但有一定规律, **可估计, 可控制**↓

如何表示抽样误差→其大小可以通过计算**标准误**间接表示

五、频率与概率

1 频率: (衡量样本) 一个事件出现的次数 m 和总的试验次数 n 之比, 成为这个事件在这 n 次试验中出现的频率。【当样本量足够大时, 发生频率才比较稳定】

2 概率: ↓当试验次数 n 很大时, 频率趋近于一个较稳定的常数, 用 P 表示。

P 取值 $0 \leq P \leq 1$; 随机事件 $0 < P < 1$; 必然事件 $P=1$; 不可能事件 $P=0$;

△**小概率事件**: $P \leq 0.05$ 或 $P \leq 0.01$ 一般认为, 小概率事件**在一次试验中是不大可能发生的**, 这就是**小概率原理**, 是**统计推断的重要原理**。

7 以下对概率描述错误的是 ()

- A、概率值介于0和1之间
- B、必然事件发生的概率为1
- C、概率用于描述某样本事件发生的强度**
- D、样本含量足够大时, 频率接近概率
- E、当随机事件发生的概率小于0.05或0.01时常称为小概率事件

学生答题: A

资料分类△、医学统计工作的基本步骤

一、资料与变量的概念

1 **资料**：又称数据，由变量和变量值组成。资料类型与变量类型相对应

2 **变量**：是指观察单位的某种特征和属性，即研究的项目或指标（判断）

变量值：变量的测量结果，或称为观察值。

二、资料分类△(各种称呼、判别，必须牢记)

1 计量资料（定量资料 or 数值资料）

测量所得的**某项指标量大小**所得到的资料，如测量 100 名男大学生的身高所获得的资料（所提供的**数据最多**，能够定量就定量）

2 计数资料（定性资料 or 无序分类资料）

是按照事物不同的属性归类，清点 **每一类 数量多少（先分类，再计数）** 所得到的资料。根据类别多少分为①二分类资料和②无序多分类资料。如将 100 名大学生按性别分组，男 53 人，女 47 人；如按 ABO 血型分组，A 型 39 人，B 型 20 人、O 型 17 人，AB 型 24 人。

3 等级资料（半定量资料、有序多分类资料）

是将事物属性按组别之间**有程度或等级差异**进行分类所得到的资料。

如按照临床疗效（痊愈、显效、好转、无效）...


三、统计步骤（研究设计、搜集资料、整理资料、分析资料）

1 研究设计

2 收集资料

3 整理资料

4 分析资料△：对资料进行统计分析



5 结果报告与结论表达

计量资料的统计描述

对原始资料进行整理、归纳，并使用合理的统计指标或统计图表将研究数据的分布类型（对称分布及偏态分布）及分布特征（集中趋势及离散趋势）表示出来

一、频数分布

样本含量较大，将观察值分为不同组别，统计不同组别观察值的例数，观察值的例数称为频数（**f**）表示各组别内观察值的分布强度。→ 绘制成表

1 频数表和直方图的制作

计算极差（全距 $R = X_{max} - X_{min}$ ）→确定组数 **k**（一般 10-15 组）、组距 **i** ($i=R/k$)、组段（最后组段为闭区间，其他为左闭右开，如 103~；110~...166~173）→汇总各组段频数
进一步加工后的数值：组中值：（组段上+组段下）/2；累计频数、累计频率

2 频数表的具体用途

（1）描述频数分布的类型

- ①对称分布：集中位置在中间，左右两侧的频数基本对称
- ②偏态分布：集中位置偏向一侧，不对称，可分为△：
 - 正偏态（右偏态分布-长尾右，高峰左，集中位置偏向数值小的一侧）；
 - 负偏态（左偏态分布-长尾左，高峰右，集中位置偏向数值大的一侧）

（2）展示频数分布特征

- ①集中趋势（观察值的中心位置或平均水平），具体描述见下↓
- ②离散趋势（观察值之间参差不齐的程度，描述变异程度），具体描述见下↓
- (3) 异常值的识别 (4) 有利于进一步对资料进行统计描述和分析

表 3-2 140 例疑诊冠心病患者平板运动后心率的频数表

组段(1)	组中值(2)	频数 <i>f</i> (3)	累计频数(4)	频率(%) (5)	累计频率(%) (6)
53 ~	57	1	1	0.7	0.7
61 ~	65	5	6	3.6	4.3
69 ~	73	9	15	6.4	10.7
77 ~	81	17	32	12.1	22.9
85 ~	89	21	53	15.0	37.9
93 ~	97	36	89	25.7	63.6
101 ~	105	21	110	15.0	78.6
109 ~	113	16	126	11.4	90.0
117 ~	121	9	135	6.4	96.4
125 ~	129	4	139	2.9	99.3
133 ~141	137	1	140	0.7	100.0
合计	—	140	—	100.0	—




图 3-1 140 例疑诊冠心病患者平板运动后心率的直方图

二、统计指标 【侧重掌握描述选择】

描述对称分布: $\bar{X} \pm S$

描述偏态分布: $M(Q)$ 或 $M(P_{25}, P_{75})$

(一) 集中趋势的描述

1 算数均数 (样本 $\bar{X}$; 总体 μ)

(1) 适用范围: 对称分布资料, 特别是正态或近似正态分布资料

(2) 算法: 加权法算的更少但是只是一个近似值

直接法: $\bar{X} = \frac{\sum X}{n}$, 所有原始观察值 $X_1, X_2 \dots$ 直接相加, 除以观察值的个数

加权法: $\bar{X} = \frac{\sum X}{\sum f} = \frac{\sum fX}{n}$, 用于相同观察值较多的原始数据, 是将相同观察值的例数 (即频数 f) 乘以该观察值 X 以替代相同观察值的逐个相加。用于频数表数据时, 观察值的实际取值用该组段的组中值来代替, 再用加权法求其均数。

2 几何均数 (G)

△适用范围: (1) 适用于各观察值之间呈倍数变化 (等比关系) 的数据

(2) 或频数分布呈偏态分布, 但经对数变换后呈正态分布或近似正态分布的资料, 如血清抗体滴度及某些疾病的潜伏期。

算法: 变换为对数后再乘, 比如说 1: 2, 1: 4 等换成 2 和 4 后再算对数均数, 为 8, 最后再将对数均数换回去, 取得几何均数, 为 1: 8

直接法: $G = \sqrt[n]{X_1 X_2 \dots X_n}$, 所有原始观察值 $X_1, X_2 \dots$ 直接连乘后再开 n 次方

加权法:

3 中位数 (M) 和百分位数 (P_x)

概念: 表示变量值 平均水平 的指标, 算数均数与之相比更充分利用数据信息。

△适用范围: 偏态分布、一端或两端无确切值

算法: 中位数不必多少, 从大到小, 奇数偶数不同;

百分位数是一种位置指标, 一个分割值, P_{50} 即为 M

频数表法: $P_x = L + \frac{i}{f_x} (n \cdot X\% - \sum f_L)$ 注意: L 为百分位数所在组段下限 (是小的数值!),

i 百分位数所在组段的组距, f_x 为百分位数所在组段的频数, n 为总例数, $\sum f_L$ 为所在组段上一组的累计频数 (就是累计频数, 不用再加上上个了, 已经加过来了)

4 众数

(二) 离散趋势的描述

1 极差 (R)

意义: 极差大反应变异程度大, 反之说明变异程度小

特点: 代表性差 (观察值利用不完全), 不稳定 (仅受最大最小)

2 四分位数间距 (Q)

△适用范围: 偏态分布、开口数据

特点：由于四分位数不受两端极大极小的影响，比极差稳定；

但是由于仅受上下四分位数影响，仍存在数据利用不充分，代表性差的问题。

计算： $Q = Q_U(P_{75}) - Q_L(P_{25})$ ，即上四分位数减去下四分位数

3 方差

△适用范围：正态分布

(1) 总体方差 (σ^2)、离均差、离均差平方和

离均差为总体中每个观察值 X 与总体均数 μ 的差值 $(X - \mu)$ ，其和 $\sum (X - \mu) = 0$ (必然是 0，因为是总体， μ 包含着每一个 X 的计算)，不能反映变异程度大小，因此用离均差平方和 (SS)， $\sum (X - \mu)^2$ 来反映。

总体方差 σ^2 即为考虑到观察值例数 N 的影响，离均差平方和的均数而得

$$\sigma^2 = \frac{\sum (X - \mu)^2}{N}$$

(2) 样本方差 (S^2)、样本离均差平方和

总体均数 μ 未知，故采用样本离均差平方和 $\sum (X - \bar{X})^2$ 以及样本例数 n 来计算样本方差

由于用样本数据计算的方差往往小于总体，因此用 $n-1$ 代替 n 来校正， $n-1$ 称为自由度

$$S^2 = \frac{\sum (X - \bar{X})^2}{n - 1}$$

4 标准差 (总体标准差 σ 、样本标准差 S)

目的与计算：为与原始数据统一标准单位，故开方。

意义：方差与标准差越大，说明变异程度越大；反之说明越小

5 变异系数 (离散系数) (CV)

是一个相对数，没有单位

适用：①比较两组 (或多组) 度量衡单位不同 (是比较的 CV，只有一个标准差不行)

②或均数相差悬殊数据间的变异程度

$$CV = \frac{S}{\bar{X}} \times 100\%$$

关于数值：CV

注意：

1 加减乘除：加或减一个不等于零的常数：均数变
标准差不变

2

概率分布

(助于理解, 后续明确) 医药研究中经常会观察病人的各种指标, 如血压、脉搏、心率等。由于个体间差异的存在, 同一指标所取的值往往不同且存在随机性, 因此, 统计学上将其称为随机变量, 通常用 X 、 Y 等表示。


随机变量取到的值与其对应的概率值构成的分布列称为变量的概率分布。

一、正态分布 (正态曲线、钟形曲线 or 高斯分布)

总体或变量的分布

1 特征

- (1) 单峰、对称、钟形曲线——两边低 (无限接近 x 轴但不相交) 中间高 ($X = \mu$ 对称)
- (2) 两个参数: **总体均数 μ** ----- 位置参数, 表集中位置。 μ 越小, 曲线越左
总体标准差 σ -- 形状参数, 表离散程度。 σ 越小, 曲线越瘦高 (集中)
- (3) 正态分布曲线下 **面积为 1 或 100%**
反应总体中相应区间个体观察值所占比例或概率



2 面积

- (1) 正态分布是一条中间高, 两边低, 且以均数为中心的对称分布
- (2) $(\mu - \sigma, \mu + \sigma)$ 内面积为 0.683
- (3) $(\mu - 1.96\sigma, \mu + 1.96\sigma)$ 内面积为 0.95
- (4) $(\mu - 2.58\sigma, \mu + 2.58\sigma)$ 内面积为 0.99

3 标准正态分布 (Z 分布 <zero>)

当 $\mu=0, \sigma=1$ 时, 称为标准正态分布。

任何一个正态分布都可以通过 $z = \frac{X - \mu}{\sigma}$ 变换为标准正态分布 (子移动中心, 母改变大小)

4 正态分布

(1) 质量控制 质量控制领域, 常提到的“ 3σ ”原则, 3σ 之外的观察值出现的概率不到 3‰, 如果超过则提示测量有问题或质量有问题。

以 $\bar{X}$ 为中心线, $\bar{X} \pm 2S$ 为警戒线, $\bar{X} \pm 3S$ 为控制线

(2) 正态分布是统计学的理论基础

t 分布、 χ^2 分布、 F 分布其抽样的基础分布也是正态分布; 不是的经过变化也可以服从

(3) 制定医学参考值范围

二、其他分布

1 χ^2 分布

一种连续性分布, 只与 ν 有关, $\nu \geq 3.84$ 时, 右侧尾部面积为 0.05

$\nu = (\text{行数} - 1)(\text{列数} - 1)$

- (1) 当 $\nu < 2$ 时, 曲线呈 L 型

- (2) 随 ν 增加, 曲线逐渐趋于对称
- (3) 当 ν 无限大时, 趋于正态分布

2 t 分布

一簇单峰曲线, 以 y 轴为中心左右对称

只有 ν 自由度一个参数

- (1) ν 越小, t 越分散, 分布的峰越低, 尾部越高;
- (2) ν 越大, t 分布越来越逼近正态分布

$$\nu = n - 1$$

- (3) 双侧 0.05 t 界值 $t_{0.05/2, \nu}$; 单侧 $t_{0.05, \nu}$

- (4) $\bar{X}$ 服从分布 $N(\mu, \sigma_{\bar{X}})$, $t = (\bar{X} - \mu) / (S / \sqrt{n})$

——读表: 横标目为自由度, 纵为尾部概率 (P 或 α)

3 F 分布

随 $\nu \uparrow$, 对称性变好

三、医学参考值范围的制定

1 概念

由于个体差异的存在, 生物医学数据并不是常数, 而是在一定范围内波动, 即所谓的医学参考值范围。是包括绝大多数正常人的生理生化指标的波动范围, 是判断某项指标正常与否的参考标准。

绝大多数人? 正常人的 90%、95%、99%

Δ 正常人: 并非指没有任何疾病的人, 而是在同质前提下, 排除了影响所测指标因素的个体 (排除患有影响被研究指标的疾病的人) 所以说部分人的指标超过了正常值, 并不能说其异常, 比如说高原人群的血红蛋白等指标

2 制定的注意事项

- (1) 样本含量应在 100 以上

(2) 参考值范围的双侧: 生理指标 (血压血糖) 多为双侧, 毒物指标 (尿铅发汞) 多为单侧上限

- (3) 应根据专业知识和研究目的确定范围

3 计算

- (1) 正态分布法-服从正态分布的指标 or 经过变换 (对数变换) 后服从

双侧, 如取 95%, 则上下各去 2.5% (0.95 面积的), 90% 则上下各去 5%, 即 0.90 面积

单侧, 90%, 上限/下限为: $\bar{X} \pm 1.28S$

95%, 上限/下限为: $\bar{X} \pm 1.64S$

99%, 上限/下限为: $\bar{X} \pm 2.33S$

- (2) 百分位数法-变换后也不成正态分布

双侧, 同理, 上下各去一半 (如 $P_{2.5}$ 、 $P_{97.5}$ ())

单侧, 亦是 P_{10} 、 P_5 、 P_1 (如 P_{95} (95))

4 题目应用

要评价某市一名 5 岁男孩的身高是否偏高或偏矮, 其方法是: 用该市 5 岁男孩身高的 95% 或 99% 参考值范围来评价

计量资料的参数估计与假设检验（统计推断）

利用随机抽样得到的样本统计量对未知总体的分布及其数量特征作出以概率形式表示的非确定判断。

一、标准误（ $\sigma_{\bar{X}}$ 、 $S_{\bar{X}}$ ）与抽样误差

抽样误差（见第一页，其规律正是标准误，主要包括均数和率的标准误，此外也包括样本方差和总体方差的抽样误差，相关系数和回归系数的抽样误差）

（一）样本均数与抽样误差

——正态分布的

- (1) 各样本均数未必等于总体均数
- (2) 各样本均数间存在差异
- (3) 样本均数围绕总体均数呈正态分布
- (4) 样本均数变异范围较原变量变异范围大大缩小

——非正态分布的

样本均数的分布根据统计学中心极限定理，只要样本含量足够大，样本均数的分布服从正态分布。

（二）均数的标准误

标准误：样本统计量的标准差称为标准误，如样本均数的标准差就称为标准误

（1）中心极限定理

设从均值为 μ 方差为 σ^2 的任意一个总体（正态偏态都可）中抽取样本含量为 n 的样本，当 n 充分大时，**样本均值的抽样分布**近似服从均值为 μ 方差为 σ^2/n 的正态分布。

（2）标准误的计算

总体标注误： $\sigma_{\bar{X}} = \sigma / \sqrt{n}$
样本标准误（总体标准差往往是未知的，故而用 S ）： $S_{\bar{X}} = S / \sqrt{n}$

（3）意义

均数的标准误反映在抽样分布中样本均数与总体均数的离散程度，也反映不同样本均数之间的离散程度，因此反应抽样误差，**标准误越小，抽样误差越小。**

适当 1 **增加样本含量** 或 2 **减少观察值的变异程度**（如选择同质性较好的总体， n 一定时，离散程度越小则抽样误差越小）**减少抽样误差，即减少标准误。**

（4）应用

- 1 衡量抽样误差大小
- 2 估计总体均数可信区间
- 3 用于假设检验

（5）标准差和标准误区别：

标准差	标准误
描述个体观测值之间的变异程度大小	描述同一总体中随机抽取 n 相同的多个样本均数间的变异程度大小
随着 n 增大趋于稳定	随着 n 增大逐渐减小，与 n 的平方根成反比
表示个体观察值的变异大小	表示抽样误差大小
描述正态分布	描述样本均数的可靠性
计算正态分布变量的参考值范围	结合均数估计总体均数的可信区间

二、参数估计

根据 **样本量** 去估计 **总体参数** 的取值 (点) 或可能存在的范围 (区间), 这种方法称为参数估计, 包括**点估计** (不考虑抽样误差, 不可靠) 和**区间估计** (根据选定的可信度 or 置信度, 用概率表示) 估计总体参数所在的范围, 该范围称为可信区间 (CI) (L, U); 可信度: 估计正确的概率)。

(二) 总体均数的可信区间

按按照预先给定的概率 (**1- α** , **可信度**), 利用样本信息估计**总体参数可能存在的范围**, 该范围称为参数的**置信区间或可信区间**。

1 基本概述

(1) **可信区间 (CI)**: 即 $\uparrow$, 有**置信限/可信限 (CL)** 构成的一个范围, 是开区间, 不包括上下限值。

(2) **可信度 (1- α)**: 判断可信区间包含总体参数可能的概率, 95%或 99%

(3) **可信限 (CL)**: 可信区间的两个端点

(2) **可信区间两个要素**

准确度 (1- α), 可信度越接近 1, 可信度越高, 如 99%可信区间比 95%更高

精密度: 反应可信区间的范围或宽度

可信区间范围越小 (越窄), 精密度越高, 如 95%可信区间比 99%更高

——不能笼统的说 99 比 95 好

2 计算

——依据**总体标准差 σ 是否已知** + **样本含量 n 的大小 (60)** ——有 **t 分布+ μ 分布法**

1) 总体标准差 σ 已知: $(\bar{X}-1.96\sigma_{\bar{X}}, \bar{X}+1.96\sigma_{\bar{X}})$

2) 总体标准差 σ 未知, 但样本含量 n 足够大: —— **n 足够大, 正态分布的原理**

总体均数的双侧 (1- α): $(\bar{X}-1.96S_{\bar{X}}, \bar{X}+1.96S_{\bar{X}})$

3) 总体标准差 σ 未知, 样本含量 n 不够大: ——**t 分布的原理**

总体均数的双侧 (1- α): $(\bar{X}-t_{0.05/2, v} \cdot S_{\bar{X}}, \bar{X}+t_{0.05/2, v} \cdot S_{\bar{X}})$

注意: 因为 2) 的样本量够大 (一般是大于 50), t 分布近似正态, Z 分布所以用 1.96, 而 3) 样本含量不够大, t 分布, 故而要依据其具体图像, 要查表 (见附录)

注意: 0.05/2, 是指 α 为 0.05, 2 是双侧的意思; v 为自由度 $n-1$

注意:

3 统计软件的实现: (就是正态分析的界面)

1) Analyze——descriptive statistics ——Explore

2) 分析的指标选入 depend list

4 置信区间和参考值范围的区别

总体均数的置信区间	参考值范围
总体均数的可能范围	个体值的波动范围
U 分布或 t 分布法	正态分布法或百分位数法
总体均数的区间估计	绝大多数观察对象某项指标的分布范围

(三) 总体均数的点估计

点估计：直接将样本均数 $\bar{X}$ 作为总体均数 μ 的估计值就成为总体均数的点估计。

方法简单，但未考虑抽样误差的大小

(三) 总体率的估计（不要求）

二、假设检验（显著性检验）

1 基本思想

是对未知的总体参数或分布提出某种假设，然后根据样本的统计量及抽样误差理论，利用小概率反证法的逻辑思维作出是否拒绝此次假设的推断方法。

思想：反证法

小概率事件原理：发生概率很小的随机事件，在一次抽样试验中几乎不可能发生，习惯上称 $P \leq 0.05$ 为小概率事件 $P \leq 0.01$ 为极小概率事件。（问：经过变换以后的一定在）

目的：

判断是由于何种原因造成的不同，以做出决策。

2 步骤

(1) 建立检验建设

①**无效假设 H_0** （即检验假设，又称为原假设，或零假设）：通常假设两个总体参数相等，或两个总体参数的差值等于 0，或某种数据资料服从某种特定分布。

②**备择假设 H_1** ：与 H_0 相对立；注意 H_1 还有单侧双侧之分，一般为双侧检验，若从专业知识能排除掉一侧，则用单侧。

举例： $H_0: \mu = \mu_0$ ，即男性体育生身高均数和一般男大学生身高均数没有差别。

H_1 ：双侧（若目的是判断有无差别，大小都可能则）： $H_1: \mu \neq \mu_0$

单侧：（用专业知识，男体育生不会小于则） $H_1: \mu > \mu_0$

(2) **确定检验水准 α** ，表示预先设定的小概率事件标准， $\alpha=0.05$ 或 0.01 （在 H_0 、 H_1 后直接写上）

为了控制选用方法错误的概率，减少二类错误，因此可以增大 α 检验水准，**设置为 0.10**

(3) **选定检验方法，计算检验统计量**

(4) **确定 P 值，作出统计推断**

$P > \alpha$ ，不拒绝 H_0 ， $P \leq \alpha$ 拒绝 H_0 ，接受 H_1

3 假设检验的两个错误

实际情况	统计推断	
	拒绝 H_0 ，接受 H_1 ($P \leq \alpha$)	不拒绝 H_0 ($P > \alpha$)
H_0 成立	I 型错误 (α) <弃真>	推断正确 ($1 - \alpha$)
H_1 成立	推断正确 ($1 - \beta$)	II 型错误 (β) <存伪>

(简单理解：认为 H_1 正确或 H_0 正确，而实际情况到底正不正确？)

(1) I 型错误：拒绝了实际上成立的 H_0 ，即弃真，错误概率 α

(2) II 型错误：不拒绝实际上错误的 H_0 ，即存伪，错误概率 β （样本量小时易出现）

检验效能（把握度）： $1 - \beta$ ：当总体间确有差别，按 α 检验水准能发现这种差别的能力

——与的关系：此消彼长： α 越小， β 越大，反之 β 越小， α 越大

通常将更有把握的、不能轻易否定或拒绝时导致后果更严重、危害更大的假设作为 H_0 ， H_0 是应是受保护的，找不到充分理由就不能拒绝。

4 注意事项

- (1) 要有严密的研究设计
- (2) 假设检验的结论不能绝对化, $P \leq \alpha$ 为差异有统计学意义而非有显著差异
- (3) 正确理解 P 值的含义
- (4) 注意样本含量是否合理
- (5) 有统计学意义 $\neq$ 有实际专业意义

三、正态性检验

1 目的

检验总体是否服从正态分布, 因为有些统计方法只能适用于正态分布或近似正态分布, 如使用均数、标准差描述计量资料的集中或离散趋势, 使用正态分布法计算正常值的范围, 以及 t 检验和方差分析等。

2 两个系数

偏度系数 s : $s = 0$ 表示数据分布与正态分布的对称性相同, 绝对值越大, 越偏斜
 $s > 0$ 为正偏态, 反之负

峰度系数 k : $k = 0$ 表示数据分布与正态分布的陡缓程度相同;
 $k > 0$ 表示比正态分布高峰陡峭, 为尖

3 方法:

(1) 经验

(2) 图示法: 概率图(P-P 图)、分位数图 (Q-Q 图)、直方图、箱图、茎叶图

P-P 图是以累计频率为横坐标, 累积概率为纵坐标

Q-Q 图是以样本的分位数为横坐标, 相应分位数为纵坐标

(3) 假设检验法 (对 k 、 s 共用一个指标)

W 检验 (Shapiro-Wilk 检验) 用于 $n \leq 50$;

D 检验 (Kolmogorov-Smirnov 检验) 用于大样本检验

计量资料的 t 检验

△是计量资料两组均数比较最常用的假设检验方法

t 检验和 z 检验分别以 t 分布和 z 分布（标准正态分布）为基础。当样本含量 n 较大时，t 值近似于 u 值，有人将其称为 u 检验或 Z 检验，实际上它是 t 检验的特例。

一、配对 t 检验

1 适用范围

(1) 配对设计（什么是配对设计？

①两个同质受试对象分别接受两种处理，异体配对 ②同一受试对象或同一样本的两个部分，分别接受两种不同处理 ③自身对比，即将同一受试对象处理前后的结果进行比较)

(2) 计量资料

(3) 均数比较

2 基本原理及应用条件

基本原理：假设两种处理的效应相同， $\mu_1 - \mu_2 = 0$ ，即配对对子的差值均数 $\bar{d} = 0$

应用条件：**研究变量的差值 d 总体服从正态分布**

3 步骤

(1) 差值 d 的正态性检验

(2) 配对 t 检验 ($H_0: \mu_d = 0$, $H_1: \mu_d \neq 0$)

举例：某中医院用中药治疗 9 例再生障碍性贫血患者，治疗 1 个疗程后，血红蛋白数据的变化见表（略）。问：该中药治疗再生障碍性贫血有无作用？

1 正态性检验

(1) H_0 : 差值数据总体服从正态分布; H_1 : 差值数据总体不服从正态分布

$\alpha=0.05$

(2) 因对子数 $n=9$ ，所以用 W 检验，通过 SPSS 得出 $W = 0.931$, $P=0.493$

$P=0.439$ ，所以按照检验水准 $\alpha=0.05$ ，不拒绝 H_0 ，认为差值数据总体服从正态分布

2 配对 t 检验

(1) $H_0: \mu_d = 0$ ，该中药治疗再障患者前后血红蛋白含量相同；

$H_1: \mu_d \neq 0$ ，该中药治疗再障患者前后血红蛋白含量不同

$\alpha=0.05$

(2) 采用配对 t 检验，经 SPSS 得出， $t=4.784$, $P=0.001$ （如果手工算的，只能得到 t，不能得到 P，则需要查 t 界值表，得 $t_{0.05/2 (8)} = 2.306$, $t < t_{0.05/2 (8)}$, $P < 0.05$)

(3) 因此，按照所以按照检验水准 $\alpha=0.05$ ，拒绝 H_0 ，接受 H_1 ，差别具有统计学意义，可认为该中药治疗再障有效

二、单样本 t 检验

1 目的：从正态总体 N 中随机抽取一份含量为 n 的样本，算得均数和标注差，判断其总体均数 μ 是否与某个已知总体均数 μ_0 相同

2 适用范围：(1) 完全随机设计 (2) 计量资料 (3) 单样本均数与另外已知总体均数

3 应用条件：样本所代表的总体服从正态分布 or 近似

4 步骤

(1) 正态性检验

(2) 单样本 t 检验

三、两独立样本 t 检验 (成组 t 检验)

1 目的：检验两独立样本均数所代表的两位置总体均数是否有差别

2 适用范围：(1) 完全随机设计 (2) 计量资料 (3) 两样本均数

3 应用条件：

(1) 同质性，两样本来自同分布的总体 (2) 两样本个体测量值之间相互独立

(3) 两个样本所代表的总体均数分别服从正态分布 (正态性)

(4) 两总体方差相等 ($\sigma_1^2 = \sigma_2^2$)，即方差齐性 (F)

4 步骤

(1) 正态性检验

(2) 两样本方差齐性检验 (F 检验或 Levene 检验；F 检验用于正态，L 用于不明)

$F = \frac{s_1^2}{s_2^2}$, S 大者在上, 若手动则查 F 界值表, 判断 ($H_0: \sigma_1^2 = \sigma_2^2$, 两样本总体方差相等)

(3) 两独立样本 t 检验 f

四、两独立样本校正 t 检验

满足正态性，却方差不齐 (用 F 检验测定) → 两独立样本 t' 检验

计量资料的方差分析 (F 检验)

△目的：计量资料 多样本均数 比较 完全随机设计

(多样本均数比较若多次重复采用 t 检验，会使犯**第一类错误**的概率增大)

一、方差分析概述

1 方差 (均方)

$MS = \frac{SS}{\nu}$, 由离均差平方和 (离均差为总体中每个观察值 X 与总体均数 μ 的差值 $(X - \mu)$)

与自由度相除而得

SS 表示变异的绝对数量, MS 表示平均的变异大小

2 方差分析的基本思想

将反映所有观察值间的变异总离均差平方和及自由度分别分解成相关的若干部分,

然后求各相应部分的均方,

再用各部分的均方与组内均方比较,

得出检验统计量 F 值, 最后确定 P, 得出统计推断

3 应用条件

(1) 各样本相互**独立**

(2) 总体均数分别服从**正态**分布

(3) 总体方差相等, **方差齐** (如 4 个总体, 则 4 个总体得方差齐, ↓)

多样本方差齐性检验: 1) Bartlett 法: 要求来自正态分布总体

2) Levene 检验: 适用于任意分布资料, 较保守

4 应用场景

(1) 2 个或多个样本均数间的比较

(2) 分析 2 个或多个因素间的交互作用 (正交、析因)

(3) 回归方程的线性假设检验

(4) 多元线性回归分析中偏回归系数的假设检验

(5) 两样本的方差齐性检验

5 实例应用

观察某中药降脂片对高脂血症大鼠丙二醛 (MDA) 影响, 40 只高脂血症大鼠, 随机分为对照组、低剂量组、中剂量组和高剂量组, 用药 20 天后, 测定对照组和各实验组大鼠 MDA 的变化, 结果见表 7-1. 试分析各组大鼠 MDA 含量有无差异?

表 7-1 对照组和各实验组 MDA 含量 (mmol/L)

	对照组	低剂量组	中剂量组	高剂量组	合计
	8.14	7.41	7.24	6.35	
	8.10	7.44	7.20	6.27	
	8.12	7.38	7.22	6.33	
	8.16	7.47	7.18	6.29	
	8.13	7.42	7.17	6.31	
	8.14	7.49	7.21	6.40	
	8.12	7.48	7.18	6.35	
	8.10	7.43	7.22	6.30	
	8.13	7.40	7.19	6.28	
	8.20	7.48	7.23	6.36	
n_j	10	10	10	10	40 (N)
$\sum_{j=1}^{n_i} X_{ij}$	81.34	74.40	72.04	63.24	291.02 ($\sum X_{ij}$)
$\bar{X}_i$	8.134	7.440	7.204	6.324	7.2755 ($\bar{X}$)
$\sum_{j=1}^{n_i} X_{ij}^2$	661.6274	553.5492	518.9812	399.945	2134.103 ($\sum X_{ij}^2$)
S_i	0.029515	0.038287	0.023664	0.04115	

注意: Σ 的上标为上限, 下标为起始

X_{ij} 意为 i 组的第 j 个数

(1) 变异的分解 $SS_{\text{总}} = SS_{\text{组间}} + SS_{\text{组内}}$

1) 总变异 ($SS_{\text{总}}$): 40 只大鼠 MDA 含量不同, 存在变异, 称为总变异。反应了全部观察值之间的总的变异情况, 其大小可以用所有数据的总离均差平方和表示。

$$v_{\text{总}} = N (\text{总例数}) - 1, \text{此例为: } 40 - 1 = 39$$

$$SS_{\text{总}} = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X})^2 = \sum X^2 - C, \quad C = \frac{(\sum X_i)^2}{N} \text{此例为: } 2134.103 - \frac{(291.02)^2}{40} = 16.789$$

2) 组间变异 ($SS_{\text{组间}}$): 4 组大鼠 MDA 含量均数大小不同, 不同组间的差异称为... 反应的是处理因素的作用 (如果存在的话)、随机误差

$$v_{\text{组间}} = k (\text{组数}) - 1, \text{此例为: } 4 - 1 = 3,$$

$$SS_{\text{组间}} = \sum_{i=1}^k n_i (\bar{X}_i - \bar{X})^2 = \sum \frac{(\sum X_i)^2}{n_i} - C, \text{此例为: } 10(8.134 - 7.2755)^2 + \dots = 16.74547$$

3) 组内变异 ($SS_{\text{组内}}$): 同一组内大鼠 MDA 的含量并不一样, 产生这种差异的原因是 大鼠间的个体差异、测量误差等偶然因素, 由这类原因造成的误差称为随机误差。=

$$v_{\text{组内}} = \sum_{i=1}^k (n_i - 1), \text{此例为: } (10 - 1) + (10 - 1) + (10 - 1) + (10 - 1) = 36$$

$$SS_{\text{组内}} = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2, \text{此例为: } (8.14 - 8.134)^2 + (8.10 - 8.134)^2 + \dots + (7.24 - 7.204)^2 + (7.20 - 7.204)^2 + \dots + (6.36 - 7.2755)^2 = 0.04153$$

(2) 变异的比较: 组间变异与组内变异与自由度有关, 所以不能直接比较离均差平方和, 需用组间均方与组内均方相比, 即得方差分析的检验统计量 F

$$F = \frac{MS_{\text{组间}}}{MS_{\text{组内}}} = \frac{SS_{\text{组间}}/v_{\text{组间}}}{SS_{\text{组内}}/v_{\text{组内}}} = \frac{\text{处理效应的估计} + \text{误差方差的组间估计}}{\text{误差方差的组内估计}}$$

F 值的含义

1) 若各组总体均数相等，即处理因素不起作用，组间均方和组内均方都只反应随机误差，理论上，此时的组间均方和组内均方应相等，两者的比值 F 为 1；但因为分子和分母对误差方差的估计是不同的，任意一个都可能更大些，因此，当处理因素不起作用，即 H_0 成立时，根据 F 分布，F 值在 1 上下波动。

3) 若各总体存在实质差异，即处理因素起作用，组间均方是随机误差和处理因素共同起作用的结果，则组间远远大于组内，F 值明显大于 1

4. 建立假设 $H_0: \mu_1 = \mu_2 = \mu_3$;

$H_1: \mu_1, \mu_2, \mu_3$ 不等或不全相等

5. 意义：方差分析的结果只能说明多组总体均数总的是否有差异，不能推断总体均数是否两两相等，要进一步分析需进行多组均数的两两比较

二、完全随机设计资料的方差分析（单因素方差分析，one-way ANOVA, 2MS, 1F)

1 应用条件及目的

(1) 完全随机设计<包括各组含量相等和不相等的情况>

(2) 单处理因素

→通过两个或多个样本推断样本所代表的总体均数是否相等

2 基本思想

$$SS_{\text{总}} = SS_{\text{组间}} + SS_{\text{组内}}, \quad v_{\text{总}} = v_{\text{组间}} + v_{\text{组内}}$$

三、随机区组设计资料的方差分析（双因素方差分析，two-way ANOVA, 3MS, 2F)

随机区组设计资料的方差分析可分别分析处理因素和区组因素（配伍因素），因此属于双因素方差分析。

1 随机区组设计（应用条件）

(1) 概念：随机区组设计，也称配伍组设计，将受试对象先按对实验结果有影响的非处理因素（如患者按年龄、性别、病情，动物按窝别、种系等）配成若干个区组，然后再将每个区组内的受试对象随机分配到各个处理组中的方法。

(2) 目的：将对结果有干扰的非处理因素的作用加以控制，使得实验对象的变异从误差中消去，缩小实验误差

(3) 特征：① 一般来说区组内的个体数应等于实验的处理组数或其倍数

② 消除配伍因素对实验结果的影响，缩小组间差别，实验效率 > 完全随机

机

2 基本思想

因多了区组因素（配伍因素），故总变异分解为三部分。

（处理间变异：处理因素的+误差；区组间变异：个体间变异+误差；误差变异：误差
区组间变异+误差变异相当于组内变异）

$$SS_{\text{总}} = SS_{\text{处理}} + SS_{\text{误差}} + SS_{\text{区组}}, \quad v_{\text{总}} = v_{\text{处理}} + v_{\text{误差}} + v_{\text{区组}}$$

$$F_1 = \frac{MS_{\text{处理间}}}{MS_{\text{误差}}}, \quad F_2 = \frac{MS_{\text{区组间}}}{MS_{\text{误差}}}$$

3 举例

表 7-5 实验各组裸鼠胃癌移植瘤重量 (g)

种系	大蒜素剂量 (mg/kg)			对照组	
A	10.32	7.35	4.23	12.10	34
B	8.74	6.51	4.85	13.62	33.72
C	6.58	6.34	5.21	14.35	32.48
D	9.25	5.87	5.64	14.68	35.44
E	7.56	7.64	3.94	13.94	33.08
F	9.65	5.72	3.76	12.86	31.99
	52.1	39.43	27.63	81.55	200.71

C 计算同前: $(200.71)^2/24=1678.521$
SS 总=1967.241-1678.521=288.720, $v_{总}=24-1=23$
SS 处理及 $v_{处理}$: 各个处理组数据之和的平方除以 b (区组数) 减去 C
 $(52.1^2+39.43^2+27.63^2+81.55^2)/6-1678.521=268.638$, $v_{处理}=k-1=3$
SS 区组及 $v_{区组}$: 各个区组数据之和的平方除以 k (处理组数) 减去 C
 $(34^2+33.72^2+\dots+31.99^2)/4-1678.521=1.886$, $v_{区组}=b-1=5$
SS 误差及 $v_{误差}$: SS 总-SS 处理-SS 区组, 即 $288.720-268.638-1.886=18.196$
 $v_{误差}=23-5-3=15$
所以: MS 处理=268.638/3=89.546; MS 区组=1.886/5=0.3772
F 处理=89.546/1.213=73.819;
F 区组=0.3772/1.213=0.311
(可认为处理因素有影响, 区组没影响)

4 特点

- (1) 组内分出了误差和区组间, 误差变异减小了, 相应的 F 值变大, P 值减小, 越容易检测出其差异, **检验效能提高**,
- (2) 研究目的不是区组间
- (3) 当 $k=2$, 与配对设计资料的 t 检验等价, 有 $t=\sqrt{k} F$

5 SPSS

Analyze——general lineal model
——univariate——dependent variable 分析变量
Fixed factor 分组变量 (固定因素, 是确定的)
Random factor 区组变量
——Model——custom: 分组变量、区组变量选进去

Continue ok

5 了解: 如何随机区组设计

随机数生成, 组内排序

四、拉丁方设计 (three-way classification ANOVA, 4MS, 3F)

完全随机设计只涉及一个处理因素, 但随机区组设计涉及一个处理因素、一个区组因素 (或称配伍因素); 倘若实验研究涉及一个处理因素+两个控制因素, 每个因素的类别数或水平数相等, 此时可采用拉丁方设计。

特点: 在随机区组发展而来, 可多安排一个已知的对实验结果有影响的非处理因素, 增加了均衡性, 减少了误差, 提高了效率。

举例: 为了比较 1、2、3、4、5、6 这六种药物给家兔注射后产生的皮肤疱疹大小, 采

表2 5个区组小白鼠按随机区组设计分配结果															
区组号	1			2			3			4			5		
小白鼠编号	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
随机数	68	35	26	00	99	53	93	61	28	52	70	05	48	34	56
序号	3	2	1	1	3	2	3	2	1	2	3	1	2	1	3
分配结果	丙	乙	甲	甲	丙	乙	丙	乙	甲	乙	丙	甲	乙	甲	丙

用拉丁方设计，选用 6 只家兔，并在每只家兔的 6 个不同部位进行注射。

——分析：药物是处理因素，家兔和部位是减少试验误差的控制因素，且三个因素的水平数均为 6

五、两阶段交叉设计资料的方差分析（4MS，3F）

交叉设计：欲将 A、B 两种处理先后施加于同一批试验对象，随机地使 50%的实验对象先接受 A 后接受 B，另一半正好相反。

两阶段：A、B 两种因素先后以同等机会出现在两个实验阶段

洗脱阶段：消除残留效应的影响

六、多个样本均数的多重比较

——如果用 t 检验进行两两比较——**加大犯 I 类错误**（把总体均数间本无差别，判断成有差别）的概率。——如：3 个样本均数，若用 t 作 3 次比较，且每次比较的检验水准为 0.05，则每次比较不犯 I 类错误的概率为 $(1-0.05)$ ，3 次不犯 I 类错误的概率为 $(1-0.05)^3$

应用：多个样本均数比较，且要两两比较，得到谁大谁小而不是不等或不全相等的结论

1 SNK-q 检验

应用：适用于多个样本均数间两两比较（比较的次数为 $(k(k-1))/2$ ）

注意：两两比较是独立的！不可以递推

关于计算过程的简单说明，以表 7-1，对其两两比较为例（SPSS 都自动出结果了，侧重理解一下过程）

(1) 建立假设

(2) 计算检验统计量 q 值

① 将所有样本均数从大到小排序并编秩次

组别	对照组	低剂量组	中剂量组	高剂量组
均数	8.134	7.440	7.204	6.324
秩次 (R)	1	2	3	4

补充：如何编秩次？90、98、95、95、95、
首先从大到小排序，98、95、95、95、90
然后为其标秩次，第一为 1，以此类推，98 (1) ...90 (5)
关于重复的数值，重复前两秩次相加/2，即 $(1+5)/2=3$ ，分子如是奇数，可以为.5

① 几个指标：均数差值、组数 (a)（即 1 与 3 之间共有几个组，1,2, 3，共 3 个），q 值、P 值

(3) 确定 P 值，查表

2 Dunnett-t 检验

应用：适用于多个实验组均数与一个对照组均数两两比较

3 LSD-t 检验（最小显著差异 t 检验）

应用：适用于样本均数间的比较。

多组中某一对或几对在专业上有特殊意义的均数进行比较

——最全面的。往往用这个

计数资料的统计描述

一、统计指标

(助于理解) 计数资料的数据是**绝对数**, 如某病的治愈人数、死亡人数等。绝对数适用于表示被描述对象的规模, 其缺点是缺乏可比性, 如甲、乙两种疗法的治疗人数不同时, 比较两种疗法的治愈人数没有意义, 需要在绝对数的基础上计算相对数, 相对数的意义是将绝对数转换为技术相同的相对数指标, 如每百例患者治愈人数等, 以便相互比较。

(一) 相对数

相对数是两个有联系的绝对数、相对数或平均数之比。常用的相对数指标有率、构成比和相对比。

1 率: 某现象发生的频率或强度

(1) 发病率, 某一时期内 (一般为一年) 某人群中发生某病新病例的频率

$$\text{发病率} = \frac{\text{某人群某时期内某病新病例数}}{\text{该人群同期暴露人口数}} \times K$$

注意: 暴露人口是指对某病具有发病风险的人, 不包括不可能发病的人。

(2) 患病率, 某一时点某人群某病的 (新、旧) 病例数与同期平均人口数之比。

$$\text{时点患病率} = \frac{\text{某一时点某病现患病例数}}{\text{该时点人口数}} \times K$$

$$\text{时期患病率} = \frac{\text{某观察时期内某病现患病例数}}{\text{同期平均人口数}} \times K$$

时点与时期: 时点较为常用, 通常时点没有长度, 不超过 1 个月, 而时期指的是特定的一段时间, 通常多超过 1 个月, 但不超过 1 年

用途: 描述病程较长或发病时间不易明确的疾病的患病情况, 如慢性病在某一时间横断面的患病情况。在一定的时间和人群中, 患病率=发病率×病程

(3) 死亡率, 某地某人群在一定时间内 (一般为一年) 的↓之比

$$\text{死亡率} = \frac{\text{某年某人群死亡总人数}}{\text{同年该人群平均人口数}} \times K$$

(4) 病死率, 说明一种疾病的严重程度或医疗水平和质量

$$\text{某病病死率} = \frac{\text{某时期某病死亡人数}}{\text{同期该病患者总人数}} \times K$$

(5) 生存率, 是指观察对象从某个规定时刻 (如发病、确诊、开始治疗或手术时间等) 开始, 随访到一定时间的生存百分比, 常用于对慢性疾病如恶性肿瘤、心血管病等治疗的治疗效果评价或预后估计

$$n \text{ 年生存率} = \frac{\text{随访满 } n \text{ 年存活的患者数}}{\text{随访满 } n \text{ 年的患者数}} \times K$$

2 构成比: 事物内部各组成部分占整体的比重或分布

3 相对比: 甲指标/乙治标×100%, 用倍数或百分数表示

(二) 应用相对数的注意事项

- 1 计算相对数时分母不宜太小 分母过小相对数不稳定。观察单位数较小时，应直接用绝对数表示，如△“治疗 5 例，其中 4 例有效” ， 不要说有效率 80%!!
- 2 率不能相加求合计率
- 3 资料对比注意可比性，用于比较的应该是同质的。
若两组资料内部构成不同，应分组计算频率指标或标准化后再做比较。
- 4 不能以构成比代替率（结构相对数不能代替强度相对数）
构成比：事物内部某种构成所占比例或分布，并不说明某现象发生的强度和频率
比如说：各个年龄组高血压患病人数占患病总人数的比例。60-岁组百分比大，说明属于这个组的人多，不能说明这个年龄段发生的频率高
- 5 考虑抽样误差

二、率的标准化

基本思想: 采用某影响因素的统一标准构成以消除研究资料的该因素内部构成不同对合计率的影响，使通过标准化后的合计率（或总率）具有可比性。

使用注意

- 1 仅适用于因某因素两组内部构成不同的情况，并有可能影响两组总率比较的情况。对于因其他条件导致的不同不可。
- 2 由于选择的标准人口不同，算出的标准化率也不同。因此。当比较几个标准化率时，应采用统一标准人口
- 3 标准化后的标准化率不能反应当时当地的实际水平
- 4 两样本标准化率是样本值，存在抽样误差。比较两样本的标准化率，当 n 较小，还需作假设检验。

三、统计表与统计图

(一) 统计表

- 基本结构:
- 1 表号，如表 3-1
 - 2 标题，包括何时、何地、何事，如 2020 年某医院失眠症患者的分类和治疗的效果
 - 3 标目：横标目-主语，统计表所要说明的事物或对象，如中药组、针中组
纵标目-谓语，描述主语的统计指标，如治疗人数、有效人数
需要在后面标注单位，如有效率（%）
总标目-必要时可加上，一般是两行，如轻度患者、中度患者
 - 4 线条：顶线、标目线、底线 3 条等长线，顶线和底线加粗。
复合表的标目用短横线隔开
不能出现斜线和竖线
 - 5 数字：必须阿拉伯数字，每列按小数点对齐
无数字用“-”表示；确实数字用“...”表示
使用相对数也得给出绝对数
 - 6 备注：如需对某些数字或指标加以说明，在其右上角用“*”标注

举例:

表 3-15 2020 年某医院失眠症患者的分类和治疗的效果

组别	轻度患者			中度患者		
	治疗人数	有效人数	有效率(%)	治疗人数	有效人数	有效率(%)
中药组	70	55	78.6	80	56	70.0
针中组	70	62	88.6	80	62	77.5

合计	140	117	83.6	160	118	73.8
----	-----	-----	------	-----	-----	------

（二）统计图

常与统计表一起使用

基本结构：1 标题，也称图题，图的下方，包括时间、地点、对象和表的主要内容

2 坐标，横坐标，纵坐标，一般比例为 5: 7

3 刻度 4 图形 5 图例

常用统计图：1 **直条图**：等宽的直条长短表示大小，可以是绝对数也可是相对数

2 **线图**：反映在时间上的变化，适用于连续性资料

3 **直方图**：以直方面积描述各组频数和频率的多少

3 **散点图**：以点的密集程度和趋势反映两个有联系变量间的关系，

4 **箱图**：描述计量变量的分布特征，Q

计数资料的 χ^2 检验

一、 χ^2 检验概述

1 应用范围

(1) 完全随机设计 (2) 计数资料

2 目的：比较两个及两个以上样本率（构成比）差别和两个分类变量的关联性分析

3 基本思想：检验实际频数与期望频数的偏离程度（其后理解）

假设其无效假设 H_0 成立：实际频数与期望频数没有差别。基于此，计算 χ^2 值， χ^2 值表示实际频数与理论频数之间的偏离程度。

- (1) 设 A 代表某个类别的实际频数，T 代表基于 H_0 计算出的理论频数，A 与 T 之差为残差。
- (2) 残差可以表示某一个类别实际频数与理论频数的偏离程度。但是残差有正有负，相加为 0，因此可以将残差平方后求和。
- (3) 残差大小只是一个相对概念，相对于 T 为 5 时 20 的残差非常大，但相对于 T 为 500 时 20 的残差非常小，所以用残差平方除以理论频数再求和，以估计实际频数和理论频数的差别

基本步骤

4 计算及意义

$$\chi^2 = \frac{\sum \frac{(A-T)^2}{T}}$$

χ^2 值为 0，实际频数和理论频数完全一致。 χ^2 值越小则表示两者之间的差异越小，反之越大

χ^2 值的大小还与格子数相关，由于残差必大于 0，因此格子数越多，数值可能越大，因此还需考虑格子数目（自由度 ν ）的影响

$$\nu = (\text{行数 } R-1) (\text{列数 } C-1)$$

ΔT_{RC} : 第 R 行第 C 列的理论频数

6 结果判断：举例： $\chi^2_{0.05,1}=3.84$ ，如 $\chi^2 > \chi^2_{0.05,1}$ ， $P < 0.05$ ，拒绝 H_0 ，故两数不等

7 χ^2 分布

一种连续性分布，按分布的密度函数可给出不同自由度大小的一簇分布曲线，其形状大小依赖于自由度的大小

$$\nu = (R-1) (C-1) (\text{行, 列})$$

自由度与曲线：1 当自由度 $\nu < 2$ 时，曲线呈现 L 型


2 随着自由度逐渐增大，曲线逐渐趋于对称

3 当自由度逐渐正无穷时， χ^2 分布逐渐趋近正态分布

分布规律：1 自由度一定时， χ^2 值越大，P 值越小

$$\nu=1 \text{ 时, } \chi^2=3.84, P=0.05$$

$$\chi^2=6.63, P=0.01$$



8 SPSS 操作

(1) 数据输入格式

分组变量 1-试验组 2-对照组

Effect: 表示是否有效 1-有效 0-无效

F: 表示频数

(1) 频数变量进行加权

(2) **analyze- cross tabs**

Data- weigh cases by

row-组别; column-研究的内容 (非频数)

statistics-chi- square tests

注意: 配对不用区分 row、column, 并且不选 chi- square, 选 mcneemar

(3) 结果判读

1) 先看第一行

2) 其他的根据需求看用何种检验方法以选择结果

3) 最下面会有备注有无预测值 (理论数) 小于 5, 最小的是多少

4 其他一些小需求: 如百分比

二、完全随机设计 四格表 (2×2) 资料的分析

三种方法:

Pearson χ^2 检验	完全随机设计四格表资料, 总例数 $n \geq 40$ 且 所有格子 $T \geq 5$ 当 P 约等于 α , 改用 Fisher (不属于卡方)
校正 χ^2 检验	完全随机设计四格表资料, 总例数 $n \geq 40$ 且 有格子 $1 \leq T < 5$
Fisher 确切概率法	① $n < 40$ 或 $T < 1$ 时, 不能用 χ^2 检验 ↑ ② χ^2 检验或校正 χ^2 检验后所得 P 值非常接近 α

注意: 连续性校正仅仅适用于 $\nu=1$ 的四个表资料

△最小理论频数 T_{RC} 的判断: R 行 C 列中, 行合计中的最小值与列合计中的最小值所对应格子的理论频数最小

三、完全随机设计 R×C 表资料的分析

1 应用条件: 首先计算 T

理论频数不应小于 1, 且 $1 \leq T < 5$ 的格子数不超过总格子数的 1/5

如果不符合如不符合应增加样本量)

2. 多重比较: 不能用原来的检验水准 $\alpha = 0.05$, 否则会增加犯 I 型错误的概率, 可对检验水准进行调整——Bonferroni 调整检验水准法, $\alpha' = \alpha / \text{比较次数} = \alpha / k - 1$

四、配对设计计数资料的分析

△要求配行配列, 即 R=C

1. 独立性检验

(1) 目的：两种检查方法间关系的密切程度

(2) 参数：列联系数 $r_p = \sqrt{\chi^2 / (n + \chi^2)}$

2. 一致性检验 (Kappa 检验)

(1) 目的：分析评价两种检验方法或同一方法两次检验结果的一致性，常用于量表的信度分析、诊断实验、筛检实验的评价

(2) 参数：kappa 值 = $(P_o - P_e) / (1 - P_e)$, $Kappa \in [-1, 1]$

△ 观察一致率 P_o = 观察一致数 / 总检查数； 机遇一致率 P_e ；

(3) 结果判断： ①当两结果完全一致时 Kappa 值=1； ②两结果完全不一致时 Kappa 值=-1；

③观察一致性完全由机遇因素造成

3. 优势性检验 (差别性检验)

(1) McNemar 检验： 配对设计四格表资料

(2) Bowker 检验： 多分类配对设计 $k \times k$ 表资料

非参数检验（任意分布检验）

1 假设检验分为参数检验和非参数检验，参数检验是首选，非参数检验是补充（因为效能低，是分析秩次，而非分析原始资料）

2 适用范围：总体分布类型未知

3 优缺点：

- (1) 方法简便，易于理解，应用范围广，可用于等级资料、总体分布为偏态分布、个体数据偏大或数据的某一段无确定值的资料，以及各组离散程度相差悬殊的 888 资料或初步分析。（而参数检验对资料要求严格，比如说正态性、方差齐性）
- (2) 检验效率低于参数检验，故适合参数检验的首选参数。
- (3) 若对符合参数检验条件的资料用非参数检验，则降低检验效能 $(1 - \beta)$

一、配对设计资料的 符号秩和检验

1 目的

检验配对资料的差值是否来自中位数为 0 的总体或检验总体中位数是否等于指定值

2 步骤

将配对资料的差值按绝对值大小编秩次，差值为 0 的不参与编秩次，样本含量相应减 1（若差值为 0 参与编秩次，则其秩次为+0.5 -0.5 两个）

然后将差值的正负标在秩次之前

分别求出正、负秩次之和 T_+ 和 T_-

检验统计量 T 取秩和小的或样本量小的

Δ 编秩次时如两值相等，取秩次平均值，保持秩和不变

3 假设 H_0

$M_d=0$ （差值的总体中位数=0）

4 自己的理解

计量资料，配对设计，差值，本应该用配对 t 检验，结果不符合正态，所以...

三、完全随机设计资料的秩和检验

目的:比较样本分别代表的总体分布是否相同

1 完全随机设计两样本比较的秩和检验

Wilcoxon Mann-Whitney U 秩和检验的应用：

- (1) 完全随机设计的两样本计量资料的秩和检验
- (2) 两组有序分类变量资料（等级资料）的秩和检验

Δ 将两样本混合编秩次

2 完全随即设计多样本比较的秩和检验

Kruskal-Wallis H 秩和检验（K-W 检验）的应用

- (1) 完全随机设计多个样本计量资料比较的秩和检验
- (2) 多组有序分类变量资料（等级资料）的秩和检验

三、随机区组设计的秩和检验（Friedman 检验，又称 M 检验）：

随机区组设计计量资料

SPSS 操作

配对：Antlyze- Nonparametric Tests —— Legacy Dialogs——2 related samples
——两个变量于同一行

双变量相关与回归

Δ 确定性关系（函数关系）：如圆的周长和半径的关系

非确定性关系（随机关系）：如年龄与血压的关系，是指宏观上存在关系，但并未精确到可以用函数关系来表达。医学研究中常常要分析非确定性关系。

——“回归”逐渐发展成为分析两个变量或多个变量之间某种数量依存关系的一类统计方法。

一、直线相关分析（简单线性相关）

1 目的：反应两变量间是否有线性关系以及线性关系的方向、密切程度

2 适用范围：双变量正态分布

3 步骤：

考察资料是否满足双变量正态性

→做散点图考察两变量有无直线趋势

→计算相关系数 r

→相关系数的假设检验

4 相关系数（Pearson 积差相关系数）：样本是 r 、总体是 ρ

(1) r 无单位， $r \in [-1, 1]$

(2) $r \in (0, 1]$ ，正相关 $r = 1$ ，完全正相关

$r \in [-1, 0)$ ，负相关 $r = -1$ ，完全负相关

$r = 0$ ，无线性相关

—— $|r|$ 越大， X 与 Y 越密切

(3) 检验：相关系数的检验用查表法和 t 检验

5 注意：

$v = n - 2$

6 计算过程

(1) 录入数据：no、 x 、 y

(2) Analyze——Correlate——Bivariate correlations（双变量相关分析）

(3) 把 x 、 y 选到变量框；默认的：Pearson 系数、两变量

(4) 得到结果：第一行 person correlation 即是 r （样本的！）

(5) 样本 r 的假设检验（为了确定总体） $H_1: \rho = 0$

注意：这一步在进行上一步的时候已经算出来了！

Correlations		
	体重 (kg)	双肾总体积 (ml)
体重 (kg)	Pearson Correlation 1	.875**
	Sig. (2-tailed) .000	
	N 15	15
双肾总体积 (ml)	Pearson Correlation .875**	1
	Sig. (2-tailed) .000	
	N 15	15

**. Correlation is significant at the 0.01 level (2-tailed).

二、秩相关

1 目的：反映两个变量间相关关系的密切程度与相关方向

2 适用范围：①非双变量正态分布资料；②总体分布类型未知；③开口资料；④等级资料

3 假设 $\rho_s = 0$ ，不存在等级相关关系

三、直线回归分析

1 概念及目的

——指用直线回归方程表示两个变量间数量依存关系的统计分析方法，属双变量分析

目的：研究随机变量 Y 对另一个变量 X 的依存关系

△因变量 Y 、自变量 X 二者关系呈直线型的回归分析称为直线回归分析

2 应用条件 (LINE)

- (1) 线性: 因变量 Y 的总体平均值与自变量 X 有线性关系
- (2) 独立性
- (3) 正态性: 因变量 Y 服从正态分布, 对 X 无要求
- (4) 等方差性: 任意一组变量 $X_1, X_2, \dots, X_n$ 值, 因变量 Y 具有相同的方差

3 类别

- (1) I 型回归: X 为严格控制的变量, Y 为正态分布的变量
- (2) II 型回归: X、Y 均服从正态分布


4 直线回归模型: 总体 $\mu_y = \alpha + \beta X$

样本回归方程 $\hat{Y} = a + bX$ ($\hat{Y}$ 为条件均值 $\mu_{Y|X}$ 的估计值)

$\Delta \alpha$ 为截距, β 为斜率, β 为回归系数, 表示 X 每改变一个单位时, Y 平均变化值的估计值, β 有单位 (Y 的单位/X 的单位), $\beta=0$ 表示无直线关系

——参数估计的原理: 最小二乘法原理

5 直线回归方程的假设检验



(1) 基本思想: 将 Y 的总变异 $SS_{\text{总}} (Y - \bar{Y})^2$ 分解为 $SS_{\text{回归}} (Y - \hat{Y})^2$ 和 $SS_{\text{剩余}} (\hat{Y} - \bar{Y})^2$, 然后利用 F 检验判断回归方程是否成立

(2) $SS_{\text{总}} = SS_{\text{回归}} + SS_{\text{剩余}}$, $\nu_{\text{总}} = \nu_{\text{回归}} + \nu_{\text{剩余}}$ ($\nu_{\text{回归}} = 1$)

$$F = \frac{SS_{\text{回}} / \nu_{\text{回}}}{SS_{\text{剩}} / \nu_{\text{剩}}} = \frac{MS_{\text{回}}}{MS_{\text{剩}}}$$

(3) 残差分析

- 1) 残差: $Y - \hat{Y}$, 即因变量观测值与根据回归方程求出的预测值之差
- 2) 标准化残差: 残差除以它的标准差
- 3) 标准化残差图: 以 X 为横轴, 以标准化残差为纵轴
- 4) 资料满足独立性、正态性、方差齐性且无异常值, 则 95% 的标准化残差 $\in (-1.96, 1.96)$, 故通常以 $(-2, 2)$ 为界限证实模型的假定条件是否得到满足

6 决定系数

回归和与总平方和之比反映了回归贡献的相对程度, 也就是在 Y 的总变异中回归关系所能解释的百分比。

$$R^2 = SS_{\text{回}} / SS_{\text{总}}$$

7 直线回归的步骤

- (1) 考察是否符合应用条件 (2) 绘制散点图 (3) 求直线回归方程 (4) 回归方程的假设检验 (5) 回归系数的检验 ($\nu = n - 2$)
- (6) 模型的评价 (决定系数 R^2)
- (7) 绘制回归直线
- (8) 残差分析

(9) 模型的应用 (①因变量个体值的预测区间估计: 总体中 X 为某定值 X_0 时, 个体 Y_0 值的波动范围; ②因变量总体均数的可信区间: 因变量总体均数 μ_{Y_0} 的估计值)

8 回归直线适用范围: 回归直线不能外延, 适用范围一般以自变量取值范围为限

四、直线相关与直线回归

1 注意事项

- (1) 根据分析目的选择变量及统计方法
- (2) 进行相关、回归分析前要先绘制散点图
- (3) 用残差图考察数据是否符合模型应用条件
- (4) 结果的解释及正确应用

2 区别

- (1) 相关说明**相关**关系; 回归说明**依存**关系。相关反应伴随关系, 是相互的、对等的, 不一定有因果关系; 回归反应依存关系
- (2) r 与 b 的意义不同
- (3) 资料要求不同: 相关双正态, 回归 Y 在给定某个 X 值时服从正态分布, X 是可以精确测量和严格控制的变量;
- (4) 计算不同
- (5) 取值范围不同
- (6) r 没有单位, b 有单位
- (7) 分析目的不同: 相关是把两变量的直线关系的密切程度、方向用统计指标表示出来; 回归是把自变量与因变量关系用数学模型定量表示

3 联系

- (1) 变量间关系的方向一致: r 与 b 正负号一致
- (2) r 与 b 的假设检验等价: $t_r = t_b$
- (3) r 与 b 值可相互换算, $r = bs_x/s_y$
- (4) 可用回归解释相关

4 SPSS 操作

(1) 散点图绘制

(2) 求回归系数 b 和截距 a

(3) 列出回归方程

回归分析:

analyze→regression→linear regression :

dependent: y

independent: x

→ok——得到回归系数的结果 (年龄是 x , 尿肌酐含量是 y , 常数项 (constant) 是 1.662,

b 是 0.14)

Coefficients ^a					
Model		Unstandardized Coefficients		Standardized Coefficients	Sig.
		B	Std. Error	Beta	
1	(Constant)	1.662	.297		.001
	年龄	.139	.030	.882	.004

a. Dependent Variable: 尿肌酐含量

(4) 回归方程的假设检验 (方差分析法、t 检验法)

——F 检验

- (1) 建立假设 ($H_0: \beta = 0$ 是无关系, H_1 有关系)
- (2) 计算统计量, 得到 F 值、P 值

——t 检验

- (1) 建立假设
- (2) 计算统计量

多因素试验资料的方差分析

基本概念:

- 1 单因素试验：处理因素只有一个，可以有多个非研究因素（不能分析交互作用）。
- 2 多因素试验：处理因素有两个或两个以上（可以分析交互作用）

类别：析因设计、正交设计、嵌套设计、裂区设计

一、析因设计资料的方差分析 (Factorial experimental design)

1 概念

是一种将两个或多个因素的水平交叉分组进行实验的设计。它不仅可检验各因素内部不同水平间有无差异，还可检验2个或多个因素间是否存在交互作用

2 组合：各因素各水平的全面组合

- (1) 处理组合数 $g =$ 各因素水平数之积。
- (2) 注意：析因设计时，分析的因素数和水平数不宜过多，一般因素数不超过4，水平数不超过3

因素			组合数	
A	B	C		
a_1	b_1	c_1	$a_1 b_1 c_1$	$a_2 b_1 c_1$
			$a_1 b_1 c_2$	$a_2 b_1 c_2$
a_2	b_2	c_2	$a_1 b_1 c_3$	$a_2 b_1 c_3$
		c_3	$a_1 b_2 c_1$	$a_2 b_2 c_1$
			$a_1 b_2 c_2$	$a_2 b_2 c_2$
			$a_1 b_2 c_3$	$a_2 b_2 c_3$

(3) 分组

- 1) 完全随机：各组随机分配 n 个实验对象
- 2) 随机区组： n 个区组，每个区组 g 个实验对象随机分配

3 分析：单独效应、主效应、交互作用

表11-2 2×2 水平析因试验的均数差别

A因素		B因素		平均	$b_2 - b_1$
		b_1	b_2		
a_1	24	44	34	20	
a_2	28	52	40	24	
平均	26	48	22		
$a_2 - a_1$	4	8	6		

A因素 (2水平)	B因素 (2水平)	
	缝合后1月 (b_1)	缝合后2月 (b_2)
外膜缝合(a_1)	24 ($a_1 b_1$)	44 ($a_1 b_2$)
束膜缝合(a_2)	28 ($a_2 b_1$)	52 ($a_2 b_2$)

- (1) 单独效应(simple effect)：指其他因素的水平固定时，同一因素不同水平间的差别
A因素固定在1水平时，B因素的单独效应=20
2水平时，B因素的单独效应=24

- (2) 主效应 (main effect): 指某一因素各水平间的平均差别

B因素固定在1水平时，A因素的单独效应=4
2水平时，A因素的单独效应=8

——A的主效应: $(4+8)/2=6$

- (3) 交互作用(interaction)：当某因素的各个单独效应随另一因素变化而变化时，则称这两个因素间存在交互作用。

$$AB = [(a_2 b_2 - a_1 b_2) - (a_2 b_1 - a_1 b_1)] / 2 = (8 - 4) / 2 = 2$$

$$BA = [(a2b2 - a2b1) - (a1b2 - a1b1)]^2 = (24 - 20)^2 = 16$$

即 $AB = BA$

——4 个均数可作线图,若两条直线几乎相互平行, 则表示两因素交互作用很小; 若两条直线相互不平行, 则说明两因素可能存在交互作用




图11-2 两因素交互作用示意图

——A 因素(缝合方法)

的主效应为 6%, B 因素(缝合时间)的主效应为 22%, AB 的交互作用表示为 2%。以上都是样本均数的比较结果,要推论总体均数是否有同样的特征,需作假设检验即方差分析后下结论。

(4) 方差分析

总变异的离均差平方和 SS 及自由度 ν 分解为各因素的作用、两因素的交互作用及误差等部分。

表11-5 表11-1析因试验结果方差分析表

变异来源	自由度	SS	MS	F	P
总变异	19	7420			
(处理组间)	(3)	(2620)			
A	1	180	180	0.60	> 0.05
B	1	2420	2420	8.07	< 0.05
AB	1	20	20	0.07	> 0.05
误差	16	4800	300		

4 SPSS 应用

analyze→general linear model →univariate

→dependent variable:效应指标 →fixed factor:处理因素 1 处理因素 2

.....

→continue → ok

(model 选项框采用默认的全因素模型, 因为析因设计可以分析各因素的主效应和所有因素间的各级交互作用)

The image shows the SPSS Univariate dialog box on the left and the 'Tests of Between-Subjects Effects' table on the right. The dialog box has 'Dependent Variable: 神经轴通过率 (y)' and 'Fixed Factor(s): 缝合方式 (x1), 缝合时间 (x2)'. The table shows the following results:

Source	Type III Sum of Squares	df	Mean Square	F	Sig.
Corrected Model	2620.000 ^a	3	873.333	2.911	.067
Intercept	27380.000	1	27380.000	91.267	.000
x1	180.000	1	180.000	.600	.450
x2	2420.000	1	2420.000	8.067	.012
x1 * x2	20.000	1	20.000	.067	.800
Error	4800.000	16	300.000		
Total	34800.000	20			
Corrected Total	7420.000	19			

^a R Squared = .353 (Adjusted R Squared = .232)

两种缝合方式 (x1) 间的轴突通过率差异无统计学意义, 尚不能认为两种缝合方法对神经轴突通过率有影响;
 两种缝合时间 (x2) 的轴突通过率差异有统计学意义, 可以认为缝合后2月与1月相比, 神经轴突通过率提高了;
 缝合方式和缝合时间之间无交互作用。

5 优点缺点

(1) 优点: 是一高效的实验设计方法, 不仅能分析各因素内部不同水平间有无差别, 还可分析各因素间的交互作用。

(2) 缺点: 与正交实验设计相比, 属于全面试验, 因此, 研究的因素个数和因素的水

例11-4 研究雌螺产卵的最优条件，在20cm²的泥盒里饲养同龄雌螺10只，试验条件有4个因素（表11-15），每个因素2个水平。试在考虑温度与含氧量对雌螺产卵有交互作用的情况下安排正交试验。

表11-15 雌螺产卵条件因素与水平

因素水平	A因素 温度(°C)	B因素 含氧量(%)	C因素 含水量(%)	D因素 pH值
1	5	0.5	10	6.0
2	25	5.0	30	8.0

表头设计：

表11-14 L₈(2⁷) 正交设计表的表头设计

因素	实施	列号						
个数	比例	1	2	3	4	5	6	7
4	1/2	A	B	AB	C	AC	BC	D
				CD		BD		AD

表头设计：

表 L₈(2⁷) 交互作用表

列号	列号						
	1 A	2 B	3	4 C	5	6	7 D
1		3	2	5	4	7	6
2			1	6	7	4	5
3				7	6	5	4
4					1	2	3
5						3	2
6							1

注：此表用于安排各因素于各列

确定试验条件：

表11-13 L₈(2⁷) 正交设计表

试验序号	列号						
	1 A	2 B	3	4 C	5	6	7 D
1	1	1	1	1	1	1	1
2	1	1	1	2	2	2	2
3	1	2	2	1	1	2	2
4	1	2	2	2	2	1	1
5	2	1	2	1	2	1	2
6	2	1	2	2	1	2	1
7	2	2	1	1	2	2	1
8	2	2	1	2	1	1	2

注：此表用于安排实验

8 正交设计的统计分析

方差分析法：总变异的离均差平方和 SS 及自由度 ν 分解为各因素不同水平间、两因素的交互作用及误差等部分。

表 11-23 雌螺产卵条件的 L₈(2⁷) 正交试验方差分析表

变异来源	自由度	SS	MS	F	P
总变异	7	146.0			
A(温度)	1	8.0	8.0	3.2	>0.05
B(含氧量)	1	18.0	18.0	7.2	>0.05
C(含水量)	1	60.5	60.5	24.2	<0.05
D(pH)	1	4.5	4.5	1.8	>0.05
AB	1	50.0	50.0	20.0	<0.05
误差	2	5.0	2.5		

表 11-21 雌螺产卵条件的 L₈(2⁷) 正交试验方差分析计算表

试验序号	L ₈ (2 ⁷) 正交表各列(试验因素)							试验结果	
	1 (A)	2 (B)	3 (AB)	4 (C)	5	6	7 (D)	$\bar{X}$	X^2
1	1	1	1	1	1	1	1	86	7396
2	1	1	1	2	2	2	2	95	9025
3	1	2	2	1	1	2	2	91	8281
4	1	2	2	2	2	1	1	94	8836
5	2	1	2	1	2	1	2	91	8281
6	2	1	2	2	1	2	1	96	9216
7	2	2	1	1	2	2	1	83	6889
8	2	2	1	2	1	1	2	88	7744
T_{ik}	366	368	352	351	361	359	359	724	65668
T_{jk}	358	356	372	373	363	365	365		
SS_k	8	18	50	60.5	0.5	4.5	4.5		

三、嵌套试验

非各因素各水平的全面组合，而是各因素按隶属关系系统分组，各因素水平没有交叉

四、裂区设计 (split-plot design)

两因素析因设计的特殊形式。

析因设计：g 个处理全部都作用于同一级别的实验单位。

裂区设计：A 因素的 I 个水平作用于一级实验单位，

B 因素的 J 个水平作用于二级实验单位。

多元线性回归分析

一、概念

简称为多元回归，分析一个应变变量与多个自变量间的线性关系。

二、多元线性回归模型

一般形式为：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_m X_m + e$$

β_0 ：常数项，又称为**截距**

$\beta_1, \beta_2, \dots, \beta_m$ ：偏回归系数 (Partial regression coefficient) 简称回归系数，在其它自变量保持不变时 $X_i (i=1, 2, \dots, m)$ 每改变一个单位时，应变变量 Y 的平均变化量

e ：去除 m 个自变量对 Y 的影响后的随机误差，又称残差

1 一般形式

- (1) 常数项
- (2) 偏回归系数
- (3) e

2 应用条件应用条件

- (1) 线性趋势：Y 与 X_i 间具有线性关系
- (2) 独立性：应变变量 Y 的取值相互独立；
- (3) 正态性：对任意一组自变量取值，因变量 Y 服从正态分布；
- (4) 方差齐性：对任意一组自变量取值，因变量 Y 的方差相同。

——后两个条件等价于：残差 e 服从均数为 0、方差为 σ^2 的正态分布。

3 多元线性回归的分析步骤

- (1) 多元线性回归方程的建立

SPSS: Analyze → Regression → Linear regression

→ dependent : y

independent : x1-x4

→ok——得到未标准化的系数和其标准误

利用最小二乘法原理估计模型的参数：
(使残差平方和最小)

$$\begin{cases} l_{11}b_1 + l_{12}b_2 + \dots + l_{1m}b_m = l_{1Y} \\ l_{21}b_1 + l_{22}b_2 + \dots + l_{2m}b_m = l_{2Y} \\ \vdots \\ l_{m1}b_1 + l_{m2}b_2 + \dots + l_{mm}b_m = l_{mY} \end{cases}$$

$$b_0 = \bar{Y} - (b_1\bar{X}_1 + b_2\bar{X}_2 + \dots + b_m\bar{X}_m)$$

$$l_{11} = \sum (X_1 - \bar{X}_1)(X_1 - \bar{X}_1) - \frac{(\sum X_1)(\sum X_1)}{n} \quad \hat{Y} = 5.943 + 0.142X_1 + 0.351X_2 - 0.271X_3 + 0.638X_4$$

Model		Unstandardized Coefficients		Standardized Coefficients		t	Sig.
		B	Std. Error	Beta			
1	(Constant)	5.943	2.829			2.101	.047
	x1	.142	.366	.078		.390	.701
	x2	.351	.204	.309		1.721	.099
	x3	-.271	.121	-.339		-2.229	.036
	x4	.638	.243	.398		2.623	.016

a. Dependent Variable: y

- (2) 多元线性回归方程的假设检验及其评价

- 1) 方差分析法——SS 总=SS 回+SS 残

$$H_0: \beta_1 = \beta_2 = \dots = \beta_m = 0$$

$$H_1: \beta_i (i=1, 2, \dots, m) \text{ 不全为 } 0$$

$$SS_{\text{回}} = b_1 l_{1Y} + b_2 l_{2Y} + \dots + b_m l_{mY}$$

$$SS_{\text{残}} = SS_{\text{总}} - SS_{\text{回}}$$

$$F = \frac{SS_{\text{回}}/m}{SS_{\text{残}}/(n-m-1)} = \frac{MS_{\text{回}}}{MS_{\text{残}}}$$

ANOVA^b

Model	Sum of Squares	df	Mean Square	F	Sig.
1					
Regression	133.711	4	33.428	8.278	.000 ^a
Residual	88.841	22	4.038		
Total	222.552	26			

a. Predictors: (Constant), x4, x2, x3, x1

b. Dependent Variable: y

P<0.001

- 2) 决定系数 R^2

表明回归平方和在总平方和中所占的比重， R^2 越接近于 1，说明引入方程的自变量与应变量的相关程度越高，模型拟合越好(回归效果越好)。


$$R^2 = \frac{SS_{\text{回}}}{SS_{\text{总}}} \quad R_c^2 = 1 - (1 - R^2) \frac{n-1}{n-p-1}$$

R^2 受自变量个数的影响，故又提出校正决定系数，既反映模型的拟和优度，又同时考虑了模型中的自变量个数

3) 复相关系数

复相关系数：衡量因变量 y 与回归方程内所有自变量线性组合间相关关系的密切程度，也即 Y 与 $\hat{Y}$ 之间的相关系数。

值：在 0 与 1 之间，如果只有一个自变量， $R = |r|$



4 各自变量的假设检验及评价

- (1) 方差分析法
- (2) t 检验法
- (3) 标准化回归系数

对各数据进行标准化后求得的回归方程即标准化回归方程，其相应的回归系数即标准化回归系数。

标准化回归系数和一般回归系数的关系：

$$b'_j = b_j \sqrt{\frac{l_{jj}}{l_{yy}}} = b_j \frac{s_j}{s_y}$$

在有统计学意义的前提下，标准化回归系数绝对值的大小可直接进行比较，以衡量自变量对应变量的作用大小

未标准化的系数和其标准误差 标准化的系数

Model		Unstandardized Coefficients		Standardized Coefficients		t	Sig.
		B	Std. Error	Beta			
1	(Constant)	8.943	2.829			3.161	.047
	x1	.142	.366	.078		.390	.701
	x2	.351	.204	.309		1.721	.099
	x3	-.271	.123	-.339		-2.229	.036
	x4	.638	.243	.398		2.623	.016

a. Dependent Variable: y

三、自变量的选择方法

1 如果自变量很多

- (1) 增加了模型的复杂度
- (2) 计算量增大
- (3) 估计和预测的精度下降
- (4) 模型应用费用增加

2 最优回归方程

- (1) 对 y 的作用有统计学意义的自变量，全部选入回归方程
- (2) 对 y 的作用没有统计学意义的自变量，一个也不引入回归方程

3 自变量的选择方法

(1) 最优子集回归法：又称全局择优法

求出所有可能的回归模型(共有 $2^m - 1$ 个)选取最优者

(2) 前进法(forward selection)：

Y 对每一个自变量作直线回归，对回归平方和最大者作 F 检验，若有统计学意义则引入方程。

在此基础上，计算其它自变量的偏回归平方和，选取偏回归平方和最大者作 F 检验。

重复此过程，直到没有自变量可以引入为止

局限性：即后续变量的引入可能会使先进入方程的自变量变得不重要。

(3) 后退法(backward selection)

先将全部自变量放入方程，然后逐步剔除无统计学意义的自变量

首选偏回归平方和最小者，作 F 检验，决定它是否剔除。

剔除一个变量后建立新的回归方程，重复上述过程。

——局限性：自变量数目较多或高度相关时，可能得不出正确的结果

(4) 逐步回归法(stepwise regression)

回归平方和最大的 X_i 首先进入方程，在 X_i 进入方程的基础上计算其余 $m-1$ 个自变量分别进入回归方程时的偏回归平方和，其中最大者记为 SS_{j_i} ，对 X_{j_i} 进行检验，若有意义则进入方程，并重新对 X_i 进行检验。若 X_i 退化为无意义，则剔除 X_i ，同时再对 X_{j_i} 进行检验。若 X_{j_i} 依然有意义则继续选择下一个偏回归平方和最大者并进行检验。重复此过程。

双向筛选：引入一个有意义变量（前进法）的同时，剔除无意义的变量（后退法）

“先剔除后选入”原则


$\alpha_{\text{入}}$ 和 $\alpha_{\text{出}}$ 可等可不等

注意：引入变量的检验水准要小于或等于剔除变量的检验水准。

每引入或剔除一个自变量后都要重新对已进入方程中的自变量进行检验，直到方程外没有有意义的自变量可引入、方程内也没有无意义的自变量可剔除为止。

四、应用

1 影响因素分析、控制混杂因素



2 估计与预测

3 统计控制：利用回归方程进行逆估计，确定 Y 后控制 X

采用射频治疗仪治疗脑肿瘤：

脑皮质毁损半径(Y)

$$=b_0+b_1\text{射频温度}(X_1)+b_2\text{照射时间}(X_2)$$

五、注意事项

1 指标的数量化

- (1) Y 是连续变量
- (2) X 可为连续、有序分类或无需分类变量

(1) 连续变量：X

(2) 有序分类变量：

1 轻
X= 2 中
3 重

➤ 自变量为二分类变量： $X=\begin{cases} 0 & \text{男} \\ 1 & \text{女} \end{cases}$

➤ 自变量为多分类变量：假定有n类，则用n-1个取值为0或1的哑变量（dummy variables）来表示这些类别。

举例：如治疗原发性高血压有中医、西医、中西医结合三种疗法：

$$X_1 = \begin{cases} 1 & \text{中} \\ 0 & \text{其它} \end{cases} \quad X_2 = \begin{cases} 1 & \text{西} \\ 0 & \text{其它} \end{cases}$$

疗法	x_1	x_2
中医	1	0
西医	0	1
中西医结合	0	0

原始资料：

编号	年龄	疗法	...
1	50	中西	...
2	20	西	...
3	18	中	...
4	70	中	...
5	35	中西	...
6	29	西	...

用哑变量转换后：

编号	年龄	x_1	x_2	...
1	50	0	0	...
2	20	0	1	...
3	18	1	0	...
4	70	1	0	...
5	35	0	0	...
6	29	0	1	...

2 样本含量 n：至少是自变量个数 m 的 5-10 倍

3 关于逐步回归：不要盲目信任，结合专业知识

4 多重共线性: 值自变量之间存在较强的线性关系

使偏回归系数方差加大, 系数估计不稳, 难以有合乎专业知识的解释。

提示可能存在多重共线性的情况:

- 整个模型的检验结果为 $P < \alpha$, 但各自变量的偏回归系数的检验结果 $P > \alpha$ 。
- 专业上认为应该有统计学意义的自变量, 检验结果却无统计学意义。
- 自变量的偏回归系数取值大小或符号明显与实际情况相违背, 难以解释。
- 增加或删除一个自变量或一条记录, 自变量回归系数发生较大变化。

定义新变量、逐步回归、主成分回归、岭回归、路径分析

多重共线性的判断指标

容忍度: 若某变量的容忍度 ≤ 0.1 时, 说明该变量与其它变量存在严重的多重共线性。

$$Tolerance = 1 - R_j^2$$

R_j 为第j个自变量与其它自变量间的相关系数

方差膨胀因子 (VIF): 为容忍度的倒数。
 $VIF \geq 10$ 时, 存在严重的多重共线性

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Collinearity Statistics	
		B	Std. Error	Beta			Tolerance	VIF
1	(Constant)	5.943	2.829		2.101	.047		
	x1	.142	.366	.078	-.399	.701	.458	2.186
	x2	.351	.204	.309	1.721	.099	.562	1.780
	x3	-.271	.121	-.339	-2.229	.036	.782	1.278
	x4	.038	.243	.098	2.623	.016	.789	1.267

a. Dependent Variable: y

多重共线性的判断指标

条件指数: 条件指数 >30 , 则提示存在多重共线性。

$$h_j = \sqrt{\frac{\lambda_{\max}}{\lambda_j}}$$

方差比: 如两个或多个变量的方差比均 >0.5 , 说明这几个自变量之间存在多重共线性

Model	Dimension	Eigenvalue	Condition Index	Variance Proportions				
				(Constant)	x1	x2	x3	x4
1	1	4.356	1.000	.00	.00	.01	.01	.00
	2	.392	3.334	.00	.00	.39	.17	.00
	3	.216	4.487	.01	.01	.22	.43	.02
	4	.023	13.636	.00	.74	.24	.03	.51
	5	.013	18.548	.99	.24	.15	.36	.47


a. Dependent Variable: y

5 偏相关系数

6 变量间的交互作用

7 残差分析: 检验资料是否符合模型条件

回归模型应用条件的检验 (残差分析)



残差分析示意图

$$e_i = Y_i - \hat{Y}_i$$

$$e'_i = \frac{e_i}{\sqrt{MS_{残}}} \quad \text{标准化残差}$$

8 异常值的处理

识别: 标准化残差: 当 $e'_i = \frac{e_i}{\sqrt{MS_{残}}} > 2$, 可能为异常点。

- 处理:
- ☛ 核对记录是否错误, 从而修正或删除。
 - ☛ 考虑拟合其它形式的模型。
 - ☛ 进行稳健估计, 如加权最小二乘法。
 - ☛ 考虑增加样本含量。

思考题

1. 为了研究糖尿病患者的 C 反应蛋白 Y 与年龄 X1 和体重指数 X2 的关系, 某研究者调查了 60 名糖尿病患者, 测量和收集了 C 反应蛋白 Y (mg/L) 与年龄 X1 和体重指数 X2, 试问如何分析 C 反应蛋白与年龄和体重指数的关系?

2. 对于 3 个自变量和一个应变量的资料, 进行多元回归分析, 回归方程的假设检验 $P < 0.05$, 但自变量回归系数的假设检验 P 均 > 0.05 , 为什么?

Logistic 回归分析

多元线性回归模型要求：因变量为服从正态分布的连续性变量

——但是在**病因学研究、疾病预后研究**中，观察结果常常为**两分类资料**


一、概论

属于概率型非线性回归，是研究**二分类**或多分类观察结果与一些影响因素之间关系的一种多变量分析方法。

二、回归模型

因变量——阳性率——logit 变换

1 Y 的处理



2 模型构建

$$\ln \left(\frac{P}{1-P} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_m X_m$$

$$P = \frac{1}{1 + \exp[-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_m X_m)]}$$

注: $\exp x = e^x$

$Y = 1$ or 0

$P = P(Y=1 | X_1, X_2, \dots, X_m)$ 表示在 m 个自变量影响下阳性结果的发生概率。

3 模型参数的意义

常数项 β_0 : 表示暴露剂量为 0 时，个体发病与不发病概率之比的自然对数

回归系数 β_j : 表示在其他自变量不变的情况下，自变量改变一个单位时，**Logit P** 的平均改变量，它与衡量危险因素作用大小的 **OR 值** 有一个对应的关系。

【关于流行病学中的几个基本概念】 病例对照研究(case-control study): 选择患有特定疾病的人群作为病例组，以不患有该病但具有可比性的人群作为对照组，调查两组人群过去暴露于某种可能危险因素的比例，判断暴露危险因素是否与疾病有关联及其关联程度大小的一种观察性研究方法。

食管癌病例对照研究结果		
暴露 (E)	病例	对照
E^+ (如吸烟)	a	b
E^- (如不吸烟)	c	d

暴露(exposure)因素: 研究者所关心的任何因素 E^+ : 暴露 E^- : 非暴露

有害的——危险因素; 有益的——保护因素

比值(odds) : 又称为优势，某事物发生的可能性与不发生的可能性之比

比值比(odds ratio,OR): 又称比值比、优势比，指病例组的暴露比值与对照组的暴露比值之比，表示疾病与暴露之间的联系强度。 $OR = (a/b)/(c/d) = ad/bc$

相对危险度(relative risk,RR): 暴露组与非暴露组发病率之比 (队列研究)

OR、RR: >1 ——危险因素 $0 \sim 1$ ——保护因素

——什么对应?

$$\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_m X_m$$

假定其它自变量保持不变时，把 X_1 的某两个不同暴露水平分别赋值为 c_1 和 c_0

$$X_1 = c_1 : \ln \frac{P_1}{1-P_1} = \beta_0 + \beta_1 \times c_1 + \sum \dots \quad \text{式1}$$

$$X_1 = c_0 : \ln \frac{P_0}{1-P_0} = \beta_0 + \beta_1 \times c_0 + \sum \dots \quad \text{式2}$$

$$\text{式1} - \text{式2} = ?$$

$$\ln \frac{P_1}{1-P_1} - \ln \frac{P_0}{1-P_0} = \beta_1 \times (c_1 - c_0)$$

$$\ln \frac{P_1}{1-P_1} - \ln \frac{P_0}{1-P_0} = \ln \frac{\frac{P_1}{1-P_1}}{\frac{P_0}{1-P_0}} = \ln OR$$

$$\ln OR = \beta_1 \times (c_1 - c_0)$$

17

$$\ln OR = \beta_1 \times (c_1 - c_0)$$

所以任何一个自变量 X_j 的两个不同暴露水平下的比数为：

$$OR_j = \exp \beta_j$$

$$OR_j = \exp [\beta_j (c_1 - c_0)]$$

OR_j ：多变量调整后的优势比，表示扣除了其它自变量影响后危险因素的作用。

如果 X_j 只有两个水平，即暴露与非暴露，并分别赋值为0和1，则

$$OR_j = \exp \beta_j$$

$\beta_j > 0 : \exp(\beta_j) \text{ 即 } OR > 1$ 表示 X_j 是危险因素

$\beta_j < 0 : \exp(\beta_j) \text{ 即 } OR < 1$ 表示 X_j 是保护因素

$\beta_j = 0 : \exp(\beta_j) \text{ 即 } OR = 1$ 表示 X_j 不起作用

4 回归分析的步骤

- (1) 数据格式：同多元线性
- (2) 参数估计：最大似然估计法
- (3) 优势比估计

表 16-1 吸烟、饮酒与食管癌关系的病例-对照调查资料

分层	吸烟	饮酒	观察例数	阳性数	阴性数
k	X_1	X_2	n_k	d_k	$n_k - d_k$
1	0	0	199	63	136
2	0	1	170	63	107
3	1	0	101	44	57
4	1	1	416	265	151

$X_1 \begin{cases} 1 \text{ 吸烟} \\ 0 \text{ 不吸烟} \end{cases} \quad X_2 \begin{cases} 1 \text{ 饮酒} \\ 0 \text{ 不饮酒} \end{cases} \quad Y \begin{cases} 1 \text{ 病例} \\ 0 \text{ 对照} \end{cases}$

logistic回归分析结果：

$$b_0 = -0.9099 \quad S_{b_0} = 0.1358$$

$$b_1 = 0.8856 \quad S_{b_1} = 0.1500$$

$$b_2 = 0.5261 \quad S_{b_2} = 0.1572$$

吸烟与不吸烟优势比：

$$OR_1 = \exp b_1 = \exp 0.8856 = 2.42$$

OR_1 95%可信区间：

$$\exp[b_1 \pm u_{0.05/2} S_{b_1}]$$

$$= \exp(0.8856 \pm 1.96 \times 0.1500) = (1.81, 3.25)$$

饮酒与不饮酒优势比：

$$OR_2 = \exp b_2 = \exp 0.5261 = 1.69$$

OR_2 95%可信区间：

$$\exp[b_2 \pm u_{0.05/2} S_{b_2}]$$

$$= \exp(0.5261 \pm 1.96 \times 0.1572) = (1.24, 2.30)$$

——结果解读：有没有关系？有的话 OR 多少？

OR：吸烟者发生食管癌的风险是不吸烟者发生食管癌的 2.42 倍

可信区间：不包括 1，就是有关联

5 回归模型的假设检验

- (1) 似然比检验
- (2) Wald 检验
- (3) 记分检验

6 变量的筛选

- (1) 前进法
- (2) 后退法
- (3) 逐步回归法（最常用）(Forward LR)(注意：可能与多元线性不同)

——默认的进入 0.05；剔除 0.10

Variables in the Equation									
	B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for Exp(B)		
							Lower	Upper	
Step 1 ^a									
动物脂肪摄入	2.826	1.095	6.657	1	.010	16.875	1.972	144.380	
Constant	-.523	.315	2.751	1	.097	.593			
Step 2 ^b									
高血脂史	1.828	.680	7.227	1	.007	6.219	1.641	23.572	
动物脂肪摄入	3.059	1.144	7.143	1	.008	21.303	2.261	200.737	
Constant	-1.281	.461	7.715	1	.005	.278			
Step 3 ^c									
高血脂史	1.722	.714	5.814	1	.016	5.597	1.380	22.695	
动物脂肪摄入	3.028	1.176	6.627	1	.010	20.656	2.060	207.129	
A型性格	1.663	.785	4.493	1	.034	5.277	1.133	24.567	
Constant	-2.359	.770	9.378	1	.002	.095			
Step 4 ^d									
年龄(岁)	.924	.477	3.758	1	.053	2.519	.990	6.411	
高血脂史	1.496	.744	4.044	1	.044	4.464	1.039	19.181	
动物脂肪摄入	3.135	1.249	6.303	1	.012	23.000	1.989	265.945	
A型性格	1.947	.847	5.289	1	.021	7.000	1.333	36.834	
Constant	-4.705	1.543	9.295	1	.002	.009			

a. Variable(s) entered on step 1: 动物脂肪摄入.
b. Variable(s) entered on step 2: 高血脂史.
c. Variable(s) entered on step 3: A型性格.
d. Variable(s) entered on step 4: 年龄(岁).

——得到后，如何形成表现？

- (1) 只取最后一步 (2) 修改表头，比如说 p、OR

二、条件 Logistic 回归

针对配对资料分析的一种方法

三、有序 Logistic 回归、无序多分类 Logistic 回归

四、Logistic 回归的应用及其注意事项

1 应用

(1) 流行病学危险因素分析

$$1) \quad OR = \exp(\beta(c_1 - c_0))$$

- 2) 多个因素同时作用下的联合 OR 是各单个 OR 的连乘积

- 3) 交互作用

(2) 临床试验数据分析

评价某种药物疗效或治疗方法的效果时，logistic 回归可用于平衡混杂因素的影响

“控制混杂因素的一个简单方法是将其引入方程中进行分析”——自变量保持不变时，logit 的平均改变量多少。

(β_i 的意义：在其自变量不变时的作用大小)

(3) 分析药物或读物的剂量反应

- 1) 分析剂量与动物阳性反应率 P 的关系
- 2) 半数效量

(4) 预测与判别

根据患者的检测指标预测其患病的概率

2 注意事项

(1) 变量的取值形式

在做危险因素分析时，若自变量是一个定量指标，最好将其按变量值的大小进行分组，并赋值为 1, 2...k，否则参数的实际意义不大，甚至荒谬。如：年龄、血细胞计数等

有序分类变量：数量化 or 哑变量化

无序分类变量：化为 k-1 个哑变量(同进同出，不能有剔除)

β_i 的符号与自变量的取值形式有关

(2) 样本含量——基于大样本!

病例对照研究：至少各有 30-50 例；或自变量个数的 20 倍以上

(所以说，想哑变量化，也需要增大)

- (3) 变量选择
- (4) 有序 logistic 回归平行性检验
- (5) SAS 和 SPSS 中有序 logistic 回归分析结果的区别
- (6) 模型拟合优度检验

五、SPSS 操作

1 数据录入: x、y、f (一般不会录入频次, 都是直接录入)

(如果有频数, 则需要频数加权)

2 Analyze——Regression——Binary logistic (二分类的 log)

3 选 y 作为 dependent;

选所有的 x 到 covariates

——其余默认设置 (method: forward: LR options: entry 0.01

options: CI for exp remove: 0.15) ——OK

其他: ——如何进行哑变量化

比如说年龄段分了 4 个——如果直接分析, OR 是 1.91

哑变量化 (多元线性没有这个按钮, 如果想的话, 需要先产生再操作) ——categorical 选择到框中——first——change——continue
——各个年龄段与 第一个年龄段 相比

	B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for EXP(B)	
							Lower	Upper
Step 1 ^a			3.240	3	.356			
年龄(岁)								
年龄(岁)(1)	.844	1.533	.304	1	.582	2.327	.115	46.924
年龄(岁)(2)	.434	1.551	.078	1	.779	1.544	.074	32.283
年龄(岁)(3)	3.414	2.079	2.698	1	.100	30.391	.517	1786.674

——如何交互作用

多选两个——选择 a&b

4 结果解读 (主要看 variables in equation 这一个表)

Variables in the Equation									
		B	S.E.	Wald	df	Sig.	Exp(B)	95.0% C. I. for EXP(B)	
								Lower	Upper
Step 1 ^a	x1	.886	.150	34.862	1	.000	2.424	1.807	3.253
	x2	.526	.157	11.207	1	.001	1.692	1.244	2.303
	Constant	-.910	.136	44.870	1	.000	.403		

a. Variable(s) entered on step 1: x1, x2.

——回归系数、回归系数标准误、Wald χ^2 、自由度、P 值、OR 值、OR 值的可信区

间