



医学统计学

Medical Statistics



主讲人：戎芬

办公室：流行病学与卫生统计学教研室9310室


电 话：51322155

“非常痛心地看着，因为数据分析的缺陷和错误，那么多好的生物研究工作面临着被葬送的危险”。

—— F. Yates, M.J.R. Healy

为什么要学医学统计学？

统计知识
运用



```
graph LR; A[统计知识运用] --> B[撰写论文：报告自己观察或实验的研究结果。]; A --> C[阅读论文：吸收新知识，了解学术进展。];
```

撰写论文：报告自己观察
或实验的研究结果。

阅读论文：吸收新知识，
了解学术进展。

◆ 难，为什么还要学习？

实用

◆ 为什么大家认为难？

特点：抽象、复杂

◆ 难 → 易？

医学统计学的学习要求：

- 掌握基本的统计学术语
- 理解基本的统计学原理
- 培养统计思维能力
- 正确选择、运用统计分析方法

不要求公式的推导和记忆、复杂的手工计算

医学研究中常常需要回答的问题

案例1

随机抽取50—59岁男性正常人、糖尿病患者各11人，测定其血浆胆固醇含量分别为 3.20 ± 0.70 (mmol/L)、 5.35 ± 1.19 (mmol/L)，问两组人的血浆胆固醇有无差别？为什么？

$$t=5.136 \quad P < 0.01$$

案例2

表1 两种疗法治疗脑血管梗塞效果比较

疗 法	有效	无效	合计	有效率 (%)
甲疗法	25	6	31	80.6
乙疗法	35	6	41	85.4
合 计	60	12	72	83.3

$$\chi^2=0.283 \quad P=0.595$$

案例3

表3 甲乙两校35岁及以上知识分子的高血压患病率

年龄 (岁)	甲校			乙校		
	检查人数	病人数	患病率 (%)	检查人数	病人数	患病率 (%)
35~	236	16	6.78	478	33	6.90
45~	375	27	7.20	379	28	7.39
55~	384	38	9.90	235	24	10.21
65~80	402	59	14.68	157	24	15.29
合计	1397	140	10.02	1249	109	8.73

问：甲校高血压预防工作不如乙校吗？

统计学特点

- ◆ 医学+数学，侧重医学，淡化数学；
- ◆ 用数量反映质量；
- ◆ 大量观察+实验数据分析 → 可以揭示医学规律。

第一章 绪论

- 一、医学统计学的概念、作用和内容
- 二、统计学的几个基本概念
- 三、统计资料的类型
- 四、统计工作的步骤
- 五、统计学发展简史
- 六、统计学的应用及存在的问题

一、医学统计学的概念作用和内容

Statistics: “a science dealing with the collection, analysis, interpretation and presentation of masses of numerical data”

----Webster 国际大辞典

统计学是对令人困惑费解的数字问题做出设想的艺术。

---David Freedman

统计学 (statistics): 运用概率论、数理统计等原理与方法, 研究数据的收集、整理、分析的科学。

医学统计学 (statistics of medicine): 运用统计学的原理和方法, 研究医学科研中有关数据的收集、整理、分析的科学。

生物统计学 (biostatistics): 应用于整个生物学范畴，范围比医学统计学广，侧重于人的生物方面。

卫生统计学 (health statistics): 用于医学和卫生学领域，侧重于人的社会方面，如健康状况统计和卫生服务统计。

医学统计学的地位和作用


医学统计学是医学科研中不可缺少的一种分析问题和解决问题的重要工具。

- ◆ “反应停”事件
- ◆ 糙皮病的病因
- ◆ 新药评审中统计学专家的地位
- ◆ 课题组人员结构特点
- ◆ 期刊的投稿要求和审稿制度

《医学统计学》与专业……

- ◆ 学习统计学的目的？（应用）
- ◆ 与专业的关系：（辅助、服务、工具）

统计学的分类



二、统计学的几个基本概念

1. 总体与样本
2. 同质和变异
3. 参数和统计量
4. 误差
5. 频率与概率
6. 变量及变量值

1.总体与样本 (population and sample)

- 总体：根据研究目的确定的同质的研究对象的全体。更确切地说，是同质的所有观察单位某种观察值的集合。

有限总体和无限总体

- 样本：从总体中随机抽取的部分观察单位，其实测值的集合。总体中有代表性的一部分。
- 观察单位（个体）：最基本的研究单位。
- 样本量（sample size）：样本中所包含的观察单位数。



◆ 分类:

有限总体: 理论上说, 观察单位的数量是可知的、有限的。

无限总体: 没有时间和地点的限制, 观察单位总数量是不可知的。

鉴于总体的巨大或不可知性

不可能或没有必要对全体中的每一个个体进行研究

能否研究其中的一部分？



- ◆ 抽取样本的过程称为**抽样**。
- ◆ 对样本进行观察，用样本的特征推断总体的特征称作**统计推断**。





如何正确地由样本反映总体呢?

抽样时必须遵循随机化原则


样本具有代表性必须遵循的两个原则:

- (1) 随机化的抽样原则
- (2) 足够的样本含量 (n)

注意:

随机性: 总体中每个个体都有相同的机会被抽取到样本
随机不等于随意

随机抽样的实现: 随机数字表 (P_{723})



获取**样本**仅仅是**手段**，通过样本信息**推断**总体特征才是研究的**目的**。

研究目的



了解上海2002年全体正常18岁男子身高情况

总体



上海2002年全体正常18岁男子身高值

观测单位



每个正常18岁男子

观测值



正常18岁男子身高值

同质基础： 同一地区、同一年份、同为正常人、
同年满18岁、同为男子

2. 同质和变异

(homogeneity and variation)

同质:

严格定义 - 除了实验因素外, 影响被研究指标的非实验因素相同。

应用定义 - 除了实验因素外, 影响被研究指标的**主要的、可控制的非实验因素相同或基本相同**。

例如: 研究上海市2007年7岁男孩身高的正常值范围?

同质: 上海市、2007年7岁、男孩、无影响身高的疾病。

∞ **变异：** 同质研究单位之间的差异。

例如：

∞ 上海市2004年7岁男孩身高有高有矮

∞ 相同的药方治疗相同的疾病的病人，疗效有好有坏

∞ 变异是生物体的基本属性之一。

3.参数和统计量 (Parameter and statistics)

参数 (parameter)：根据总体的分布特征而计算的总体的统计指标。如总体均数、总体标准差、总体率是固定的常数 但一般未知 普查 常用希腊字母表示

统计量 (statistics)：根据样本的分布特征而计算的样本的统计指标。如样本均数、样本标准差、样本率在参数附近随机波动 抽样调查 一般用拉丁字母表示

参数和统计量


(Parameter and statistics)



4.误差 (Error)

泛指测量值与真值之差。

根据产生的原因和性质可分为三类：



- 过失误差：由观察者的错误造成（**一定要控制**）。**可以避免**
- 系统误差：数据收集和测量过程中由于仪器不准确、标准不规范等原因，造成观察结果呈倾向性的偏大或偏小，这种误差称为系统误差。**可以避免**
- 随机测量误差：由于一些非人为的偶然因素使得结果或大或小，是不确定、不可预知的。如测量一个人身高：178.12 178.09 178.15cm。**不可避免**
- 抽样误差：由于抽样所引起的样本统计量与总体参数之间的差异称为抽样误差。**不可避免**
但可以计算并在一定范围内控制抽样误差。

抽样误差 (sampling error)


抽样误差 (sampling error)： 由于个体变异和抽样所造成的样本统计量与总体参数以及样本统计量之间的差别。

例如：总体 $\begin{cases} \mu=120.0\text{cm} \\ N=5\text{万} \end{cases}$ 样本 $\begin{cases} \bar{X}=118.6\text{cm} \\ n=100 \end{cases}$

- 产生原因：个体变异、抽样
- 抽样误差特点：1) 不可避免性
2) 有统计规律性
- 样本含量越大，抽样误差越小，样本统计量与总体参数越接近，越能反映总体规律；
- 需进行统计推断。

真值

血压计
测定值



随机误差和系统误差

5. 概率和频率 (probability and frequency)

确定性现象：在一定条件下，一定会发生或一定不会发生的现象。其表现结果为两种事件：肯定发生某种结果的叫**必然事件**；肯定不发生某种结果的叫不可能事件。

随机现象：在同样条件下**可能**会出现两种或多种结果，究竟会发生哪种结果，事先不能确定。其表现结果称为**随机事件**。随机事件的特征：①随机性；②规律性：每次发生的可能性的**大小**是确定的。

频率：在相同条件下，独立地重复 n 次试验，随机事件 A 出现 f 次，则称 f/n 为随机事件 A 出现的频率。

例如投掷硬币，历史上有人对此做过实验得到如下结果：

实验者	投掷次数	“正面”次数	频 率
Buffon (法)	4040	2048	0.5069
k. pearson (英)	12000	6019	0.5016
k. pearson (英)	24000	12012	0.5005

概率：描述随机事件发生的可能性大小的度量，用大写的P表示；取值：0~1之间；P越接近于1，说明发生的可能性越大，越接近于0，说明发生的可能性越小。

小概率事件：通常一个事件的发生 $P \leq 0.05(5\%)$ 或 $P \leq 0.01(1\%)$ 称为小概率事件(习惯)，统计学上认为不大可能发生。

在实际工作中，当观察单位的例数足够多时，可以用频率来代替概率。频率是概率的估计值。

$$0 < P(A) < 1$$

随机事件

$$P(A) = 1$$


必然事件

$$P(A) = 0$$

不可能事件

Certain

1



0.5

Impossible

0

频率是就样本而言的，而概率从总体的意义上说的， f/n 是概率 $P(A)$ 的估计值。试验次数越多，估计越可靠。

6.变量及变量值

变量：观察对象的特征或指标称为变量。
如人的性别、年龄、体重、身高等。

变量值：对变量的测得值称为变量值或观察值，亦称为资料。

变量及变量值

胆管癌患者部分指标

[illegible]

三、统计资料的类型

∞ 变量的观察值组成资料。

∞ 根据变量值的性质（是否定量）可将资料分为：

1. 计量资料（定量资料）

2. 计数资料（定性资料）

3. 等级资料（半定量资料）



1. 计量资料—数值变量资料

定义：用**定量**的方法对观察单位准确测量后所得的资料。

特点：有度量衡单位，多为连续性资料。

注意：存在特殊的定量资料，如白细胞计数。

- ◆ 连续数据：身高、体重、年龄、体温、血压
- ◆ 离散数据：心率、白细胞计数、24小时早搏次数



2. 计数资料—分类变量资料

定义：用**定性**的方法得到的资料。将全体观测单位按照某种性质或特征分组，然后再分别清点各组观察单位的个数。

特点：没有度量衡单位，多为间断性资料，由无序分类变量值组成。



3. 等级资料

定义：将观察单位按某种属性的不同程度分成等级后分组计数所得的资料。是介于计量资料和计数资料之间的一种资料。

例如：疗效判定分为无效、显效、好转、治愈

特点：其变量值具有半定量性质
表现为等级大小或属性程度
由有序分类变量值组成

两分类数据(binary data)

男/女；怀孕/未怀孕；糖尿病/非糖尿病；
吸烟/不吸烟；高血压/血压正常

多分类数据(polytomous data)

无序/名义数据(nominal):

已婚/单身/离婚/分居/鳏寡； A/B/AB/O

有序/等级数据(ordinal categories) :

轻/中/重；治愈、好转、无效； - + ++

资料的类型

108例高血压患者治疗后的临床记录

患者 编号	年龄 (岁)	性 别	治疗 分组	收缩压 (kPa)	舒张压 (kPa)	心电 图	疗效 评价
1	37	男	A组	18.67	11.47	正常	治愈
2	45	女	对照	20.00	12.57	正常	好转
3	43	女	B组	17.33	10.93	异常	有效
4	55	男	对照	22.56	15.66	异常	无效
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
108	55	女	B组	16.80	11.58	正常	有效

变量

观察单位

住院号	年龄	身高	体重	住院天数	职业	文化程度	分娩方式	妊娠结局
2025655	27	165	71.5	5	无	中学	顺产	足月
2025653	22	160	74.0	5	无	小学	助产	足月
2025830	25	158	68.0	6	管理员	大学	顺产	足月
2022543	23	161	69.0	5	无	中学	剖宫产	足月
2022466	25	159	62.0	11	商业	中学	剖宫产	足月
2024535	27	157	68.0	2	无	小学	顺产	早产
2025834	20	158	66.0	4	无	中学	助产	早产
2019464	24	158	70.5	3	无	中学	助产	足月
2025783	29	154	57.0	7	干部	中学	剖宫产	足月

计量资料

计数资料

不同类型资料间的转化

不同资料转化举例（每分钟脉搏次数）

计量资料	计数资料	等级资料
75		缓 脉（ <60 ）
82	正常（60 ~ 100）	
125		正常脉（60~100）
96	异常（<60 或>100）	
56		速 脉（ >100 ）
⋮		

三类资料间的关系

例：一组20~40岁成年人的血压值资料

等级资料

<8	低血压
8~	正常血压
12~	轻度高血压
15~	中度高血压
17~	重度高血压

计量资料


计数资料

以12kPa为界分为正常与异常两组，统计每组例数

信息量：定量>等级>定性

四、统计工作的基本步骤

1. 设计：包括调查、实验设计。
2. 收集资料：取得准确可靠的原始资料
3. 整理资料：对资料进行清理、改错，数量化
4. 分析资料：统计描述、统计推断



1. 设计 (design)

设计：制定计划，对整个过程进行安排。是整个工作的**关键**。

1. 研究目的和假说。
2. 研究总体、研究对象、观察单位。
3. 是否施加干预，如何施加干预？
4. 需搜集那些资料，如何搜集？
5. 设置观察指标。
6. 资料的整理和汇总，计算有关统计量。
7. 控制误差。
8. 预期结果。
9. 时间和经费的安排等。

包括**调查设计**和**实验设计**

研究设计

研究设计要求：

- 广泛查阅文献
- 全面了解现状
- 充分征询意见
- 对研究工作进行全面设想

开题报告：意义、目的、方法、内容、对象、主要指标、进度、预期结果等。

（在文献综述基础上进行）其中有可能涉及到的统计内容是什么？

- ◆ 没有好的研究设计，数据分析将是徒劳无功的。好的结果基于好的设计：

**“The justification for the analysis lies not in the data collected but in the manner in which the data were collected”
– Schoolman et al.**

常用的设计类型 (贯穿在课程中, 穿起之间联系)

1. 一组样本与总体的比较
2. 单因素两组样本的比较 (成组和配对)
3. 单因素多组样本的比较 (成组设计)
4. 双因素多组样本的比较 (配伍组设计)
5. 三因素三组及以上设计 (拉丁方设计)
6. 三个或以上因素并交互作用 (正交设计)

2. 收集资料 (data collection)

收集资料：根据计划取得可靠、完整的资料。

资料的来源：

1. 统计报表：如疫情报表，医院工作报表等；
2. 经常性工作记录：如门诊病例、住院病例、健康检查记录、卫生监测记录等；
3. 专题调查或实验研究；
4. 统计年鉴和统计数据专辑。

收集资料要遵循**准确、完整、及时**三个原则。

注意：资料的真实性！

3. 整理资料 (data sorting)

- ◆ 目的是对收集到的原始资料整理、清理、核实、查对，使其系统化、条理化，便于进一步计算统计指标和深入分析。
- ◆ 资料整理前要对资料再次检查与核对，发现缺项或错项较多的调查表，须补查或剔除。审查无误后，设计分组。

可借助于计算机（软件：Epi-Data, StudyBuilder, Excel...）来完成。

西咪替丁缓释胶囊治疗感冒的有效性和安全性评价的II期临床研究
申报单位：青岛国风集团黄海制药有限责任公司

-----封面-----

NO 患者编号 61
CENTER 中心号 1 (1=上海长征医院, 2=复旦大学附属中山医院,
3=上海第二医科大学附属瑞金医院, 4=上海市第一人民医院)
KTIME 开始研究日期 01/06/2004
ETIME 结束日期 06/06/2004

-----随访1 (0天) -----

受试者一般资料及病史

SEX 性别 (1=男, 2=女) 2
AGE 年龄 33 BTIME 出生日期 09/05/1971 (日月年)
COURSE 病程 (小时) 10
COMD 是否伴有其他疾病 (否=0, 是=1) 0

系统分类(否=0, 是=1)			疾病名称	控制或治愈(否=0, 是=1)		
H01	心血管系统		H11		H21	
H02	消化系统		H12		H22	
H03	内分泌系统		H13		H23	
H04	血液淋巴系统		H14		H24	
H05	呼吸系统		H15		H25	
H06	泌尿系统		H16		H26	
H07	神经和精神系统		H17		H27	
H08	肌肉骨骼系统		H18		H28	
H09	眼、耳、鼻、喉		H19		H29	

4. 分析资料 (data analysis)

- ◆ 运用统计学的基本原理和方法，根据研究设计的目的、要求、资料的类型和分布特征**选择正确的统计分析方法**，进行分析计算有关的指标和数据，揭示事物内部的规律。

统计描述：统计指标、统计表、统计图等；

统计推断：参数估计、假设检验

- ◆ 可借助于计算机（常用软件：SPSS、SAS、STATA等）完成。

- Reports
- Descriptive Statistics
- Tables
- Compare Means
- General Linear Model
- Generalized Linear Models
- Mixed Models
- Correlate
- Regression
- Loglinear
- Classify
- Data Reduction
- Scale
- Nonparametric Tests**
- Time Series
- Survival
- Multiple Response
- Missing Value Analysis...
- Complex Samples
- Quality Control
- ROC Curve...

- Chi-Square...
- Binomial...
- Runs...
- 1-Sample K-5...
- 2 Independent Samples...**
- K Independent Samples...
- 2 Related Samples...
- K Related Samples...

Visible: 3 of 3 Variations

[illegible]

五、统计学发展简史

古典统计学、近代统计学、现代统计学

统计学发展过程中出现过几次重大的争论：

- “政治算术”与“国势学”的争论，明确了统计学的学科性质；
- “描述统计学”与“推断统计学”的争论，构筑了统计学的完整体系；
- “经典统计学”与“贝叶斯统计学”的争论，带来了统计哲学观的新变化；
- “信念统计学”与“经典统计学、贝叶斯统计学”的争论，使统计推断科学化问题的研究日趋深入。

通过这些争论完善了现代统计学的思想和方法体系。

计算机和统计软件如SAS、SPSS的出现使现代统计学得到了突飞猛进的发展。统计方法是建立在现代科学方法之上，由统计学理论指导的数据收集、表达和分析的方法。

六、医学统计学的应用及问题

医学论文中的统计学问题

统计图表及方法的误用

统计数据的伪造

要点总结：

1. 统计学中的几个基本概念
2. 统计资料的分类及特点
3. 统计工作的基本步骤

学习医学统计学应注意的问题

- ◆重点应放在医学统计学基本概念和基本原理的理解和掌握上；
- ◆重点应放在基本统计方法适用条件、用途及注意事项的理解和掌握上；
- ◆重点应放在运用医学统计学知识解决实际问题能力的培养上；
- ◆不必深究统计公式的数学推导，也不必死记硬背。

Thank You