



研究生《医学统计学》总复习...

第一篇 基本统计方法

流行病学与卫生统计学教研室

戎芳

主要内容

第一章 绪论

第一篇 基本统计方法

第二章 计量资料的统计描述

第三章 总体均数的估计与假设检验

第四章 多个样本均数比较的方差分析

第五章 计数资料的统计描述

第六章 几种离散型变量的分布及其应用

第七章 χ^2 检验

第八章 秩转换的非参数检验

第九章 双变量回归与相关

第十章 统计表与统计图

第一章 绪论

掌握要点：

1.统计学的几个基本概念

总体和样本、同质和变异、参数和统计量、频率与概率
误差：

非随机误差：过失误差、系统误差

随机误差：随机测量误差、随机抽样误差；


变量与资料类型

2.医学统计工作的基本步骤




第二章 计量资料的统计描述

1. 频数分布的类型：对称分布：正态分布

偏态分布  正偏态（右）
负偏态（左）

2. 频数分布的两大特征：集中趋势、离散趋势

3. 描述指标的正确选择




(1) 集中趋势描述

表 1 描述集中趋势的统计量

统计量	符号	定义	计算公式	应用条件	特点	说明
算术均数	$\bar{x}$	一组观察值之和与观察值个数之商	$\bar{x}=(\sum x)/n$	正态、近似正态或对称分布	数量上平均	只有对同质事物求均数才有意义
几何均数	G	n 个数值连乘积的 n 次方根	$G=\sqrt[n]{\prod x}$	等比或等差数列资料	比例或倍数上平均	变量值不能有 0, 也不能同时有正值和负值
中位数	M	将一组观察值按大小顺序排列, 位次居中的数值即中位数	$M=L+\frac{i}{f_m}\left(\frac{\sum f}{2}-\sum f_L\right)$	不拘分布或分布类型不明的资料	位次上平均	

注： $\sum$ 为求和的符号； x 为变量； n 为样本含量； $\prod$ 为求积的符号； L 为 M 所在组段的下限； i 为该组段的组距； f_m 为该组段的 f ； $\sum f$ 为总例数（ f 之和）； $\sum f_L$ 为小于 L 的各组段的频数。




(2) 离散趋势描述

表 2 描述离散趋势的统计量

统计量	符号	定义	计算公式	应用
极差	R	最大值与最小值之差	$R = x_{\max} - x_{\min}$	比较组间样本例数相近，有度量衡单位的资料
四分位数间距	Q_R	第 75 百分位数与第 25 百分位数之差	$Q_R = Q_U - Q_L$ $= P_{75} - P_{25}$	偏态分布、有度量衡单位的资料分布
方差	s^2	离均差平方和的均值	$s^2 = \frac{\sum (x - \bar{x})^2}{n - 1}$	描述所有观察值与均数的平均离散程度；方差分析
标准差	s	方差的平方根	$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}}$	正态分布或数据变换后近似正态分布、度量衡单位相同的资料
变异系数	CV	CV 是一组观察值的标准差与均数的百分比	$CV = (s / \bar{x}) 100\%$	CV 主要用于比较度量单位不同或度量单位相同均数相差悬殊时样本资料的离散性； CV 还可用于比较实验指标的稳定性及测定方法的精密度
均数的标准误	$s_{\bar{x}}$	均数的标准差	$s_{\bar{x}} = s / \sqrt{n}$	描述统计量的变异性及可靠性

注： $x_{\max}$ 为最大值， $x_{\min}$ 为最小值； Q_U 为上四分位数 (第 75 百分位数， P_{75})， Q_L 为下四分位数 (第 25 百分位数， P_{25})



计量资料的统计描述

- (1) 正态分布或近似正态分布资料常以 $\bar{x} \pm s$ 的形式表达，描述和比较数据的平均水平和离散程度。
- (2) 对数正态分布资料、等比资料可用几何均数和几何标准差描述。表达形式： $G \pm s_G$
- (3) 偏态分布资料、分布不明的资料、一端或两端有特大值或特小值、一些特定资料（生存时间、病程、潜伏期时间等）用中位数和四分位间距描述。表达形式： $M, Q_L \sim Q_U$

4. 正态分布的特征：两个参数、对称性、面积

5. 标准正态分布：特点、U转换

6. 医学参考值范围：概念、含义、计算方法

注意单侧与双侧问题



标准正态分布(standard normal distribution)

标准正态离
差

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

正态分布
 $X \sim N(\mu, \sigma^2)$

$$u = \frac{x - \mu}{\sigma}$$

u 为标准正态变量

$$\phi(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}$$

标准正态分布
 $u \sim N(0, 1)$

标准正态分布概率密度函数，记作 $u \sim N(0, 1)$ 。

总结 $x_1, x_2, x_3, \dots, x_n$ $x \sim N(\mu, \sigma^2)$ 抽样 $\rightarrow \bar{x}_1, \bar{x}_2, \bar{x}_3, \dots, \bar{x}_n$ $\bar{x} \sim N(\mu, \sigma_{\bar{x}}^2)$

$$\downarrow u = \frac{x - \mu}{\sigma}$$

标准状态 $u_1, u_2, u_3, \dots, u_n$ $u \sim N(0, 1)$

$$\downarrow u = \frac{\bar{x} - \mu}{\sigma_{\bar{x}}}$$

$u_1, u_2, u_3, \dots, u_n$ $u \sim N(0, 1)$

$$t_1 = \frac{\bar{x} - \mu}{S_{\bar{x}}}, \quad v = n - 1$$

经标准正态变量 u 变换：

一般正态分布 $N(\mu, \sigma^2)$



标准正态分布 $N(0, 1^2)$

标准正态分布的两个参数：

$\mu=0, \sigma=1$

记为 $N(0, 1)$

标准正态分布的曲线是**唯一**的。

表 8-5 正态分布和标准正态分布曲线下面积分布规律

正态分布	标准正态分布	面积(或概率)
$\mu - 1\sigma \sim \mu + 1\sigma$	$-1 \sim +1$	68.27%
$\mu - 1.96\sigma \sim \mu + 1.96\sigma$	$-1.96 \sim +1.96$	95.00%
$\mu - 2.58\sigma \sim \mu + 2.58\sigma$	$-2.58 \sim +2.58$	99.00%




图 13-3 正态曲线下面积分配示意图

$$u_{0.05/2} = 1.96 \quad (\text{双侧})$$

$$u_{0.05} = 1.64 \quad (\text{单侧})$$

$$u_{0.01/2} = 2.58 \quad (\text{双侧})$$

$$u_{0.01} = 2.33 \quad (\text{单侧})$$



第三章 总体均数的估计与假设检验

1. 抽样误差与标准误的概念
2. 样本均数抽样分布的特点
3. t分布图形与特征
4. 可信区间的含义
5. 假设检验的基本思想：小概率反证法思想
6. P值与 α
7. t 检验方法的应用
8. I型错误与 II 型错误
9. 单侧检验与双侧检验问题
10. 假设检验结论的写法
11. 可信区间与假设检验的关系

可证明均数标准误

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} \quad (\text{标准误的理论值})$$

在实际工作中 σ 常未知，用 S 来估计。均数标准误估计值

$$S_{\bar{X}} = \frac{S}{\sqrt{n}} \quad (\text{标准误的估计值})$$

均数标准误大小与标准差大小成正比，与样本含量 n 的平方根成反比。

注意： $\sigma_{\bar{X}}$ 、 $S_{\bar{X}}$ 均为样本均数的标准误

小结：根据数理统计推理和中心极限定理可得到如下结论

若 X_i 服从正态分布
则 $\bar{X}_j$ 服从正态分布

若 X_i 不服从正态分布
n大：则 $\bar{X}_j$ 近似服从正态分布
n小：则 $\bar{X}_j$ 为非正态分布

t分布的特征：

- ① 以0为中心的对称分布；
- ② 与U分布比，曲线低平；
- ③ t分布是一簇曲线，形态与自由度 $(n-1)$ 有关。




图 9-1 不同自由度下 t 分布曲线

总体均数可信区间的计算

$$u = \frac{\bar{x} - \mu}{\sigma_{\bar{x}}} \rightarrow \mu = \bar{x} \pm u \sigma_{\bar{x}} = \bar{x} \pm u \frac{\sigma}{\sqrt{n}} \quad \begin{matrix} \text{① } \sigma \text{ 已知} \\ \text{② } \sigma \text{ 未知, } n \text{ 足够大} \end{matrix} \quad \text{u 分布}$$
$$t = \frac{\bar{x} - \mu}{s_{\bar{x}}} \rightarrow \mu = \bar{x} \pm t s_{\bar{x}} = \bar{x} \pm t \cdot \frac{s}{\sqrt{n}} \quad \text{③ } \sigma \text{ 未知, } n \text{ 较小} \quad \text{t 分布}$$

总体均数可信区间与参考值范围的区别

	总体均数可信区间	参考值范围
含义	按预先给定的概率，确定未知参数 μ 的可能范围。实际上一次抽样算得的可信区间要么包含总体均数，要么不包含。 95%CI 估计错误的概率 ≤ 0.05 。 总体均数的波动范围	“正常人”的解剖、生理、生化某项指标的波动范围。 个体值的波动范围
计算公式	σ 未知: $\bar{X} \pm t_{\alpha, \nu} S_{\bar{X}}$ σ 已知或 σ 未知但 $n > 60$: $\bar{X} \pm u_{\alpha} \sigma_{\bar{X}}$ 或 $\bar{X} \pm u_{\alpha} S_{\bar{X}}$	正态分布 $X \pm u_{\alpha}$ 偏态分布 $P_X \sim P_{100-X}$
用途	总体均数的区间估计	绝大多数(如 95%)观察对象某项指标的分布范围



均数比较方法选择 — t 检验

分析目的	资料特点	分析方法
样本均数与 总体均数比较	正态分布	单样本 t 检验
	非正态分布	单样本秩和检验
两个相关样本均数 比较(配对设计)	差值 d 正态	配对 t 检验
	差值 d 非正态	配对符号秩和检验
两个独立样本均数 比较(随机设计或称 成组设计)	正态、方差齐	两独立样本 t 检验
	正态、方差不齐	t' 检验
	非正态、方差齐/不齐	两独立样本秩和检验


I 型错误与 II 型错误的定义如下表：

可能发生的两类错误

客观实际	假设检验的结果	
	拒绝 H_0	不拒绝 H_0
H_0 成立	I 型错误(α)	推断正确($1-\alpha$)
H_0 不成立即 H_1 成立	推断正确($1-\beta$)	II 型错误(β)



单侧检验与双侧检验




如果 $t < t_{\alpha}$, 则 $t < t_{\alpha/2} \rightarrow P > \alpha$ 不拒绝 H_0 .

如果 $t > t_{\alpha}$, 则 $t > t_{\alpha} \rightarrow P < \alpha$ 拒绝 H_0 , 接受 H_1 .


如果 $t_{\alpha/2} < t < t_{\alpha}$, 则单侧检验 $P < \alpha$ 拒绝 H_0 → 有差异的结论
双侧检验 $P > \alpha$ 不拒绝 H_0 .

可信区间比假设检验提供更多信息



附图 可信区间在统计推断上提供的信息

第四章 多个样本均数比较的方差分析

1. 方差分析的基本思想 
2. 不同设计类型的变异分解情况 
3. 不同设计类型的优缺点
4. 完全随机设计与随机区组设计方差分析的具体应用
5. 进一步两两比较问题 

ANOVA的基本思想

- 变异分解

$$SS_T = SS_A + SS_B + \dots + SS_e$$

$$V_T = V_A + V_B + \Lambda + V_e$$

- 构造检验统计量

$$F = MS_{\text{因素}} / MS_{\text{误差}}$$

$$\text{均方 } MS = SS/v$$



方差分析

设计方法	总变异的分解
完全随机分组设计	处理+误差
随机区组设计	处理+行间（个体）+误差
拉丁方设计	处理+行间+列间+误差
交叉设计	处理+行间+列间+误差

不同设计的目的是主要减少实验误差，显示处理因素的作用。



方差分析结果（处理）有统计学意义时，如了解各水平间均数差别情况，做均数间的多重比较。

研究者的目的	常用多重比较方法
1.处理组两两之间的比较	LSD-t检验 SNK-q检验
2.各处理组仅与对照组做比较	Dunnett-t检验

注意：多个均数的组间比较不要采用t检验方法，而用多重比较统计方法。

第五章 计数资料的统计描述

- 1.常用的3个相对数的含义
- 2.应用相对数的注意事项
- 3.率的标准化法的意义及基本思想
- 4.应用标准化法的注意事项

第七章 χ^2 检验

1. 成组设计四格表应用注意事项

Pearson χ^2 ? 校正? Fisher确切概率法?

2. 配对设计四格表应用注意事项

McNemar检验? 校正?

3. 多行多列表格应用注意事项

2x2 四格表资料

	+	-	合计
甲	a	b	
乙	c	d	
合计			n

成组设计

	+	-	合计
甲	a	b	
乙	c	d	
合计			n

配对设计

$n \geq 40$ 且所有 $T \geq 5$: 基本专用公式

$n \geq 40$ 但有 $1 \leq T < 5$: 校正公式

$n < 40$ 或 $T < 1$: Fisher 确切概率

$b+c \geq 40$: 基本公式

$b+c < 40$: 校正公式

对于四格表资料，通常规定：

- (1) 当 $n \geq 40$ 且所有的 $T \geq 5$ 时，用 χ^2 检验的基本公式或专用公式；当 $P \approx \alpha$ 时，改用四格表资料的Fisher确切概率法。
- (2) 当 $n \geq 40$ 但有 $1 \leq T < 5$ 时，用四格表资料 χ^2 检验的校正公式；或改用四格表资料的Fisher确切概率法
- (3) 当 $n < 40$ ，或 $T < 1$ 时，用四格表资料的Fisher确切概率法。

注意：连续性校正仅用于 $\nu=1$ 的四格表资料。

行×列表资料 χ^2 检验的注意事项

★差别有统计学意义时，只能说明总的来说有差别，但不能说明它们彼此之间都有差别

★关于不同类型**R**×**C**表资料的统计分析

★ 适用条件不满足时，可采用以下三种措施：

- 1) 增大样本例数使理论频数增大（**首选**）；
- 2) 删去理论数太小的行或列；将理论数太小的行或列与性质相近的邻行或邻列合并，使重新计算的理论频数增大
- 3) 改用双向无序**R**×**C**表资料的**Fisher**确切概率法

行列表分析方法选择概括表

行列表类型	分析目的	方法
1.双向无序 $R \times C$ 表	率的比较	χ^2 检验
	构成比比较	
	关联性分析	
2.单向有序 $R \times C$ 表		
(1) 分组变量有序、指标变量无序	指标比较	γ^2 检验
(2) 分组变量无序、指标变量有序	指标比较	秩和检验
3.双向有序属性相同的 $R \times C$ 表	一致性分析	Kappa 检验
4.双向有序属性不同的 $R \times C$ 表	组间差别	秩和检验
	相关性分析	等级相关
	分析线性趋势	线性趋势 χ^2 检验

第八章 秩转换的非参数检验

1. 参数检验与非参数检验的优缺点比较
2. 均数比较时当不符合参数检验条件才选用非参数检验方法
3. 编秩次的注意事项
4. 具体秩和检验方法的选用

方法选择

配对样本资料的比较
单样本中位数与总体中位数比较

Wilcoxon单样本秩和检验

完全随机设计计量资料两样本比较
等级资料的两样本比较

Wilcoxon两样本秩和检验

完全随机设计计量资料多样本比较
等级资料的多样本比较

Kruskal-Wallis H秩和检验

随机区组设计多个样本比较

Friedman M检验

第九章 双变量回归与相关

1. 直线相关与回归的应用条件。
2. 相关系数、回归系数、决定系数的含义及解释
3. 直线回归与直线相关的区别与联系。
4. 直线相关与回归应用注意事项
5. 秩相关适用于什么资料

直线相关与直线回归的区别与联系

联系：1. r 与 b 正负号一致：

r 为正时， b 也为正，表示两变量是正相关，是同向变化。

r 为负时， b 也为负，表示两变量是负相关，是反向变化。

2. r 与 b 的假设检验等价：对同一组资料若同时进行 r 与 b 的假设检验，可得到相同的 t 值，即 $t_r = t_b$ ，可用 r 的假设检验代替 b 的假设检验。

$$3. r = bs_x / s_y = b \sqrt{l_{XX} / l_{YY}}$$

4. 可用回归解释相关：决定系数：即相关系数的平方 r^2 。

$r^2 = SS_{\text{回}} / SS_{\text{总}}$ ，是回归平方和与总的离均差平方和之比，反映应变量 y 的总变异中可用回归关系解释的部分。越接近于1，表明利用回归方程进行预测越有意义。

$$r^2 = \frac{l_{XY}^2}{l_{XX} l_{YY}} = \frac{l_{XY}^2 / l_{XX}}{l_{YY}} = \frac{SS_{\text{回}}}{SS_{\text{总}}} = \frac{SS_{\text{总}} - SS_{\text{剩}}}{SS_{\text{总}}}$$

区别：1. 资料要求不同：直线回归要求应变量Y服从正态分布，X可以是精确测量和严格控制的变量，一般称为 I 型回归；直线相关要求两个变量X、Y服从双变量正态分布，这种资料若要进行回归分析称为 II 型回归。

2. 应用情况不同：直线回归说明两变量间依存变化的数量关系，直线相关则是说明两变量的相关关系；

3. r与b有区别：

(1) 意义不同：r说明具有直线关系的两个变量间关系的密切程度与相关方向；b表示X每改变一个单位，Y平均改变b个单位；

(2) 计算不同：

$$r = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2} \sqrt{\sum (Y - \bar{Y})^2}} = \frac{l_{XY}}{\sqrt{l_{XX}} \sqrt{l_{YY}}} \quad b = \frac{l_{xy}}{l_{xx}}$$

(3) 取值范围不同： $-1 \leq r \leq 1$ ， $-\infty \leq b \leq +\infty$

(4) 单位：r没有单位，b有单位。

第十章 统计表和统计图

1. 统计表的制作原则和要求?
2. 统计图的制作原则和要求?
3. 常用的统计图正确选用

图形	资料类型	分析目的
条图	计量/计数	用直条长短表述数值大小
百分条图	计数	用长条各段长度（面积）表达内部构成比
圆图	计数	用圆的扇形面积表达内部构成比
线图	计量	用线段的升降表达事物的动态（差值）变化
半对数线图	计量	用线段的升降表达事物的发展速度
直方图	计量	用直方面积表达各组段的频数或频率
散点图	计量	用点的密集度和趋势表达两变量间相关关系

总 结

统计分析的基本思路：

第一层面：看反应变量是单变量、双变量还是多变量

第二层面：看资料的类型（计量资料、计数资料、等级资料）

第三层面：看单因素还是多因素

第四层面：看单样本、两样本或多样本

第五层面：看设计类型（成组、配对或配伍设计... ..）

第六层面：看是否满足检验方法所需的前提条件。