


第十五章 多元线性回归分析

(Multiple Linear Regression)



Content


- **Multiple linear regression**
- **Choice of independent variable**
- **Application**

表1. 27名糖尿病人的血糖及有关变量的测量结果

序号 i	总胆固醇 (mmol/L) X_1	甘油三酯 (mmol/L) X_2	胰岛素 (μ U/ml) X_3	糖化血红蛋白 (%) X_4	血糖 (mmol/L) Y
1	5.68	1.90	4.53	8.2	11.2
2	3.79	1.64	7.32	6.9	8.8
3	6.02	3.56	6.95	10.8	12.3
M	M	M	M	M	M
27	3.84	1.20	6.45	9.6	10.4


- 人的体重与身高、胸围有关
- 人的心率与年龄、体重、肺活量有关
- 人的血压值与年龄、性别、劳动强度、饮食习惯、吸烟状况、家族史等有关
- 射频治疗仪定向治疗脑肿瘤过程中，脑皮质的毁损半径与辐射的温度、照射的时间有关

...




多元线性回归：简称为多元回归，分析一个应变变量与多个自变量间的线性关系。

- **目的：**作出以多个自变量估计应变变量的多元线性回归方程。
- **资料：**应变变量为定量指标；自变量全部或大部分为定量指标，若有少量定性或等级指标需作转换。
- **用途：**解释和预报。
- **意义：**由于事物间的联系常常是多方面的，一个应变变量的变化可能受到其它多个自变量的影响，如糖尿病人的血糖变化可能受胰岛素、糖化血红蛋白、血清总胆固醇、甘油三脂等多种生化指标的影响。



第一节 多元线性回归



一、多元线性回归模型

一般形式为：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_m X_m + \varepsilon$$

β_0 ：常数项，又称为截距。

$\beta_1, \beta_2, \dots, \beta_m$ ：偏回归系数 (Partial regression coefficient) 简称回归系数，在其它自变量保持不变时， X_i ($i=1, 2, \dots, m$) 每改变一个单位时，应变变量 Y 的平均变化量。

ε ：去除 m 个自变量对 Y 的影响后的随机误差，又称残差。

表2. 多元回归分析数据格式

例号	X_1	X_2	Λ	X_m	Y
1	X_{11}	X_{12}	Λ	X_{1m}	Y_1
2	X_{21}	X_{22}	Λ	X_{2m}	Y_2
M	M	M	M	M	M
n	X_{n1}	X_{n2}	Λ	X_{nm}	Y_n

- 样本含量: n
- 变量: 应变量1个, 自变量 m 个, 共 $m+1$ 个。

多元线性回归模型的应用条件

- 1. 线性趋势：Y与 X_i 间具有线性关系
- 2. 独立性：应变变量Y的取值相互独立
- 3. 正态性：对任意一组自变量取值，应变变量Y服从正态分布
- 4. 方差齐性：对任意一组自变量取值，应变变量y的方差相同

后两个条件等价于：残差 ε 服从均数为0、方差为 σ^2 的正态分布。

多元线性回归的分析步骤

一般步骤

(1) 求偏回归系数估计值


$$b_0, b_1, b_2, \Lambda, b_m$$

建立回归方程

$$\hat{Y} = b_0 + b_1 X_1 + b_2 X_2 + \Lambda + b_m X_m$$

假设检验

(2) 检验并评价回归方程及各自变量的作用大小



二、多元线性回归方程的建立

例15-1 27名糖尿病人的血清总胆固醇、甘油三脂、空腹胰岛素、糖化血红蛋白、空腹血糖的测量值列于表15-2中，试建立血糖与其它几项指标关系的多元线性回归方程。

表15-2. 27名糖尿病人的血糖及有关变量的测量结果

序号 i	总胆固醇 (mmol/L)	甘油三脂 (mmol/L)	胰岛素 (μ U/ml)	糖化血 红蛋白(%)	血糖 (mmol/L)
	X_1	X_2	X_3	X_4	Y
1	5.68	1.90	4.53	8.2	11.2
2	3.79	1.64	7.32	6.9	8.8
3	6.02	3.56	6.95	10.8	12.3
4	4.85	1.07	5.88	8.3	11.6
5	4.60	2.32	4.05	7.5	13.4
6	6.05	0.64	1.42	13.6	18.3
7	4.90	8.50	12.60	8.5	11.1
8	7.08	3.00	6.75	11.5	12.1
9	3.85	2.11	16.28	7.9	9.6
10	4.65	0.63	6.59	7.1	8.4
11	4.59	1.97	3.61	8.7	9.3
12	4.29	1.97	6.61	7.8	10.6
13	7.97	1.93	7.57	9.9	8.4
14	6.19	1.18	1.42	6.9	9.6
15	6.13	2.06	10.35	10.5	10.9
16	5.71	1.78	8.53	8.0	10.1
17	6.40	2.40	4.53	10.3	14.8
18	6.06	3.67	12.79	7.1	9.1
19	5.09	1.03	2.53	8.9	10.8
20	6.13	1.71	5.28	9.9	10.2
21	5.78	3.36	2.96	8.0	13.6
22	5.43	1.13	4.31	11.3	14.9
23	6.50	6.21	3.47	12.3	16.0
24	7.98	7.92	3.37	9.8	13.2
25	11.54	10.89	1.20	10.5	20.0
26	5.84	0.92	8.61	6.4	13.3
27	3.84	1.20	6.45	9.6	10.4

$$Q = \sum (Y - \hat{Y})^2 = \sum [Y - (b_0 + b_1 X_1 + b_2 X_2 + \Lambda + b_m X_m)]^2$$

求偏导数

$$\begin{cases} l_{11}b_1 + l_{12}b_2 + \Lambda + l_{1m}b_m = l_{1Y} \\ l_{21}b_1 + l_{22}b_2 + \Lambda + l_{2m}b_m = l_{2Y} \\ \Lambda \quad \Lambda \\ l_{m1}b_1 + l_{m2}b_2 + \Lambda + l_{mm}b_m = l_{mY} \end{cases}$$

原理 最小二乘法

利用最小二乘法原理估计模型的参数，使残差平方和最小

$$b_0 = \bar{Y} - (b_1 \bar{X}_1 + b_2 \bar{X}_2 + \Lambda + b_m \bar{X}_m)$$

$$\sum (Y - \hat{Y})^2 \quad l_{ij} = \sum (X_i - \bar{X}_i)(X_j - \bar{X}_j) = \sum X_i X_j - \frac{\sum X_i \sum X_j}{n}, \quad i, j=1, 2, \dots, m$$

$$l_{jY} = \sum (X_j - \bar{X}_j)(Y - \bar{Y}) = \sum X_j Y - \frac{\sum X_j \sum Y}{n}, \quad j=1, 2, \dots, m$$

$$\hat{Y} = 5.9433 + 0.1424X_1 + 0.3515X_2 - 0.2706X_3 + 0.6382X_4$$

建立多元回归方程

求解后得

$$b_1 = 0.1424 \quad b_2 = 0.3515 \quad b_3 = -0.2706 \quad b_4 = 0.6382$$


算得均值分别为 $\bar{X}_1 = 5.8126$, $\bar{X}_2 = 2.8407$, $\bar{X}_3 = 6.1467$, $\bar{X}_4 = 9.1185$,

$\bar{Y} = 11.9259$, 按照公式 $b_0 = \bar{Y} - (b_1\bar{X}_1 + b_2\bar{X}_2 + b_3\bar{X}_3 + b_4\bar{X}_4)$ 可求得常数项

$$\begin{aligned} b_0 &= 11.9259 - (0.1424 \times 5.8126 + 0.3515 \times 2.8407 - 0.2706 \times 6.1467 + 0.6382 \times 9.1185) \\ &= 5.9433 \end{aligned}$$

故所求多元回归方程为

$$\hat{Y} = 5.9433 + 0.1424X_1 + 0.3515X_2 - 0.2706X_3 + 0.6382X_4$$



三、假设检验及其评价

- 回归方程是否成立？
- 各偏回归系数是否等于0？

(一) 对回归方程的假设检验

1. 方差分析法:

$$H_0: \beta_1 = \beta_2 = \cdots = \beta_m = 0$$

$$H_1: \text{各 } \beta_j (j=1, 2, \cdots, m) \text{ 不全为 } 0$$

$$\alpha = 0.05$$

$$\text{总变异 } \sum (Y - \bar{Y})^2 = SS_{\text{总}} = SS_{\text{回}} + SS_{\text{残}}$$

$$\text{回归 } \sum (\hat{Y} - \bar{Y})^2 = SS_{\text{回}} = b_1 l_{1Y} + b_2 l_{2Y} + \cdots + b_m l_{mY} = \sum b_j l_{jY}$$

$$\text{残差 } \sum (Y - \hat{Y})^2 = SS_{\text{残}} = SS_{\text{总}} - SS_{\text{回}}$$

用统计量 F 检验假设 $H_0: \beta_1 = \beta_2 = \cdots = \beta_m = 0$ 是否成立

$$F = \frac{SS_{\text{回}} / m}{SS_{\text{残}} / (n - m - 1)} = \frac{MS_{\text{回}}}{MS_{\text{残}}} \quad F \sim F(m, n - m - 1)$$


表15-3 多元线性回归方差分析表 ($\alpha = 0.05$)

变异来源	自由度	SS	MS	F	P
总变异	$n-1$	$SS_{\text{总}}$			
回 归	m	$SS_{\text{回}}$	$SS_{\text{回}}/m$	$MS_{\text{回}}/MS_{\text{残}}$	
残 差	$n-m-1$	$SS_{\text{残}}$	$SS_{\text{残}}/(n-m-1)$		

表15-4 例15-1的方差分析表 ($\alpha = 0.05$)

变异来源	自由度	SS	MS	F	P
总变异	26	222.5519			
回 归	4	133.7107	33.4277	8.28	<0.01
残 差	22	88.8412	4.0382		

查 F 界值表得 $F_{0.01(4,22)} = 4.31$, $F > 4.31$, $P < 0.01$, 在 $\alpha = 0.05$ 水平上拒绝 H_0 , 接受 H_1 , 认为所建回归方程具有统计学意义。




2. 决定系数 R^2 :

$$R^2 = \frac{SS_{\text{回}}}{SS_{\text{总}}} = 1 - \frac{SS_{\text{残}}}{SS_{\text{总}}}$$

$0 \leq R^2 \leq 1$ ，说明自变量 X_1, X_2, Λ, X_m 能够解释 Y 变化的百分比，其值愈接近于 1，说明模型对数据的拟合程度愈好。本例

$$R^2 = \frac{133.7107}{222.5519} = 0.6008$$

表明血糖含量变异的 60% 可由总胆固醇、甘油三脂、胰岛素和糖化血红蛋白的变化来解释。




R^2 受自变量个数的影响，由此又提出校正决定系数，既反映模型的拟和优度，又同时考虑了模型中的自变量个数。

$$R_c^2 = 1 - (1 - R^2) \frac{n-1}{n-p-1}$$

n 为样本含量；

R^2 为包含 $p(p \leq m)$ 个自变量的回归方程决定系数；

R_c^2 的变化规律：当 R^2 相同时，自变量个数越多 R_c^2 越小。 R_c^2 越大，回归方程拟合效果越好。




3. 复相关系数

复相关系数 (multiple correlation coefficient) 衡量应变变量 y 与回归方程内所有自变量线性组合间相关关系的密切程度，也即 Y 与 $\hat{Y}$ 之间的相关系数。 R 其值在0与1之间。

$$R = \sqrt{R^2} = \sqrt{\frac{SS_{\text{回}}}{SS_{\text{总}}}}$$

如果只有一个自变量，此时 $R = |r|$




（二）各自变量的假设检验及评价

指明方程中的每一个自变量对 Y 的影响（方差分析和决定系数检验整体）。

1. 偏回归平方和

表示模型中含有其它 $m-1$ 个自变量的条件下该自变量对 Y 的回归贡献。其值愈大说明相应的自变量愈重要。


$$H_0 : \beta_j = 0, \quad H_1 : \beta_j \neq 0$$

$$\alpha = 0.05$$

$$F_j = \frac{SS_{\text{回}}(X_j)/1}{SS_{\text{残}}/(n-m-1)} \quad \nu_1 = 1, \quad \nu_2 = n-m-1$$

一般情况下， $m-1$ 个自变量对 Y 的回归平方和由重新建立的新方程得到，而不是简单地把 $b_j X_j$ 从有 m 个自变量的方程中剔出后算得。

各自变量的偏回归平方和可以通过拟合包含不同自变量的回归方程计算得到。

表15-5 对例15-1数据作回归分析的部分中间结果

回归方程中 包含的自变量	平方和（变异）	
	$SS_{\text{回}}$	$SS_{\text{残}}$
① X_1, X_2, X_3, X_4	133.7107	88.8412
② X_2, X_3, X_4	133.0978	89.4540
③ X_1, X_3, X_4	121.7480	100.8038
④ X_1, X_2, X_4	113.6472	108.9047
⑤ X_1, X_2, X_3	105.9168	116.6351

$$SS_{\text{回}}(X_1) = SS_{\text{回}}(X_1, X_2, X_3, X_4) - SS_{\text{回}}(X_2, X_3, X_4)$$

$$= 133.7107 - 133.0978 = 0.6129$$

$$SS_{\text{回}}(X_2) = SS_{\text{回}}(X_1, X_2, X_3, X_4) - SS_{\text{回}}(X_1, X_3, X_4)$$

$$= 133.7107 - 121.7480 = 11.9627$$

$$SS_{\text{回}}(X_3) = SS_{\text{回}}(X_1, X_2, X_3, X_4) - SS_{\text{回}}(X_1, X_2, X_4)$$

$$= 133.7107 - 113.6472 = 20.0635$$

$$SS_{\text{回}}(X_4) = SS_{\text{回}}(X_1, X_2, X_3, X_4) - SS_{\text{回}}(X_1, X_2, X_3)$$

$$= 133.7107 - 105.9168 = 27.7939$$

$$F_1 = \frac{0.6129/1}{88.8412/(27-4-1)} = 0.152, \quad F_2 = \frac{11.9627/1}{88.8412/(27-4-1)} = 2.962$$

$$F_3 = \frac{20.0635/1}{88.8412/(27-4-1)} = 4.968, \quad F_4 = \frac{27.7939/1}{88.8412/(27-4-1)} = 6.883$$

查 F 界值表, 得 $F_{0.05(1, 22)} = 4.30$, 由于 F_3 和 F_4 均大于 4.30, 故在 $\alpha=0.05$ 检验水准上拒绝 H_0 , 接受 H_1 , 认为血糖与胰岛素(X_3)、糖化血红蛋白(X_4)有线性回归关系。由两个变量的偏回归平方和大小看出, 糖化血红蛋白的回归贡献更大一些。

结果


2. t 检验法 是一种与偏回归平方和检验完全等价的一种方法。计算公式为

$$t_j = \frac{b_j}{S_{b_j}}$$

b_j 为偏回归系数的估计值, S_{b_j} 是 b_j 的标准误。

 H_0 成立时, t_j 服从自由度为 $\nu = n - m - 1$ 的 t 分布。

 如果 $|t_j| \geq t_{\alpha/2, n-m-1}$, 则在 α (0.05) 水平上拒绝 H_0 , 接受 H_1 , 说明 X_j 与 Y 有线性回归关系。



结 果

$$t_1 = \frac{0.1424}{0.3656} = 0.390$$


$$t_2 = \frac{0.3515}{0.2042} = 1.721$$

$$t_3 = \frac{-0.2706}{0.1214} = -2.229$$

$$t_4 = \frac{0.6382}{0.2433} = 2.623$$

结 论

$t_{0.05/2,22} = 2.074$, $t_4 > |t_3| > 2.074$, P 值均小于 0.05, 说明 b_3 和 b_4 有统计学意义, 而 b_1 和 b_2 则没有统计学意义。

- 
- 对于同一组资料，不同自变量的 t 值间可以互相比较， t 的绝对值越大，说明该自变量对 Y 的回归所起的作用越大。
 - 通常SPSS软件在输出多元回归分析结果时会同时给出 t 检验的结果。

3. 标准化回归系数

- 在回归模型中，各自变量的测量单位不同，若单从各偏回归系数的绝对值大小比较是不准确的。
- 应对各数据进行标准化后求得回归方程即标准化回归方程，其相应的回归系数即标准化回归系数。
- 数据标准化，将原始数据减去相应变量的均数后再除以该变量的标准差。


$$X'_j = \frac{X_j - \bar{X}_j}{S}$$

$$\hat{Y} = 5.9433 + 0.1424X_1 + 0.3515X_2 - 0.2706X_3 + 0.6382X_4$$

例 15-1 27 名糖尿病患者的血清总胆固醇、甘油三酯、空腹胰岛素、糖化血红蛋白、空腹血糖的测量值列于表 15-2 中，试建立血糖与其他几项指标的多元线性回归方程。

表 15-2 27 名糖尿病患者的血糖及有关变量的测量结果

序号 i	总胆固醇(mmol/L) X_1	甘油三酯(mmol/L) X_2	胰岛素(μ U/ml) X_3	糖化血红蛋白(%) X_4	空腹血糖(mmol/L) Y
1	5.68	1.90	4.53	8.2	11.2
2	3.79	1.64	7.32	6.9	8.8
3	6.02	3.56	6.95	10.8	12.3
4	4.85	1.07	5.88	8.3	11.6
5	4.60	2.32	4.05	7.5	13.4
6	6.05	0.64	1.42	13.6	18.3
7	4.90	8.50	12.60	8.5	11.1
8	7.08	3.00	6.75	11.5	12.1
9	3.85	2.11	16.28	7.9	9.6
10	4.65	0.63	6.59	7.1	8.4
11	4.59	1.97	3.61	8.7	9.3
12	4.29	1.97	6.61	7.8	10.6
13	7.97	1.93	7.57	9.9	8.4
14	6.19	1.18	1.42	6.9	9.6
15	6.13	2.06	10.35	10.5	10.9
16	5.71	1.78	8.53	8.0	10.1
17	6.40	2.40	4.53	10.3	14.8
18	6.06	3.67	12.79	7.1	9.1
19	5.09	1.03	2.53	8.9	10.8
20	6.13	1.71	5.28	9.9	10.2
21	5.78	3.36	2.96	8.0	13.6
22	5.43	1.13	4.31	11.3	14.9
23	6.50	6.21	3.47	12.3	16.0
24	7.98	7.92	3.37	9.8	13.2
25	11.54	10.89	1.20	10.5	20.0
26	5.84	0.92	8.61	6.4	13.3
27	3.84	1.20	6.45	9.6	10.4


$$X'_j = \frac{(X_j - \bar{X}_j)}{S_j}$$

标准化回归方程的截距为0，标准化回归系数与一般回归方程的回归系数之间的关系为：

$$b'_j = b_j \sqrt{\frac{l_{jj}}{l_{YY}}} = b_j \left(\frac{S_j}{S_Y} \right)$$

在有统计学意义的前提下，标准化回归系数绝对值的大小可直接进行比较，以衡量自变量对应变量的作用大小。

$$S_1 = 1.5934, \quad S_2 = 2.5748, \quad S_3 = 3.6706, \quad S_4 = 1.8234, \quad S_Y = 2.9257$$

$$b'_1 = 0.1424 \times \frac{1.5934}{2.9257} = 0.0776$$


$$b'_2 = 0.3515 \times \frac{2.5748}{2.9257} = 0.3093$$

$$b'_3 = -0.2706 \times \frac{3.6706}{2.9257} = -0.3395$$

$$b'_4 = 0.6382 \times \frac{1.8234}{2.9257} = 0.3977$$


结论

结果显示,对血糖影响大小的顺序依次为糖化血红蛋白(X_4)、胰岛素(X_3)、甘油三脂(X_2)和总胆固醇(X_1)。



注意

- 偏回归系数有单位，用来解释各自变量对应变量的影响，表示在其它自变量保持不变时， x_j 增加或减少一个单位时 Y 的平均变化量。不能用各 $|b_j|$ 来比较各 x_j 对 $\hat{y}$ 的影响大小。
- 标准化回归系数无单位，用来比较各自变量对应变量的影响大小， $|b'_j|$ 越大， x_j 对 $\hat{y}$ 的影响越大。




方程的求解过程复杂，可借助于SPSS、SAS等统计软件来完成

SPSS: Analyze→Regression→Linear
regression→dependent: y

independent: x_1-x_4

SPSS实现



The image displays the SPSS software interface. The 'Analyze' menu is open, showing the path: Analyze > Regression > Linear... The 'Linear...' option is highlighted by the mouse cursor. In the background, a data table is visible with the following data:

	no	X1
1	1	5.68
2	2	3.79
3	3	6.02
4	4	4.85
5	5	4.60
6	6	6.05
7	7	4.90
8	8	7.08
9	9	3.85
10	10	4.65
11	11	4.59
12	12	4.29
13	13	7.97
14	14	6.19

The 'Analyze' menu options are: Reports, Descriptive Statistics, Tables, Compare Means, General Linear Model, Mixed Models, Correlate, **Regression**, Loglinear, Classify, Data Reduction, Scale, Nonparametric Tests, Time Series, Survival, Multiple Response, Missing Value Analysis..., and Complex Samples. The 'Regression' submenu options are: **Linear...**, Curve Estimation..., Binary Logistic..., Multinomial Logistic..., Ordinal..., Probit..., Nonlinear..., Weight Estimation..., 2-Stage Least Squares..., and Optimal Scaling...

SPSS实现

Linear Regression

Dependent: # Y

Block 1 of 1

Previous Next

Independent(s):

Method: Enter

Selection Variable:

Case Labels:

WLS Weight:

Statistics... Plots... Save... Options...

OK Paste Reset Cancel Help

no
X1
X2
X3
X4

SPSS主要结果-对回归模型的F检验

ANOVA^b

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	133.711	4	33.428	8.278	.000 ^a
	Residual	88.841	22	4.038		
	Total	222.552	26			

a. Predictors: (Constant), X4, X2, X3, X1

b. Dependent Variable: Y

SPSS主要结果-模型评价指标

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.775 ^a	.601	.528	2.0095

a. Predictors: (Constant) X4, X2, X3, X1

复相关
系数

决定
系数

校正决定
系数


剩余
标准差

SPSS主要结果-偏回归系数估计及t检验

Coefficients^a


Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	5.943	2.829		2.101	.047
	X1	.142	.366	.078	.390	.701
	X2	.351	.204	.309	1.721	.099
	X3	-.271	.121	-.339	-2.229	.036
	X4	.638	.243	.398	2.623	.016

a. Dependent Variable: Y




第二节 自变量选择方法

目的：使得预报和（或）解释效果好




变量全部选入的缺点：

1. 增加了模型的复杂度
2. 计算量增大
3. 估计和预测的精度下降
4. 模型应用费用增加



最优回归方程：

- 对 y 的作用有统计学意义的自变量，全部
选入回归方程
- 对 y 的作用没有统计学意义的自变量，一
个也不引入回归方程




一、全局择优法

目的：预报效果好

意义：求出所有可能的回归模型（共有 $2^m - 1$ 个）选取最优者

选择方法：


1. 校正决定系数 R_c^2 选择法
2. C_p 选择法



1. 校正决定系数 R_c^2 选择法，其计算公式为

$$R_c^2 = 1 - (1 - R^2) \frac{n-1}{n-p-1} = 1 - \frac{MS_{\text{残}}}{MS_{\text{总}}}$$

n 为样本含量， R^2 为包含 $p(p \leq m)$ 个自变量的回归方程的决定系数。 R_c^2 的变化规律是：当 R^2 相同时，自变量个数越多 R_c^2 越小。所谓“最优”回归方程是指 R_c^2 最大者。



2. C_p 选择法

$$C_p = \frac{(SS_{\text{残}})_p}{(MS_{\text{残}})_m} - [n - 2(p + 1)]$$

$(SS_{\text{残}})_p$ 是由 $p(p \leq m)$ 个自变量作回归的误差平方和, $(MS_{\text{残}})_m$ 是从全部 m 个自变量的回归模型中得到的残差均方。

当由 p 个自变量拟合的方程理论上为最优时, C_p 的期望值是 $p+1$, 因此应选择 C_p 最接近 $p+1$ 的回归方程为最优方程。如果全部自变量中没有包含对 Y 有主要作用的变量, 则不宜用 C_p 方法选择自变量。


应选择 C_p 最接近 $p+1$ 的回归方程为最优方程。注意: 当 $p=m$ 时, 必有 $C_m=m+1$, 这种情况不在选择之列, 即应有 $p < m$ 。

例15-2 用全局择优法对例15-1数据的自变量进行选择。

方程中的 自变量	R_c^2	C_p	方程中的 自变量	R_c^2	C_p
X_2, X_3, X_4	0.546	3.15	X_2, X_3	0.408	9.14
X_1, X_2, X_3, X_4	0.528	5.00	X_1, X_3	0.375	10.78
X_1, X_3, X_4	0.488	5.96	X_4	0.347	11.63
X_1, X_2, X_4	0.447	7.97	X_1	0.284	14.92
X_1, X_4	0.441	7.42	X_1, X_2	0.275	15.89
X_2, X_4	0.440	7.51	X_3	0.231	17.77
X_3, X_4	0.435	7.72	X_2	0.179	20.53
X_1, X_2, X_3	0.408	9.88			

$m=4$ ，故回归方程拟合数为 $2^m - 1 = 2^4 - 1 = 15$ 。

最优组合均为 X_2, X_3, X_4 ，即由甘油三脂、胰岛素和糖化血红蛋白与血糖建立的回归方程最优。



全局择优法的局限性

如果自变量个数为4，则所有的回归方程有 $2^4 - 1 = 15$ 个；当自变量数个数为10时，所有可能的回归方程为 $2^{10} - 1 = 1023$ 个；当自变量个数为50时，所有可能的回归方程为 $2^{50} - 1 \approx 10^{15}$ 个。

二、逐步选择法

1. 前进法 (forward selection)
2. 后退法 (backward elimination)
3. 逐步回归法 (stepwise regression)。

它们的共同特点是每一步只引入或剔除一个自变量，决定其取舍则基于对偏回归平方和的 F 检验。


$$F_j = \frac{SS^{(l)}_{\text{回}}(X_j)/1}{SS_{\text{残}}/(n-p-1)}; v_1 = 1; v_2 = n - p - 1$$

（一）前进法（forward selection）

自变量从无到有、从少到多

1. Y 对每一个自变量作直线回归，对回归平方和最大的自变量作 F 检验，有意义（ P 小）则引入。
2. 在此基础上，计算其它自变量的偏回归平方和，选取偏回归平方和最大者作 F 检验...

局限性：即后续变量的引入可能会使先进入方程的自变量变得不重要。




（二）后退法（**backward elimination**）

先将全部自变量放入方程，然后逐步剔除


1. 选偏回归平方和最小的变量，做F检验决定它是否剔除，无意义（P大）则剔除。
2. 对剩余自变量建立新的回归方程，重复上述过程。


局限性：当自变量数目较多或某些自变量高度相关时，可能得不出正确的结果



（三）逐步回归法（**stepwise regression**）

- 双向筛选：**引入**有意义的变量（前进法），
剔除无意义变量（后退法）
- “**先剔除后选入**”原则

- 
- 自变量回归平方和最大的 X_i 首先进入方程，在 X_i 进入方程的基础上计算其余 $m-1$ 个自变量分别进入回归方程时的偏回归平方和，其中最大者记为 SS_j ，对 X_j 进行检验，若有意义则进入方程，并重新对 X_i 进行检验。若 X_i 退化为无意义，则剔除 X_i ，同时再对 X_j 进行检验。若 X_j 依然有意义则继续选择下一个偏回归平方和最大者并进行检验。重复此过程。
 - 每引入或剔除一个自变量后都要重新对已进入方程中的自变量进行检验，直到方程外没有有意义的自变量可引入、方程内也没有无意义的自变量可剔除为止。



- “先剔除后选入” 原则

- $\alpha_{\text{入}} \leq \alpha_{\text{出}}$ 引入变量的检验水准要小于或等于剔除变量的检验水准

检验水准的设置：小样本定为0.10或0.15，大样本定为0.05。 α 值定得越小表示选取自变量的标准越严，被选入的自变量个数相对也较少。

逐步回归法实例 (令 $\alpha_{\lambda}=0.10$, $\alpha_{\text{出}}=0.15$)

表 15-7 逐步回归过程

步骤(l)	引入变量	剔除变量	变量个数 p	R^2	$SS_{\text{回}}^{(l)}(X_j)$	$SS_{\text{残}}^{(l)}$	F 值	P 值
1	X_4		1	0.372	82.714	139.837	14.788	0.0007
2	X_1		2	0.484	25.076	114.762	5.244	0.0311
3	X_3		3	0.547	13.958	100.804	3.185	0.0875
4	X_2		4	0.601	11.963	88.841	2.962	0.0993
5		X_1	3	0.598	0.613	88.841	0.152	0.7006

逐步回归法实例（第一步）

模型	$SS_{回}$	$SS_{残}$	$SS_{总}$	F值	P值
Y与 X_4	82.7144	139.8375	222.5519	14.788	0.0007
Y与 X_1	69.4251	153.1267	222.5519		
Y与 X_2	46.7873	175.7645	222.5519		
Y与 X_3	57.9133	164.6386	222.5519		

X_4 选入方程

逐步回归法实例（第二步）

模型	SS _回	SS _{偏回}	SS _残	F值	P值
Y与X ₄	82.7144				
Y与X ₄ X ₁	107.7903	25.0759	114.7615	5.2441	0.0311
Y与X ₄ X ₂	107.4074	24.6931	115.1444	5.1469	0.0326
Y与X ₄ X ₃	106.5683	23.8539	115.9836	4.9360	0.0360

X₁引入方程

逐步回归法实例 (X_4/X_1 剔除否)

变量	模型	$SS_{回}$	$SS_{偏回}$	$SS_{残}$	F值	P值
	Y与 X_4 X_1	107.7903		114.7615		
X_4	Y与 X_1	69.4251	38.3652			
X_1	Y与 X_4	82.7144	25.0759		5.2441	0.0311

X_1 不能剔除

逐步回归法实例（第三步）

模型	SS _回	SS _{偏回}	SS _残	F值	P值
Y与X ₄ X ₁	107.7903				
Y与X ₄ X ₁ X ₂	113.6472	5.8569			
Y与X ₄ X ₁ X ₃	121.7480	13.9577	100.8038	3.1847	0.0875

X₃引入方程

逐步回归法实例 ($X_4/X_1/X_3$ 剔除否)

变量	模型	$SS_{回}$	$SS_{偏回}$	$SS_{残}$	F值	P值
	Y与 $X_4 X_1 X_3$	121.7480		100.804		
X_1	Y与 $X_4 X_3$	106.5683	15.1797			
X_3	Y与 $X_4 X_1$	107.7903	13.9577		3.1847	0.0870
X_4	Y与 $X_1 X_3$	94.2026	27.5454			

X_3 不能剔除

逐步回归法实例（第四步）

模型	$SS_{回}$	$SS_{偏回}$	$SS_{残}$	F值	P值
Y与 X_4 X_1 X_3	121.7480				
Y与 X_4 X_1 X_3 X_2	133.7107	11.9627	88.8412	2.9624	0.099

X_2 引入方程

逐步回归法实例（ $X_4/X_1/X_3/X_2$ 剔除否）


变量	模型	$SS_{回}$	$SS_{偏回}$	$SS_{残}$	F值	P值
	Y与 $X_4 X_1 X_3 X_2$	133.7107		88.8412		
X_2	Y与 $X_4 X_1 X_3$	121.7480	11.9627			
X_1	Y与 $X_4 X_3 X_2$	133.0978	0.6129		0.1518	0.7006
X_3	Y与 $X_4 X_1 X_2$	113.6472	20.0635			
X_4	Y与 $X_1 X_3 X_2$	105.9167	27.7940			

X_1 剔除

逐步回归法实例（第五步）

变量	模型	SS _回	SS _{偏回}	SS _残	F值	P值
	Y与X ₄ X ₃ X ₂	133.0978		89.4540		
X ₄	Y与X ₃ X ₂	100.8292	32.2686			
X ₃	Y与X ₄ X ₂	107.4074	25.6904		6.6054	0.0171
X ₂	Y与X ₄ X ₃	106.5683	26.5295			

既不能剔除，也不能引入，选择自变量过程结束



例15-3的方差分析结果

变异来源	自由度	<i>SS</i>	<i>MS</i>	<i>F</i>	<i>P</i>
总变异	26	222.5519			
回 归	3	133.098	44.366	11.41	0.0001
残 差	23	89.454	3.889		

例15-3的回归系数及其检验

变量	回归系数 b	标准误 S_b	标准回归系数 b'	t 值	P 值
常数项	6.4996	2.3962		2.713	0.0124
X_2	0.4023	0.1540	0.3541	2.612	0.0156
X_3	-0.2870	0.1117	-0.3601	-2.570	0.0171
X_4	0.6632	0.2303	0.4133	2.880	0.0084

方程为： $\hat{Y} = 6.4996 + 0.4023 X_2 - 0.2871 X_3 + 0.6632 X_4$

“最优”回归方程为

$$\hat{Y} = 6.4996 + 0.4023X_2 - 0.2871X_3 + 0.6632X_4$$

结果表明：血糖的变化与甘油三脂、胰岛素和糖化血红蛋白有线性回归关系，其中与胰岛素负相关。由标准化回归系数看出，糖化血红蛋白对空腹血糖的影响最大。

注意：

外引 $F_j \geq F_{\alpha_{\lambda}(1, n-p-1)}$ $P < \alpha_{\lambda}$ X_j 入选

内剔 $F_j \leq F_{\alpha_{\text{出}}(1, n-p-1)}$ $P > \alpha_{\text{出}}$ X_j 剔除

$\alpha_{\lambda} \leq \alpha_{\text{出}}$ ，以免 X_j 上一步剔除后下一步又被选入

选入和剔除的检验水准改变时结果也会改变，

如 $\alpha_{\text{入}}=0.05$ 、 $\alpha_{\text{出}}=0.10$ 时结果为：

Variables Entered/Removed^a

Model	Variables Entered	Variables Removed	Method
1	x4	.	Stepwise (Criteria: Probability-of-F-to-enter <= .050, Probability-of-F-to-remove >= .100)
2	x1	.	Stepwise (Criteria: Probability-of-F-to-enter <= .050, Probability-of-F-to-remove >= .100)

a. Dependent Variable: y

选入和剔除的检验水准改变时结果也会改变，

如 $\alpha_{\text{入}}=0.1$ 、 $\alpha_{\text{出}}=0.15$ 时结果为：

Variables Entered/Removed^a

Model	Variables Entered	Variables Removed	Method
1	x4	.	Stepwise (Criteria: Probability-of-F-to-enter <= .1 Probability-of-F-to-remove >= .150).
2	x1	.	Stepwise (Criteria: Probability-of-F-to-enter <= .1 Probability-of-F-to-remove >= .150).
3	x3	.	Stepwise (Criteria: Probability-of-F-to-enter <= .1 Probability-of-F-to-remove >= .150).
4	x2	.	Stepwise (Criteria: Probability-of-F-to-enter <= .1 Probability-of-F-to-remove >= .150).
5	.	x1	Stepwise (Criteria: Probability-of-F-to-enter <= .1 Probability-of-F-to-remove >= .150).

a. Dependent Variable: y

SPSS实现

Linear Regression

Dependent:

Block 1 of 1

Independent(s):

Method:

Buttons: Previous, Next

Linear Regression: Options

Stepping Method Criteria

☒ Use probability of F
Entry: Removal:

☐ Use F value
Entry: Removal:

☒ Include constant in equation

Missing Values

☒ Exclude cases listwise
☐ Exclude cases pairwise
☐ Replace with mean

Buttons: Continue, Cancel, Help

Linear Regression: Statistics

Regression Coefficients

☒ Estimates
☐ Confidence intervals
☐ Covariance matrix

☒ Model fit
☐ R squared change
☐ Descriptives
☒ Part and partial correlations
☐ Collinearity diagnostics

Residuals

☐ Durbin-Watson
☐ Casewise diagnostics
 ☒ Outliers outside: standard deviations
 ☐ All cases

Buttons: Continue, Cancel, Help

21
22
23
24

SPSS主要输出结果

ANOVA^f

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	82.714	1	82.714	14.788	.001 ^a
	Residual	139.837	25	5.593		
	Total	222.552	26			
2	Regression	107.790	2	53.895	11.271	.000 ^b
	Residual	114.762	24	4.782		
	Total	222.552	26			
3	Regression	121.748	3	40.583	9.260	.000 ^c
	Residual	100.804	23	4.383		
	Total	222.552	26			
4	Regression	133.711	4	33.428	8.278	.000 ^d
	Residual	88.841	22	4.038		
	Total	222.552	26			
5	Regression	133.098	3	44.366	11.407	.000 ^e
	Residual	89.454	23	3.889		
	Total	222.552	26			

a. Predictors: (Constant), X4

b. Predictors: (Constant), X4, X1

c. Predictors: (Constant), X4, X1, X3

d. Predictors: (Constant), X4, X1, X3, X2

e. Predictors: (Constant), X4, X3, X2

f. Dependent Variable: Y

SPSS主要输出结果

Coefficients^a

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Correlations		
		B	Std. Error	Beta			Zero-order	Partial	Part
1	(Constant)	3.006	2.364		1.272	.215			
	X4	.978	.254	.610	3.845	.001	.610	.610	.610
2	(Constant)	1.310	2.308		.568	.576			
	X4	.732	.259	.456	2.833	.009	.610	.501	.415
	X1	.678	.296	.369	2.290	.031	.559	.423	.336
3	(Constant)	4.309	2.776		1.552	.134			
	X4	.635	.253	.396	2.507	.020	.610	.463	.352
	X1	.545	.293	.297	1.861	.076	.559	.362	.261
	X3	-.219	.122	-.274	-1.785	.088	-.510	-.349	-.250
4	(Constant)	5.943	2.829		2.101	.047			
	X4	.638	.243	.398	2.623	.016	.610	.488	.353
	X1	.142	.366	.078	.390	.701	.559	.083	.052
	X3	-.271	.121	-.339	-2.229	.036	-.510	-.429	-.300
	X2	.351	.204	.309	1.721	.099	.459	.344	.232
5	(Constant)	6.500	2.396		2.713	.012			
	X4	.663	.230	.413	2.880	.008	.610	.515	.381
	X3	-.287	.112	-.360	-2.570	.017	-.510	-.472	-.340
	X2	.402	.154	.354	2.612	.016	.459	.478	.345

a. Dependent Variable: Y

SPSS主要输出结果

Excluded Variables

Model		Beta In	t	Sig.	Partial Correlation	Collinearity Statistics
						Tolerance
1	X1	.369 ^a	2.290	.031	.423	.828
	X2	.341 ^a	2.269	.033	.420	.952
	X3	-.347 ^a	-2.222	.036	-.413	.891
2	X2	.210 ^b	1.112	.278	.226	.599
	X3	-.274 ^b	-1.785	.088	-.349	.834
3	X2	.309 ^c	1.721	.099	.344	.562
5	X1	.078 ^d	.390	.701	.083	.458


a. Predictors in the Model: (Constant), X4

b. Predictors in the Model: (Constant), X4, X1


c. Predictors in the Model: (Constant), X4, X1, X3

d. Predictors in the Model: (Constant), X4, X3, X2

e. Dependent Variable: Y




第三节 多元线性回归的 应用及注意事项



一、多元线性回归的应用

1. 影响因素分析
2. 混杂因素控制
3. 估计与预测
4. 统计控制（逆估计）



1. 影响因素分析


年龄 (X_1)

饮食习惯 (X_2)

吸烟状况 (X_3)


工作紧张度 (X_4)

家族史 (X_5)




高血压 (Y)

- M
- 在影响高血压的众多可疑因素中，需要研究哪些因素有影响，哪些因素影响较大。



2. 混杂因素控制


- 在临床试验中，可能由于种种原因难以保证各组的指标基线相同，如在年龄、病情等指标不一致出现混杂的情况下，如何对不同的治疗方法进行比较等。
- 这些问题都可以利用回归分析来处理。控制混杂因素(confounding factor)的一个简单办法就是将其引入回归方程中，与其他主要变量一起进行分析。



3. 估计与预测

预测：由自变量值推出因变量Y的值、容许区间和总体均数的可信区间。

- 新生儿体重 $(Y) = b_0 + b_1 \text{胎儿孕龄}(X_1) + b_2 \text{胎儿头径}(X_2) + b_3 \text{胎儿胸径}(X_3) + b_4 \text{胎儿腹径}(X_4)$
- 心脏表面积 $(Y) = b_0 + b_1 \text{心脏横径}(X_1) + b_2 \text{心脏纵径}(X_2) + b_3 \text{心脏宽径}(X_3)$



4. 统计控制（逆估计）

利用回归方程进行逆估计，确定Y后控制X。

○ 采用射频治疗仪治疗脑肿瘤：

脑皮质毁损半径(Y)

$$=b_0+b_1\text{射频温度}(X_1)+b_2\text{照射时间}(X_2)$$

二、多元线性回归应用的注意事项

1. 指标的数量化

应变变量Y为连续变量

自变量X可为连续、有序分类或无序分类变量

(1) 连续变量：X

(2) 无序分类变量：

分2类，可用一个 $(0, 1)$ 变量。如性别 $X = \begin{cases} 0 & \text{男} \\ 1 & \text{女} \end{cases}$

分k类，化为k-1个 $(0, 1)$ 哑变量，如血型；

西、中西、中医三种疗法

$$X1 = \begin{cases} 1 & \text{西} \\ 0 & \text{其它} \end{cases}$$

$$X2 = \begin{cases} 1 & \text{中西} \\ 0 & \text{其它} \end{cases}$$

疗法	X1	X2
西	1	0
中西	0	1
中	0	0

原资料

哑变量化

姓名	性别	年龄	疗法
1	1	50	中西
2	1	20	西
3	0	18	中
4	0	70	中
5	1	35	中西
6	0	29	西

序号	性别	年龄	X1	X2
1	1	50	0	1
2	1	20	1	0
3	0	18	0	0
4	0	70	0	0
5	1	35	0	1
6	0	29	1	0

(3) 有序分类变量：等级 $\longrightarrow$ 定量

$X =$

1	轻
2	中
3	重


一般是将等级从弱到强转换为 $X = 0, 1, 2, \Lambda$ （或 $X = 1, 2, 3, \Lambda$ ）

如文化程度分为小学、中学、大学、大学以上四个等级。Y为经济收入。

$$X_1 = \begin{cases} 1 & \text{小学} \\ 2 & \text{中学} \\ 3 & \text{大学} \\ 4 & \text{大学以上} \end{cases} \longrightarrow \hat{Y} = b_0 + b_1 X_1 +$$

也可将K个等级转换为K-1个 (0, 1) 变量

哑变量	X_1	X_2	X_3
小学	0	0	0
中学	1	0	0
大学	0	1	0
大学以上	0	0	1



2. **样本含量:** n 至少是自变量个数 m 的5~10倍

3. **关于逐步回归:**对逐步回归得到的结果不要盲目信任，所谓的“最优”回归方程是相对的而不是绝对的。不同回归方程适应不同用途，依专业知识定。

4. **多重共线性:**指一些自变量之间存在较强的线性关系。如高血压与年龄、吸烟年限、饮白酒年限等，这些自变量通常是高度相关的，有可能使通过最小二乘法建立回归方程失效。

多重共线性的识别和处理

○ 多重共线性的主要形式：

- ① 整个模型的方差分析结果为 $P < \alpha$ ，但各自变量的偏回归系数的统计学检验结果却 $P > \alpha$ 。
- ② 专业上认为应该有统计学意义的自变量检验结果却无统计学意义。
- ③ 自变量的偏回归系数取值大小甚至符号明显与实际情况相违背，难以解释。
- ④ 增加或删除一个自变量或一条记录，自变量回归系数发生较大变化。

○ 多重共线性的危害：

使偏回归系数方差加大，系数估计不稳，难以有合乎专业知识的解释。

容忍度:若某变量的容忍度 ≤ 0.1 时，说明该变量与其它变量存在严重的多重共线性。

$$Tolerance = 1 - R_j^2$$

R_j 为第j个自变量与其它自变量间的相关系数

方差膨胀因子 (VIF) :为容忍度的倒数。
 $VIF \geq 10$ 时，存在严重的多重共线性

Coefficients^a

		Unstandardized Coefficients		Standardized Coefficients	t	Sig.	Collinearity Statistics	
		B	Std. Error	Beta			Tolerance	VIF
1	(Constant)	5.943	2.829		2.101	.047		
	x1	.142	.366	.078	.390	.701	.458	2.186
	x2	.351	.204	.309	1.721	.099	.562	1.780
	x3	-.271	.121	-.339	-2.229	.036	.782	1.278
	x4	.638	.243	.398	2.623	.016	.789	1.267

a. Dependent Variable: y

条件指数: 条件指数>30， 则提示存在多重共线性。

$$h_j = \sqrt{\frac{\lambda_{\max}}{\lambda_j}}$$

方差比: 如两个或多个变量的方差比均>0.5， 说明这几个自变量之间存在多重共线性


Collinearity Diagnostics

Model	Dimension	Eigenvalue	Condition Index	Variance Proportions				
				(Constant)	x1	x2	x3	x4
1	1	4.356	1.000	.00	.00	.01	.01	.00
	2	.392	3.334	.00	.00	.39	.17	.00
	3	.216	4.487	.01	.01	.22	.43	.02
	4	.023	13.636	.00	.74	.24	.03	.51
	5	.013	18.548	.99	.24	.15	.36	.47

a. Dependent Variable: y

消除共线性的方法：

- 剔除、重建回归方程
- 定义新变量或合并自变量
- 逐步回归
- 主成分回归
- 岭回归
- 路径分析
-




5. 偏相关系数

表示在一组变量中，任意两个变量在其他变量固定不变时，它们之间相关的密切程度和方向。或者说，扣除其他变量对它们的影响后，两个变量之间的线性相关情况。在做多元回归分析时可以借助变量间的偏相关分析，得到在控制不同自变量时应变量与任一自变量之间的关系。偏相关系数可以表示为 $r_{YX_j|X_1, X_2, \dots, X_{j-1}, X_{j+1}, \dots, X_p}$ ，计算可以用偏回归平方与总平方和之比得到，即

$$r_{YX_j|X_1, X_2, \dots, X_{j-1}, X_{j+1}, \dots, X_p}^2 = \frac{SS_{[Y|X_j]}}{SS_{[Y]}} \quad (15-18)$$

6. 变量间的交互作用

是否考虑交互作用主要靠专业知识；为了检验两个自变量是否具有交互作用，普遍的做法是在方程中加入它们的乘积项。




如对表 15-2 数据的分析, 已经选出甘油三酯(X_2)、胰岛素(X_3) 和糖化血红蛋白(X_4) 三个变量, 在方程中加入 X_3X_4 项, 如果这一乘积项显著, 则说明胰岛素和糖化血红蛋白之间有交互作用。为此需要定义一个新的变量 $Z = X_3X_4$, 按方程

$$\hat{Y} = b_0 + b_2X_2 + b_3X_3 + b_4X_4 + b_ZZ$$

估计参数。若经检验, 拒绝 $H_0: \beta_Z = 0$, 便可认为除 X_3 和 X_4 的主效应外还有交互作用。本例结果为

$$\hat{Y} = -0.7898 + 0.3690X_2 + 1.2267X_3 + 1.5097X_4 - 0.1785Z$$

经检验 Z 的作用显著 ($P < 0.01$), 说明糖尿病患者体内胰岛素对血糖的影响依赖于糖化血红蛋白的含量。




7. 残差分析

检查资料是否符合模型条件；

$$\mathbf{e}_i = \mathbf{Y}_i - \hat{\mathbf{Y}}_i \quad e_i \sim N(0, \sigma^2)$$


$$\mathbf{e}'_i = \frac{\mathbf{e}_i}{\sqrt{\mathbf{MS}_{\text{残}}}} \quad \text{标准化残差} \quad e'_i \sim N(0, 1^2)$$

e'



以标准化残差为纵坐标，以 $\hat{Y}_i$ 为横坐标作残差图进行分析。

回归模型应用条件的检验（残差分析）



残差分析示意图

8.异常值的识别与处理:

识别方法:

标准化残差: 当 $e_i' = \frac{e_i}{\sqrt{MS_{\text{残}}}} > 2$, 可能为异常点。

处理方法:

- 核对记录是否错误, 从而修正或删除。
- 考虑拟合其它形式的模型。
- 进行稳健估计, 如加权最小二乘法。
- 考虑增加样本含量。

谢谢大家！

