

第九章

双变量回归与相关

变量

某市1995年104名男童身高 (cm) 资料如下

117.3	119.6	121.9	125.1	117.0	115.4	124.7	120.1	123.0	122.8
120.6	121.5	125.0	125.9	123.2	126.6	122.0	127.6	125.1	120.1
119.5	126.1	126.4	125.6	118.9	130.4	124.9	125.8	126.1	120.9
116.1	124.0	124.6	118.7	119.1	121.9	118.0	117.0	114.6	123.9
116.0	125.3	123.6	123.6	126.4	115.5	119.2	114.0	123.4	126.6
117.3	113.6	127.6	120.5	113.6	130.2	128.3	118.2	124.7	122.4
118.8	123.1	122.7	126.6	127.8	125.9	<u>110.5</u>	124.8	115.2	119.4
128.0	116.7	132.4	129.3	121.7	115.0	120.4	122.1	127.0	<u>135.3</u>
125.7	111.2	124.3	124.2	124.7	121.7	121.3	124.1	119.9	121.7
113.8	116.7	129.9	128.5	126.5	122.8	120.1	118.2	122.5	127.7
124.9	123.3	120.3	125.7						



单变量资料

表1 不同饲料组大鼠肝中维生素A含量 (IU/g)

大鼠对号	正常饲料组	维生素 E 缺乏组
(1)	(2)	(3)
1	3550	2450
2	2000	2400
3	3000	1800
4	3950	3200
5	3800	3250
6	3750	2700
7	3450	2500
8	3050	1750
合计	26550	20050

变量

单
变
量
资
料


表2. SAH患者血清和脑脊液IL-6 (pg/ml) 检测结果

患者号	血清IL-6	脑脊液IL-6
1	22.4	134.0
2	51.6	167.0
3	58.1	32.3
4	25.1	80.2
5	65.9	100.0
6	79.7	139.1
7	75.3	187.2
8	32.4	97.2
9	96.4	192.3
10	85.7	199.4

变量 X

变量 Y

双变量资料



SAH患者血清和脑脊液IL-6散点图

- 医学上，许多现象之间都有相互联系，例如：身高与体重、体温与脉搏、年龄与血压、产前检查与婴儿体重、胰岛素与血糖水平、毒物剂量与动物的存活时间等。
- 在这些有关系的现象中，它们之间联系的程度和性质也各不相同。这里，体温和脉搏的关系就比产前检查与婴儿体重之间的关系密切得多，而体重和身高的关系则介于二者之间。

回归分析与相关分析

变量间关系问题：年龄~身高、肺活量~体重、
药物剂量与动物死亡率等。

两个关系：

(1) 依存关系：应变量 Y 随一个或多个自变量 X 变化而变化 —

回归分析（简单回归、多元回归；线性回归、非线性回归）

(1) 互依关系：应变量 Y 与一个或一组自变量 X 间有无关系—

相关分析（简单相关、多元相关；线性相关、非线性相关）。

第一节 直线回归(Linear Regression)

- 一、直线回归的概念
- 二、直线回归方程的建立
- 三、回归系数的假设检验
- 四、直线回归方程的图示
- 五、直线回归的区间估计
- 六、直线回归方程的应用

表1. 孕妇尿中雌三醇含量与产儿的体重

编号 (1)	尿雌三醇 mg/24h (2)	产儿体重 kg (3)	编号 (1)	尿雌三醇 mg/24h (2)	产儿体重 kg (3)
1	7	2.5	17	17	3.2
2	9	2.5	18	25	3.2
3	9	2.5	19	27	3.4
4	12	2.7	20	15	3.4
5	14	2.7	21	15	3.4
6	16	2.7	22	15	3.5
7	16	2.4	23	16	3.5
8	14	3.0	24	19	3.4
9	16	3.0	25	18	3.5
10	16	3.1	26	17	3.6
11	17	3.0	27	18	3.7
12	19	3.1	28	20	3.8
13	21	3.1	29	22	4.0
14	24	3.1	30	25	3.9
15	15	3.2	31	24	4.3
16	16	3.2			

变量x

变量y

双变量资料

两变量的散点图




图1 尿雌三醇含量与体重的散点图

回归的由来

英国统计学家Pearson K (1857~1936) 1903年搜集了1078个家庭人员的身高、前臂长等指标的记录，发现儿子身高（Y，英寸）与父亲身高（X，英寸）存在线性关系：


$$\hat{Y} = 33.73 + 0.516 X$$

回归的由来

表明：高个子父亲儿子的平均身高虽然比矮个子父亲儿子的平均身高要高一些，但稍矮于其父亲的平均身高；而矮个子父亲儿子的平均身高虽然比高个子父亲儿子的平均身高要矮一些，但稍高于其父亲的平均身高。

英国人类学家Galton F（1822~1911）将这种趋向于种族稳定的现象称之为“回归”。至此，“回归”逐渐发展成为分析两个变量或多个变量之间某种数量依存关系的一类统计方法。

Galton 数据散点图 (英寸)



一、直线回归的概念

在实际生活当中，由于其它因素的干扰，许多双变量之间的关系呈直线趋势，但并不是严格的直线关系，为了区别于两变量间的直线关系，我们称这种关系为直线回归。

直线回归仍用直线方程来描述两变量间的回归关系，但称为直线回归方程。

函数关系：确定。

例如：圆周长与半径 $y=2\pi r$

回归关系：不确定。

例如血压和年龄的关系，称为直线回归(linear regression)。

直线回归：用直线回归方程表示两个变量间数量依存关系的统计分析方法，属双变量分析的范畴。

- 直线回归方程:

$$\hat{Y} = a + bX$$

X: 自变量, 一般为资料中能精确测定和控制的量。

$\hat{Y}$: 因变量Y的估计值

a: 截距

b: 回归系数

直线回归方程: $\hat{Y} = a + bX$

a : 截距(intercept), 直线与Y轴交点的纵坐标($X=0$)。

b : 斜率(slope), 回归系数(regression coefficient)。

意义: X 每改变一个单位, Y 平均改变 b 个单位 (估计值)



$b > 0$, Y 随 X 的增大而增大 (减少而减少) —— 斜上;

$b < 0$, Y 随 X 的增大而减小 (减少而增加) —— 斜下;


$b = 0$, Y 与 X 无直线关系 —— 水平。

$|b|$ 越大, 表示 Y 随 X 变化越快, 直线越陡峭。

一般表达式: $\hat{Y} = a + bX$



$$\hat{y} = a + bx$$



Simple Linear Regression Model

根据散点图可以假定，对于 x 各个取值，相应的 Y 的总体均数 $\mu_{y.x}$ ，在一条直线上， $\hat{y}$ 实际上是 x 对应的 Y 的总体均数 $\mu_{y.x}$ 的一个样本估计值。


The diagram illustrates the Simple Linear Regression Model equation: $\mu_{Y|X} = \alpha + \beta X$. The components are labeled as follows:

- Y的总均数** (Total mean of Y) points to $\mu_{Y|X}$.
- 自变量** (Independent variable) points to X .
- Intercept总体截距** (Intercept total intercept) points to α .
- Slope总体斜率** (Slope total slope) points to β .

$$\mu_{Y|X} = \alpha + \beta X$$

y

x



直线回归模型的四个假定

- 线性——LINEARITY

反应变量均数 μ 与X间呈直线关系


$$\mu_{Y \cdot X} = \alpha + \beta X$$

- 独立——INDEPENDENCE

每一观察值之间彼此独立

- 正态 ——NORMALITY

对于任何给定的X对应Y的总体服从正态分布，均数为 $\mu_{Y|X}$ ，标准差为 $\sigma_{Y|X}$



- 标准差相等——EQUAL STANDARD DEVIATION

对于任何X值，随机变量Y的标准差 $\sigma_{Y|X}$ 相等

二、直线回归方程的求法

回归系数与截距的计算:

应用数学上的最小二乘法原理

➤求解a,b实际就是如何合理找到一条能最好代表数据点分布趋势的直线。

根据数学上的最小二乘法原理：各实测点与该点的估计值最接近，即 $y - \hat{y}$ （剩余值或残差）纵向垂直距离最短。

保证各实测值Y至直线的纵向距离 $\hat{y}$ 的平方和最小，即使 $\sum (Y - \hat{Y})^2$ 最小，此回归直线必过 $(\bar{X}, \bar{Y})$ 这一点。

回归方程参数的计算

$$b = \frac{\Sigma(X - \bar{X})(Y - \bar{Y})}{\Sigma(X - \bar{X})^2} = \frac{\Sigma XY - (\Sigma X)(\Sigma Y)/n}{\Sigma X^2 - (\Sigma X)^2/n} = \frac{l_{XY}}{l_{XX}}$$

$$a = \bar{Y} - b\bar{X}$$

直线回归方程的求法:

1. 绘制散点图
2. 求回归系数 b 和截距 a
3. 列出回归方程

例1:为探讨某地饮水中氟含量与氟骨症的关系，
试对测量得到的下列8对数据进行直线回归分析。

编 号	1	2	3	4	5	6	7	8
氟含量 (mg/L) X	0.48	0.64	1.00	1.47	1.60	2.86	3.21	4.71
患病率 (%) Y	22.37	23.31	25.32	22.29	28.57	35.00	46.07	46.08

两相关变量的散点图




图1 某地区饮水氟含量与氟骨症患病率散点图

回归参数的计算:

编号	氟含量 X	患病率 Y	X^2	Y^2	XY
1	0.48	22.37	0.2304	500.4169	10.7376
2	0.64	23.31	0.4096	543.3561	14.9184
3	1.00	25.32	1.0000	641.1024	25.3200
4	1.47	22.29	2.1609	496.8441	32.7663
5	1.60	28.57	2.5600	816.2449	45.7120
6	2.86	35.00	8.1796	1225.0000	100.1000
7	3.21	46.07	10.3041	2122.4450	147.8847
8	4.71	46.08	22.1841	2123.3660	217.0368
合计	ΣX 15.97	ΣY 249.01	ΣX^2 47.0287	ΣY^2 8468.7754	ΣXY 594.4758

$$b = \frac{l_{XY}}{l_{XX}} = \frac{\Sigma XY - (\Sigma X)(\Sigma Y)/n}{\Sigma X^2 - (\Sigma X)^2/n}$$
$$= \frac{97.39}{15.15} = 6.43$$

$$\bar{X} = \Sigma X / n = 15.97 / 8 = 2$$

$$\bar{Y} = \Sigma Y / n = 249.01 / 8 = 31.13$$

$$a = \bar{Y} - b\bar{X} = 18.27$$

列出回归方程: $\hat{Y} = 18.27 + 6.43X$

例2： 在脑血管疾病的诊断治疗中，脑脊液白细胞介素-6（IL-6）水平是影响诊断与预后分析的一项重要指标，但脑脊液在临床上有时又不容易采集到。某医生欲了解急性脑血管病病人血清IL-6 (pg/ml) 与脑脊液IL-6 (pg/ml) 水平，随机抽取了某医院确诊的10例蛛网膜下腔出血（SAH）患者24小时内血清IL-6和脑脊液IL-6数据如表2，问SAH患者血清IL-6和脑脊液IL-6间是否有直线回归关系存在？

进行回归分析

表2. SAH患者血清和脑脊液IL-6 (pg/ml) 检测结果

患者号	血清IL-6	脑脊液IL-6
1	22.4	134.0
2	51.6	167.0
3	58.1	132.3
4	25.1	80.2
5	65.9	100.0
6	79.7	139.1
7	75.3	187.2
8	32.4	97.2
9	96.4	192.3
10	85.7	199.4

1. 绘制散点图（略）：
2. 求回归系数 b 和截距 a ：
计算：

$$\bar{X}、\bar{Y}、L_{XX}、L_{YY}、L_{XY}$$

$$\bar{X}=59.26$$

$$\bar{Y}=142.87$$

$$L_{XX}=6104.664$$

$$L_{YY}=16242.101$$

$$L_{XY}=7201.698$$

$$b = \frac{l_{XY}}{l_{XX}} = 1.1797$$

$$a = \bar{Y} - b\bar{X} = 72.9610$$

3. 列出回归方程:

$$\hat{Y} = 72.96 + 1.18X$$

回归方程中a、b的解释

- 1. 斜率 (b)

- 当X每增加1个单位时，Y改变 b 个单位

- 本例 $b=1.1797$ ，表明在所研究对象范围内，血清IL-6每增加1pg/ml，脑脊液IL-6增加1.1797pg/ml

- 2. Y的截距 (a)

- $x=0$ 时Y的平均值

- 本例 $a=72.96$ ，表示血清IL-6为0时，脑脊液IL-6期望值为72.96pg/ml

- （注意有时这种解释无实际意义）

三、回归系数的假设检验

$b \neq 0$ 原因:

- ①总体回归系数 $\beta = 0$ ，由于抽样误差引起
- ②总体回归系数 $\beta \neq 0$ ，存在回归关系

▶ 方差分析法

▶ t检验法


回归系数的假设检验：方差分析法

方差分析的基本思想：

把总的离均差平方和(即总变异)分解为至少两个部分，其中有一部分主要表示某因素的效应，有一部分表示抽样误差的影响，然后比较两者的均方，计算F值，若F值远大于1，可认为该因素有效应，否则认为该因素无效应。

$$Y\text{的总变异: } SS_{\text{总}} = SS_{\text{回}} + SS_{\text{剩}}$$

应变变量Y的离均差平方和的分解



应变变量 Y 的离均差平方和的分解

$$Y - \bar{Y} = (\hat{Y} - \bar{Y}) + (Y - \hat{Y})$$

$$\sum (Y - \bar{Y})^2 = \sum [(\hat{Y} - \bar{Y}) + (Y - \hat{Y})]^2$$

$$\sum (Y - \bar{Y})^2 = \sum (\hat{Y} - \bar{Y})^2 + \sum (Y - \hat{Y})^2$$

$$SS_{\text{总}} = SS_{\text{回}} + SS_{\text{剩}}$$

几个平方和的意义

1. **SS_总** 即 $\sum(Y - \bar{Y})^2$ ，为Y的总离均差平方和，表示未考虑x与y的回归关系时，Y的总变异。


2. **SS_回** 即 $\sum(\hat{Y} - \bar{Y})^2$ ，为回归平方和(regression sum of squares) 由于x与y的直线关系而使Y变异减小的部分,即总变异中，可以用x解释的部分。SS_回越大，回归效果越好。

3. **SS_剩** 即 $\sum(Y - \hat{Y})^2$ ，为剩余平方和(residual sum of squares) x对y的线性影响之外的一切因素对Y的变异，即总变异中，无法用x解释的部分。SS_剩越小，回归效果越好。

- 方差分析

- ❖ 变异分解

$SS_{\text{总}}$: 因变量 Y 的总变异



回归系数的方差分析表

变异来源	SS	v	MS	F	P
总变异	$l_{YY} = \sum (Y - \bar{Y})^2$	n-1			
回归	$bl_{XY} = l_{XY}^2 = b^2 l_{XX}$	1	$\frac{SS_{回}}{v_{回}}$	$\frac{MS_{回}}{MS_{残}}$	
残差	$SS_{总} - SS_{回}$	n-2	$\frac{SS_{残}}{v_{残}}$		

回归系数的方差分析

$$SS_{\text{总}} = SS_{\text{回}} + SS_{\text{剩}}$$

$$v_{\text{总}} = n - 1 \quad v_{\text{回}} = 1 \quad v_{\text{剩}} = n - 2$$

$$SS_{\text{总}} = l_{YY}$$

$$SS_{\text{回}} = b l_{XY} = l_{XY}^2 / l_{XX}$$

$$SS_{\text{剩}} = SS_{\text{总}} - SS_{\text{回}} = l_{YY} - l_{XY}^2 / l_{XX}$$

$$F = \frac{SS_{\text{回}} / v_{\text{回}}}{SS_{\text{剩}} / v_{\text{剩}}} = \frac{MS_{\text{回}}}{MS_{\text{剩}}}$$

例：用方差分析法对例1数据求得的回归系数进行假设检验 $b=6.43$

★回归系数方差分析的基本步骤：

$H_0: \beta = 0$ (饮水中氟含量与氟骨症之间没有直线关系)

$H_1: \beta \neq 0$ (饮水中氟含量与氟骨症之间有直线关系)

$\alpha = 0.05$

★计算统计量： $SS_{\text{总}} = l_{YY} = 718.03$

$$SS_{\text{回}} = b l_{XY} = l_{XY}^2 / l_{XX} = 626.06$$

$$SS_{\text{剩}} = SS_{\text{总}} - SS_{\text{回}} = l_{YY} - l_{XY}^2 / l_{XX} = 91.97$$

$$F = \frac{SS_{\text{回}} / \nu_{\text{回}}}{SS_{\text{剩}} / \nu_{\text{剩}}} = \frac{MS_{\text{回}}}{MS_{\text{剩}}} = 40.84$$

表1 回归系数方差分析表

变异来源	SS	DF	MS	F	P
回归	626.06	1	626.06	40.84	$P<0.01$
剩余	91.97	6	15.33		
总变异	718.03	7			

★确定P值： $\nu_{\text{回}}=1$ $\nu_{\text{剩}}=6$, 查F界值表得 $P<0.01$

★下结论：按 $\alpha=0.05$ 的检验水准，拒绝 H_0 ，接受 H_1 ，可认为饮水中氟含量与氟骨症之间有直线关系。

回归系数的假设检验：t检验法

$$t_b = \frac{b-0}{S_b} \quad \nu = n - 2$$

$$S_b = \frac{S_{Y.X}}{\sqrt{l_{XX}}} \quad S_{Y.X} = \sqrt{\frac{\sum (Y - \hat{Y})^2}{n-2}} = \sqrt{\frac{SS_{\text{剩}}}{n-2}}$$

$S_{Y.X}$ ：表示去除X影响后Y的变异程度，即
剩余标准差。

剩余（残差）标准差 $S_{Y.X}$

$$S_{y.x} = \sqrt{\frac{\sum (Y - \hat{Y})^2}{n-2}} = \sqrt{\frac{\sum (\text{残差})^2}{n-2}} = \sqrt{\frac{SS_{\text{剩}}}{n-2}} = \sqrt{MS_{\text{剩}}} = \hat{\sigma}_{y.x}$$

度量了实际散点远离回归直线的离散程度，反映了模型的可靠性，**越小模型越好**。

t_b 检验，区间的计算均需要使用这一值。

例：用t检验法对饮水中氟含量与氟骨症之间的 直线回归系数进行假设检验

$$H_0: \beta = 0$$

$$H_1: \beta \neq 0$$

$$\alpha = 0.05$$

$$n=8 \quad SS_{\text{剩}} = 91.97 \quad l_{xx} = 15.15,$$

$$b = 6.43$$

$$S_{Y \cdot X} = \dots = 3.92$$

$$S_b = \dots = 1.01$$

$$t = \dots = 6.37$$

按 $\nu=6$ ，查 t 界值表得 $P<0.001$ ，按 $\alpha=0.05$ 的

检验水准，拒绝 H_0 ，接受 H_1 ，可认为饮水中

氟含量与氟骨症之间有直线关系。

注意：对回归系数的假设检验可用方差分析和 t 检验，两种检验是完全等价的，即两者的关系：

$$t = \sqrt{F}$$

四、直线回归方程的图示

在自变量X的实测范围内任取相距较远且易读数的两X值代入回归方程求得两点坐标、连线即得其回归直线。

注意：1. 回归直线不应超出x的实测值范围。

2. 所绘回归直线必然通过 $(\bar{X}, \bar{Y})$ 。

3. 将直线的左端延长与纵轴交点纵坐标必等于截距a, 据此可判断所绘图形是否正确。

$X: 0.48 \sim 4.71$

$X_1 (0.48, 21.38)$ 、 $X_2 (4.71, 48.57)$
 $(\bar{X}, \bar{Y})$ 、 $(0, a)$




图12-1 某地区饮水氟含量与氟骨症患病率散点图

五、直线回归的区间估计

- (一) 总体回归系数 β 的估计
- (二) 应变变量条件均数 $\mu_{\hat{y}}$ 的区间估计
- (三) 个体Y值的容许区间

(一) 总体回归系数 β 的区间估计

β 的100 (1- α) %的可信区间为:

$$(b - t_{\alpha/2, v} s_b, b + t_{\alpha/2, v} s_b)$$

$$\text{或 } b \pm t_{\alpha/2, v} s_b$$

$$v = n - 2 \quad S_b = \frac{S_{YX}}{\sqrt{l_{XX}}}$$

$$b \pm t_{\alpha/2, v} s_b$$

$$s_b = \frac{s_{y \cdot x}}{\sqrt{l_{xx}}} \longrightarrow \text{样本回归系数的标准误}$$

$$s_{y \cdot x} = \sqrt{\frac{\sum (y - \hat{y})^2}{n - 2}} \longrightarrow \text{剩余标准差}$$

$$\sum (y - \hat{y})^2 = l_{yy} - \frac{l_{xy}^2}{l_{xx}}$$

$s_{y \cdot x}$ 为 Y 的剩余标准差——扣除 X 的影响后 Y 的变异程度。

例：（续前例）试求总体回归系数 β 的95%可信区间

$$\hat{Y}=18.29+6.43X$$

$$b=6.43, \quad v=8-2=6,$$

$$t_{0.05/2, 6}=2.447, \quad S_b=1.01$$

β 的95%可信区间为：

$$\begin{aligned} & (6.43-2.447 \times 1.01, \quad 6.43+2.447 \times 1.01) \\ & = (3.96, \quad 8.90) \end{aligned}$$

(二) 应变变量条件均数 $\mu_{\hat{y}}$ 的区间估计

$\mu_{\hat{y}}$: 是总体中 x 取某定值 x_0 时 $\hat{y}$ 的条件均数。

指 x_0 一定时, 代入回归方程求得的点估计值, 为 $\hat{y} = a + bX$, $\hat{y}_{x_0}$ 为 $x = x_0$ 时

的条件均数, 它遵从总体均数为 $\mu_{\hat{y}} = \alpha + \beta x$ 和标准差 $\sigma_{\hat{y}} = \sigma \sqrt{\frac{1}{n} + \frac{(x - \bar{x})^2}{\sum (x - \bar{x})^2}}$ 的正


态分布, 当 σ 未知时, 以 $S_{y.x}$ 代替, 随机变量 $\hat{y}_{x_0}$ 服从 $v = n - 2$ 的 t 分布。

当 $x = x_0$ 时, 总体均数 $\mu_{\hat{y}}$ 的 $1 - \alpha$ 的可信区间为 $\hat{y}_0 \pm t_{\alpha/2, (n-2)} S_{\hat{y}_0}$

其中, 标准误估计值 $S_{\hat{y}_0} = S_{YX} \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum (X - \bar{X})^2}}$

y

x



例：（续前例）试计算当 $x_0=1.00$ 时 $\mu_{\hat{y}}$ 的95%可信区间

$$\hat{Y} = 18.29 + 6.43X$$

$$x_0=1.00 \text{ 时, } \hat{Y}_0=24.72 \quad S_{Y.X}=3.92 \quad l_{xx}=15.15, \quad \bar{X}=2.00$$

$$S_{\hat{Y}_0} = 3.92 \sqrt{\frac{1}{8} + \frac{(1.00 - 2.00)^2}{15.15}} = 1.71$$

$$v=8-2=6, \quad t_{0.05/2, 6} = 2.447$$

$\mu_{\hat{y}}$ 的95%可信区间:

$$(24.72 \pm 2.447 \times 1.71) = (20.54, 28.90)$$

(三) 个体Y值的容许区间

总体中， x 为某定值 X_0 时， Y 值由于随机误差影响在 $\hat{Y}_0$ 上下波动的范围。

$(\hat{Y} - t_{\alpha/2(n-2)} S_{Y_0}, \hat{Y} + t_{\alpha/2(n-2)} S_{Y_0})$ 缩写为 $\hat{Y} \pm t_{\alpha/2(n-2)} S_{Y_0}$

$$S_{Y_0} = S_{Y.X} \sqrt{1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum (X - \bar{X})^2}} = S_{Y.X} \sqrt{1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{l_{XX}}}$$

S_{Y_0} 是 x 取定值时，个体 Y 值的标准差。

例：（续前例）试计算当 $x_0=1.00$ 时个体 Y 值的95%容许区间

$$S_{y_0} = 3.92 \sqrt{1 + \frac{1}{8} + \frac{(1.00 - 2.00)^2}{15.15}} = 4.28$$

$$v=8-2=6, \quad t_{0.05/2, 6} = 2.447$$

个体 Y 值的95%容许区间：

$$(24.72 \pm 2.447 \times 4.28) = (14.25, 35.19)$$

S_{YX} : 剩余标准差

$S_{\hat{Y}_0}$: 样本条件均数的标准误

S_{Y_0} : x 取某定值 x_0 时应变量 y 的标准差

当 $X=X_0$ 时，相应 Y 的均数的95%可信区间

表示在固定的 X_0 处，反复抽样100次，可算得100个相应 Y 的总体均数的可信区间，平均有95个可信区间包含总体均数。

当 $X=X_0$ 时，其个体 Y 值的95%预测区间

表示一个预测值的取值范围，即平均有95%个个体值在此范围内。

六、直线回归方程的应用

- 1、定量描述两变量之间的依存关系
- 2、利用回归方程进行预测预报（给定X值，估计Y）

用容易测量的指标估计不容易测量的指标：

估计值的置信区间： $\hat{y} \pm t_{\alpha/2, (n-2)} s_{\hat{y}}$

个体值的预测区间： $\hat{y} \pm t_{\alpha/2, (n-2)} s_y$

- 3、利用回归方程进行统计控制（给定Y值范围，求X值范围）

直线回归应用的注意事项

- (1) 因变量Y应是来自正态分布总体的随机变量;
- (2) 回归分析前应先绘制散点图;
- (3) 做回归分析要有实际意义;
- (4) 两变量间有直线关系时不一定是因果关系;
- (5) 应对回归系数 β 进行假设检验;
- (6) 回归直线不宜外延;
- (7) 要注意离群值对回归效果的影响。

第二节 直线相关

(linear correlation)

- 一、直线相关的概念
- 二、相关系数的意义与计算
- 三、相关系数的假设检验
- 四、相关系数的可信区间
- 五、直线相关应用的注意事项

例：为研究中年女性体重指数和收缩压之间的关系，随机测量了16名40岁以上女性的体重指数和收缩压，见表1。

表1. 16名中年女性的体重指数(kg/m²)和收缩压(kPa)

编号	体重指数	收缩压	X ²	Y ²	XY
(1)	(2)	(3)	(4)	(5)	(6)
1	2.86	18.00	8.1796	324.0000	51.4800
2	3.41	18.93	11.6281	358.3449	64.5513
3	3.62	20.00	13.1044	400.0000	72.4000
4	3.20	17.60	10.2400	309.7600	56.3200
...	...	...	...	...	...
15	3.33	19.87	11.0889	394.8169	66.1671
16	3.76	21.07	14.1376	443.9449	79.2232
合计	56.50	314.68	202.1506	6240.7690	1121.8578




图1. 16名中年女性体重指数和收缩压的散点图



一、直线相关的概念

直线相关分析:

描述两变量间是否有直线关系以及直线关系的
方向和密切程度的分析方法。

条件:


两变量 (x, y) 都是来自正态分布的随机变量。

二、相关系数的意义与计算


直线相关系数：又称积差相关系数，或Pearson 相关系数，是说明具有直线关系的两个变量间，相关关系的密切程度与相关方向的指标。

r --- 样本相关系数

ρ --- 总体相关系数



正相关
 $0 < r < 1$




负相关
 $-1 < r < 0$

散点呈椭圆形分布，
X、Y 同时增减——正相关
(positive correlation)
X、Y 此增彼减——负相关
(negative correlation)




完全正相关
 $r = 1$




完全负相关
 $r = -1$

散点在一条直线上，
x、Y 变化趋势相同——完全正相关；反向变化——完全负相关。

直线相关示意图



零相关 $r = 0$



非线性相关 $r = 0$

X、Y变化互不影响或无
直线相关关系----零相
关 (zero correlation)



零相关 $r = 0$



零相关 $r = 0$

直线相关示意图

$$r = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2} \sqrt{\sum (y - \bar{y})^2}} = \frac{l_{xy}}{\sqrt{l_{xx} l_{yy}}}$$

$$l_{xy} = \sum (x - \bar{x})(y - \bar{y}) = \sum xy - \frac{\sum x \sum y}{n}$$

范围、大小、符号：

r无单位， $-1 \leq r \leq 1$ 。

r 值为正——正相关；

为负——负相关；

$|r|=1$ ——完全相关；

$|r|=0$ ——零相关。

例：计算表1中体重指数和收缩压的相关系数

(1) 绘制散点图： 

(2) 计算：

$$l_{xx}=2.6350$$

$$l_{yy}=51.8001$$

$$l_{xy}=10.6441$$

$$r = \dots = 0.9110$$

三、相关系数的假设检验

$r \neq 0$ 原因：①由于抽样误差引起， $\rho = 0$
②存在相关关系， $\rho \neq 0$

1、t检验法

2、查表法

相关系数的假设检验

1. t 检验法

$$t = \frac{r - 0}{S_r} = \frac{r}{\sqrt{\frac{1 - r^2}{n - 2}}}$$

S_r —相关系数的标准误

$$v = n - 2$$

例. 根据体重指数和收缩压间样本相关系数 $r=0.91$,
对总体相关系数 $\rho=0$ 进行假设检验

(1) 建立假设, 确定检验水准

H_0 : $\rho=0$ 即变量间不存在直线相关关系。

H_1 : $\rho \neq 0$ 即变量间存在直线相关关系。

$\alpha=0.05$

(2) 计算检验统计量

$r=0.91$, $n=16$, 代入公式 计算得

$$t=\dots=8.2653$$

(3) 查t界值表, 确定P值, 下结论

根据 $\nu=16-2=14$ 查t界值表得 $P < 0.01$, 按 $\alpha=0.05$ 的检验水准, 拒绝 H_0 , 接受 H_1 , 可认为体重指数和收缩压之间存在正相关关系。

注: 对于同一资料, $t_b=t_r$, 检验完全等价。

2. 查表法

根据 r 值及 $v=n-2$ 查附表14相关系数 r 界值表确定 P 值。

$r=0.91$ ， $v=14$ 查 r 界值表得 $r_{0.01/2, 14}=0.623$ ，
所以 $P<0.01$ ，按 $\alpha=0.05$ 的检验水准，拒绝 H_0 ，
接受 H_1 ，可认为体重指数和收缩压之间存在正相关关系。

四、总体相关系数的可信区间

r : 呈非正态分布, 作正态变换。

- 先对 r 作 z 变换

$$z = \tanh^{-1} r \quad \text{或} \quad z = \frac{1}{2} \ln \frac{(1+r)}{(1-r)}$$

- 按正态近似原理, z 的 $1-\alpha$ 可信区间为:

$$(z - u_{\alpha} / \sqrt{n-3}, z + u_{\alpha} / \sqrt{n-3})$$

- 将 z 反变换为 r

$$r = \tanh z \quad \text{或} \quad r = \frac{e^{2z} - 1}{e^{2z} + 1}$$

公式中 $\tanh$ 为双曲正切函数; $\tanh^{-1}$ 为反双曲正切函数。

例. 根据体重指数和收缩压间样本相关系数 $r=0.91$,
求总体相关系数 ρ 的95%可信区间。

$$r=0.91$$

$$Z \pm u_{\alpha/2} / \sqrt{n-3}$$

$$Z = \frac{1}{2} \ln \frac{1+r}{1-r} = 1.5334$$

$$= 1.5334 \pm 1.96 / \sqrt{16-3}$$

$$= 0.9898 \quad 2.0770$$

$$r = \tanh Z = \frac{e^{2Z} - 1}{e^{2Z} + 1}$$

$$\tanh 0.9898 \sim \tanh 2.0770 = 0.76 \sim 0.97$$

总体相关系数 ρ 的95%CI: (0.76, 0.97)

五、直线相关应用的注意事项

1. 相关分析一定要有实际意义。
2. 相关关系不一定是因果关系。
3. 必须对样本相关系数 r 进行假设检验。
4. 同一个观察指标的两次重复测量结果间的相关系数表示测量结果的可靠性。
5. 进行相关分析前要先绘制散点图。

小结

直线回归与相关应用的注意事项

- (1) 根据分析目的选择变量及统计方法;
- (2) 进行相关、回归分析前应绘制散点图;
- (3) 用残差图考察数据是否符合模型假设条件;
- (4) 结果的解释及正确应用。

直线相关与直线回归的区别与联系

联系： 1. r 与 b 正负号一致： r 为正时， b 也为正，表示两变量是正相关，是同向变化。 r 为负时， b 也为负，表示两变量是负相关，是反向变化。

2. r 与 b 的假设检验等价：对同一组资料若同时进行 r 与 b 的假设检验，可得到相同的 t 值，即 $t_r = t_b$ ，可用 r 的假设检验代替 b 的假设检验。

$$3. r = bs_x / s_y = b \sqrt{l_{XX} / l_{YY}}$$

4. 可用回归解释相关：**决定系数**：即相关系数的平方 r^2 。

$r^2 = SS_{\text{回}} / SS_{\text{总}}$ ，是回归平方和与总的离均差平方和之比，反映应变量 y 的总变异中可用回归关系解释的部分。越接近于1，表明利用回归方程进行预测越有意义。

$$r^2 = \frac{l_{XY}^2}{l_{XX} l_{YY}} = \frac{l_{XY}^2 / l_{XX}}{l_{YY}} = \frac{SS_{\text{回}}}{SS_{\text{总}}} = \frac{SS_{\text{总}} - SS_{\text{剩}}}{SS_{\text{总}}}$$

决定系数

$$R^2 = \frac{SS_{\text{回}}}{SS_{\text{总}}} = \frac{l_{XY}^2}{l_{XX} l_{YY}}$$

- $SS_{\text{总}}$ 不变, $SS_{\text{回}}$ 大小决定了相关系数 r 绝对值大小, $SS_{\text{回}}$ 越接近 $SS_{\text{总}}$, r 绝对值越接近 1, 说明相关的实际效果越好。
- 对直线回归的拟合优度检验等价于对总体回归系数的假设检验, 其

$$F = \frac{R^2}{(1-R^2) / (n-2)} = \frac{SS_{\text{回}}}{SS_{\text{残}} / \nu_{\text{残}}} = \frac{MS_{\text{回}}}{MS_{\text{残}}}, \quad \nu_1 = 1, \quad \nu_2 = n - 2$$

$$\sqrt{F} = t_b = t_r$$

区别： 1. 资料要求不同：直线回归要求应变量Y服从正态分布，X可以是精确测量和严格控制的变量，一般称为 I 型回归；直线相关要求两个变量X、Y服从双变量正态分布，这种资料若要进行回归分析称为 II 型回归。

2. 应用情况不同：直线回归说明两变量间依存变化的数量关系，直线相关则是说明两变量的相关关系；

3. r与b有区别：

(1) 意义不同：r说明具有直线关系的两个变量间关系的密切程度与相关方向；b表示X每改变一个单位，Y平均改变b个单位；

(2) 计算不同：

$$r = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2} \sqrt{\sum (Y - \bar{Y})^2}} = \frac{l_{XY}}{\sqrt{l_{XX}} \sqrt{l_{YY}}} \quad b = \frac{l_{xy}}{l_{xx}}$$

(3) 取值范围不同： $-1 \leq r \leq 1$, $-\infty \leq b \leq +\infty$

(4) 单位：r没有单位，b有单位。

对于两组新数据（两个变量）可先做散点图，求出它们的相关系数，对于确有相关关系的变量再进行回归分析，求出回归方程。能进行回归分析的变量之间存在相关关系。

第三节 秩相关

等级相关又称为秩相关，是一种非参数统计方法，适用条件：

1. 资料不服从双变量正态分布
2. 总体分布类型未知
3. 数据一端或两端有不确定值的资料
4. 等级资料

常用的有：Spearman等级相关

- Spearman等级相关

$$r_s = 1 - \frac{6 \sum d^2}{n(n^2 - 1)}$$

- r_s 为等级相关系数：说明2个变量间相关关系的密切程度与相关方向。
- 总体相关系数 ρ_s

表2 肝癌死亡率与黄曲霉毒素相对含量

乡编号	黄曲霉毒素相对含量	肝癌死亡率 (1/10万)
	X	Y
1	0.7	21.5
2	1.0	18.9
3	1.7	14.4
4	3.7	46.5
5	4.0	27.3
6	5.1	64.6
7	5.5	46.3
8	5.7	34.2
9	5.9	77.6
10	10.0	55.1

表2 肝癌死亡率与黄曲霉毒素相对含量

乡编号	黄曲霉毒素 相对含量		肝癌死亡率 (1/10万)		d	d ²
	X	秩次	Y	秩次	(6)=	
(1)	(2)	(3)	(4)	(5)	(3)-(5)	(7)
1	0.7	1	21.5	3	-2	4
2	1.0	2	18.9	2	0	0
3	1.7	3	14.4	1	2	4
4	3.7	4	46.5	7	-3	9
5	4.0	5	27.3	4	1	1
6	5.1	6	64.6	9	-3	9
7	5.5	7	46.3	6	1	1
8	5.7	8	34.2	5	3	9
9	5.9	9	77.6	10	-1	1
10	10.0	10	55.1	8	2	4
合计						42

$$r_s = 1 - \frac{6 \sum d^2}{n(n^2 - 1)} = 1 - \frac{6 \times 42}{10 \times (10^2 - 1)} = 0.746$$

(1) $n \leq 50$, 查表法: P_{721} 附表14 r_s 界值表

本例: $n=10$, $r_{s \ 0.05/2, 10}=0.648$ $r_{s \ 0.02/2, 10}=0.745$

$P < 0.02 \dots$

(2) $n > 50$, u 检验

$$u = r_s \sqrt{n-1}$$

- 当X, Y对应的相同秩次较多时, 宜用校正值 r_s'

$$r_s = \frac{(n^3 - n)/6 - (T_X + T_Y) - \sum d^2}{\sqrt{(n^3 - n)/6 - 2T_X} \sqrt{(n^3 - n)/6 - 2T_Y}}$$

$$T_X / T_Y = \sum (t^3 - t) / 12$$

第四节 加权直线回归

第五节 两条回归直线的比较

(自学)

第六节 曲线拟合（自学）

一、曲线拟合的一般步骤

1. 依据分析目的确定X与Y，根据两变量散点图、结合专业知识选择曲线类型。
2. 求回归方程：曲线直线化。
3. 拟合优度： R^2

标准 CRF(X)刺激大鼠垂体前叶细胞分泌 ACTH(Y)测定结果

编 号	X	Y
1	0.005	34.11
2	0.050	57.99
3	0.500	94.49
4	5.000	128.50
5	25.000	169.98
合 计	—	485.07

CRF:促肾上腺皮质激素释放因子

ACTH:肾上腺皮质激素




图1 数据散点图

标准 CRF(X)刺激大鼠垂体前叶细胞分泌 ACTH(Y)测定结果

编 号	X	$X'=\lg X$	Y
1	0.005	-2.30	34.11
2	0.050	-1.30	57.99
3	0.500	-0.30	94.49
4	5.000	0.70	128.50
5	25.000	1.40	169.98
合 计	—	-1.80	485.07




图2 对X作对数变换后的散点图

15名重伤病人的住院天数 X (天)与预后指数 Y

编 号	1	2	3	4	5	6	7
住院天数 X	2	5	7	10	14	19	26
预后指数 Y	54	50	45	37	35	25	20

编 号	8	9	10	11	12	13	14	15
住院天数 X	31	34	38	45	52	53	60	65
预后指数 Y	16	18	13	8	11	8	4	6




图3 数据散点图




图4 对Y作数据变换后的散点图

二、曲线拟合的用途

1. 定量刻画X与Y的关系。
2. 用相关指数 $\sqrt{R^2}$ 反应两变量曲线关系的密切程度。

三、常见的几种曲线拟合




图 9- 15 a

$$Y = e^{(a+bX)}$$




图 9- 15 b

$$y = b_0 + b_1 x + b_2 x^2$$






图 9- 15 c


$$y = b_0 + b_1 x + b_2 x^2 + b_3 x^3$$





Logistic 曲线

图 9- 15 d



$$Y = k / [1 + a \cdot \exp (bX)] + l$$

$$\ln \frac{k - (Y - l)}{Y - l} = \ln a + bX$$

Hande Hall