

第十七章 生存分析 (Survival Analysis)

本章内容

第一节 生存分析中的基本概念

第二节 生存分析的统计方法

第三节 生存率的估计与生存曲线

第四节 生存率的比较

第五节 Cox比例风险回归模型

第六节 寿命表(不讲)

***要求掌握概念、方法、用途。**

概述

- 临床上疗效、预后的评价常用疾病的结局指标：如有效率、治愈率、死亡率比较。
- 对于短期内能明确治疗效果的疾病是适用的。
- 对于远期疗效，上述指标的评价不全面。

例1:

两种方法对疾病的疗效

方法	治疗人数	生存人数	生存率%
甲方法	100	20	20
乙方法	100	50	50

经 χ^2 检验: $p < 0.05$, 乙法预后优于甲法。

假定:

- 1.观察期间疾病的死亡率不随时间变化。
- 2.研究对象观察时间长度相等。

例2:

某病的疗效比较

	治愈率(%)	平均治愈时间(月)
甲药	80	20
乙药	81	12

疗效除了应评价“结局”的好坏，结局所经历时间长短也是评价疗效的重要指标。

随访观察某事件出现“某结局”和“结局出现的时间”的资料统称为**随访资料**。

时间 结局

两种药物的疗效比较：

	治愈率	所需时间
A药	90%	20天
B药	90%	12天

随访数据的类型:

- 有的研究对象能够观察到结局出现，得到准确的生存时间——完全数据；
- 有的研究对象中途失访、退出、死于其它疾病或研究结束时还未出现规定的结局等等——不完全数据。

生存分析资料的特点：

1. **时间**和生存**结局**都是要关心的因素

2. **存在大量失访**

失去联系（病人搬走，电话号码改变）

无法观察到结局（死于其他原因）

研究截止

3. 生存时间的分布**一般不服从正态分布**

常为正偏态分布

生存分析：是将事件发生的结果和随访时间两个因素结合起来、可以对**完全和不完全数据**进行分析的统计分析方法，它能充分利用所得到的研究信息，更加准确的评价和比较**随访资料**。

随访研究(follow-up study)是医学中常用前瞻性研究。该类数据通过随访得到，称为**随访资料**。

第一节 生存分析中的基本概念

一、生存时间(*survive time*): 是任何两个有联系的事件之间的时间间隔, 常用符号 t 表示。


狭义: 患某种疾病的病人从发病到死亡所经历的时间跨度。

广义: 从某种起始事件到终点事件所经历的时间跨度。

起始事件与终点事件

- **起始事件** (initial event) : 是反映研究对象生存过程的**起始特征**的事件。
- **终点事件** (terminal event) : 指反映治疗效果特征的事件, 研究者所关心的**特定结局**, 又称**死亡事件**、**失效事件**。

起始事件和终点事件 (*initial and failure event*)



应明确规定起始事件、失效事件以及时间的测度单位。

二、删失 (censoring)

生存结局：“死亡”、“删失”

发生删失的主要原因：

- (1) 因迁移原因失去联系；
- (2) 死于其他原因而造成失访；
- (3) 因客观原因中途退出；
- (4) 预定终止结果迟迟不发生。

删失数据提供了其生存期长于观察期的信息，这种数据为**不完全数据**，也称为**删失数据** (censor time)、**截尾数据**或**终检值** (censored data)。

生存时间资料的种类：

(1)完全数据(complete data): 在随访研究中能观察到所规定的明确结局, 即获得完整确切的生存时间, 这类数据称完全数据。t 如生存年数: 1、2、3...

(2)不完全数据、截尾数据(censored data): 由于失访、死于其他疾病、研究工作结束等原因, 使得部分病人不能随访到底, 未观察到规定的结局, 称之为截尾。从起点至截尾点所经历的时间, 称为截尾数据(截尾值), 又称删失值(数据)或终检值。t⁺ 如生存年数: 3 +、5 + ...

生存数据的特点:

- 1) 完全数据(t^+) : 研究对象在规定研究期间提供确切的“时间和结局”。
- 2) 截尾数据(t^+): 截尾数据虽然提供的信息不完全, 但提供了部分信息, 如 $t=10^+$ 年 >9 年。
- 3) 生存数据的结果变量 (Y) 有两个:
时间 (t) 值, $t > 0$
结局状态 (y) =如 “死亡或截尾值”

截尾数据的统计处理

在实际工作中，很多医学工作者将失访或中止等原因造成的删失数据抛弃掉。这样做不仅损失了大量信息，而且也不太科学。

例某研究者追踪100名癌症患者，经治疗后的生存情况，随访第1年有30人死亡，有40人无法联系失访。试估计其生存率。

方法一：去掉截尾数据总例数
N=60

	生存数	生存率
1年	30	$30/60=50\%$

方法二：不去掉截尾数据
N=100

	生存数	生存率
	70	$70/100=70\%$

生存时间资料的特征

- 生存时间数据常呈指数分布、Weibull分布、对数正态分布、对数Logistic分布或更为复杂的分布，或不规则状态，难以用传统的统计方法对这类数据进行处理。

生存分析资料收集——纵向随访观察

随访内容


- 1.明确研究对象的起始事件时间，如手术日期等；
- 2.明确结局事件：如死亡或复发；
- 3.明确研究跨度时间：如2000年至2005年结束；
- 4.记录个体影响结果（ y ）的其他自变量。

随访方式


- 1.全部观察对象同时接受不同处理（起点相同）
随访方式：多见于动物实验（见图17-1, a)
- 2.观察对象在不同时间接受处理因素（起点不同）
随访方式：临床研究研究（见图17-1, b)

三、生存时间的图示

动物实验随访数据 (图17-1, a)



一批病人不同时间进入研究的随访资料



四、生存率 (*survival rate*)

生存函数 (survival function) 又称累积生存概率, 简称生存率 (*survival rate*), 是某个研究对象的存活时间长于 t 时刻的概率, 它是时间 t 的函数。

无截尾数据时:

$s(t)$ = 生存时间长于 t 的观察对象数/观察对象总数


$$3\text{年生存率} = \frac{\text{活满3年例数}}{\text{期初观察例数}} \quad 5\text{年生存率} = \frac{\text{活满5年例数}}{\text{期初观察例数}}$$

有截尾数据时:

- 分时段计算生存概率
- 生存概率:单个生存时段的结果, 而生存率实质上是累积条件生存概率, 是多个时段的累积结果。
- 设病人在各个时段生存概率为 P_j , $j = 1, 2, \dots$, 则各个生存概率 P_j 的乘积为生存率:

$$S(t) = p_1 p_2 \cdots p_k$$

生存概率和生存率的关系



五、生存概率与死亡概率

生存概率(probability of survival): 表示某时段开始时存活的个体, 到该时段结束时仍存活的可能性。

$$p = \frac{\text{活过该年人数}}{\text{某年年初人口数}}$$

死亡概率(probability of death): 表示某时段开始时存活的个体, 在该时段内死亡的可能性, 它是一个随时间上升的函数。

$$q = \frac{\text{该年内死亡人数}}{\text{某年年初人口数}}$$

死亡率(mortality rate):

$$m = \frac{\text{该年内死亡人数}}{\text{某年年平均人口数}}$$

六、风险函数 (hazard function)

表示一个具有协变量 X 的观察对象，从生存时间 t 到 $t + \Delta t$ 这一非常小的区间内死亡的概率极限，即生存时间已达到 t 的观察对象在 t 时刻的瞬时死亡率。

$$h(t, X) = \lim_{\Delta t \rightarrow 0} \frac{[P(t < T < t + \Delta t \mid (T > t, X))]}{\Delta t}$$

- **死亡概率密度函数**：表示具有协变量X的所有观察对象在t时刻的瞬时死亡率。

$$f(t, X) = \lim_{\Delta t \rightarrow 0} \frac{P(t < T < t \pm \Delta t, X)}{\Delta t}$$

- **生存函数、风险函数、死亡概率密度函数**具有以下关系：

$$h(t, X) = \frac{f(t, X)}{S(t, X)}$$

第二节 生存分析的统计方法

1.统计描述：用统计指标描述生存过程，如计算生存率、平均生存时间、中位生存时间、绘制生存曲线等。

大样本资料常用寿命表法

小、大样本资料常用乘积极限法（product-limit method），由Kaplan和Meier在1958年首先提出的，故又称Kaplan-Meier法（简称K-M法）。

2.统计推断：统计检验不同处理方式的生存过程(时点生存率比较、生存曲线比较)有无差别log-rank法和Breslow检验。

3.影响生存时间的危险因素分析：cox比例风险回归模型

生存分析的基本方法

□非参数法：

小、大样本（原始）资料：乘积极限法（K - M法）

大样本(频数表)资料：寿命表法

□参数法：指数分布法、*Weibull*分布法等

□半参数法：Cox比例风险回归模型

生存资料的基本要求

1. 样本由随机抽样方法获得，要有一定的数量
2. 死亡例数不能太少
3. 截尾比例不能太大，否则结果将存在较大偏倚
4. 生存时间尽可能精确到天数
5. 缺项要尽量补齐

第三节 生存率的估计与生存曲线

描述生存资料的几个指标

1. 不同时间点生存率
2. 生存曲线
3. 中位生存时间

一、生存率估计的统计方法（非参数方法）

Kaplan-Meier法（K - M法），也叫**乘积极限法**
(product-limit method, PL法)

适用于小样本、大样本，应用范围很广。

方法：

- 1) 将生存时间 t 由小到大排列。截尾值排在完全数据后，例：20, 20⁺
- 2) 列出 t 时刻死亡数 (d)
- 3) 生存率估计用概率乘法原理

1.生存率的计算:

$$S(t_i) = P(T > t_i) = p_1 p_2 \cdots p_i$$

2.生存率标准误的计算（了解）：

$$SE(S(t_i)) = S(t_i) \sqrt{\sum_{i=1}^{t_i} \frac{d_i}{n_i(n_i - d_i)}}$$

3.总体生存率可信区间的估计

$$S(t_i) \pm u_{\alpha} SE[S(t_i)]$$

**当总体率的可信区间的上、下限可能<0或>1时，
可计算生存率经对数变换后的值以及相应的标准误。**

例17-2 为了比较不同手术方法治疗肾上腺肿瘤的疗效，某研究者随机将43例病人分成两组，甲组23例、乙组20例的生存时间（月）如下所示，试计算其生存率与标准误。

甲组： 1, 3, 5 (3) , 6 (3) , 7, 8, 10 (2) , 14⁺, 17, 19⁺, 20⁺, 22⁺, 26⁺, 31⁺, 34, 34⁺, 44, 59

乙组： 1 (2) , 2, 3 (2) , 4 (3) , 6 (2) , 8, 9 (2) , 10, 11, 12, 13, 15, 17, 18

表17-4 甲手术方式病人的生存率与标准误的计算

序号 i	时间 (月) t_i	死亡数 d_i	期初例数 n_i	死亡概率 q_i	生存概率 p_i	生存率 $S(t_i)$	标准误 SE
1	1	1	23	0.043	0.957	0.957	0.0425
2	3	1	22	0.045	0.955	0.914	0.0588
3	5	3	21	0.143	0.857	0.783	0.0860
4	6	3	18	0.167	0.833	0.652	0.0993
5	7	1	15	0.067	0.933	0.609	0.1018
6	8	1	14	0.071	0.929	0.565	0.1034
7	10	2	13	0.154	0.846	0.478	0.1042
8	14 ⁺	0	11	0.000	1.000	0.478	0.1041
9	17	1	10	0.100	0.900	0.430	0.1041
10	19 ⁺	0	9	0.000	1.000	0.430	0.1041
11	20 ⁺	0	8	0.000	1.000	0.430	0.1041
12	22 ⁺	0	7	0.000	1.000	0.430	0.1041
13	26 ⁺	0	6	0.000	1.000	0.430	0.1041
14	31 ⁺	0	5	0.000	1.000	0.430	0.1041
15	34	1	4	0.250	0.750	0.323	0.1216
16	34 ⁺	0	3	0.000	1.000	0.323	0.1216
17	44	1	2	0.500	0.500	0.161	0.1293
18	59	1	1	1.000	0.000	0.000	-

小结：生存率的计算


- (1)对生存时间进行排序
- (2)计算生存时间t对应的死亡人数
- (3)期初观察人数
- (4)计算死亡概率和生存概率
- (5)计算生存率

$$s(t_i) = p_1 \cdot p_2 \cdot p_3 \cdot \cdots \cdot p_i$$

生存曲线(survival curve)：又称Kaplan - Meier曲线，是以生存时间 t 为横轴，生存率 $P(T \geq t)$ 为纵轴绘制的一条曲线，用以描述其生存过程。

阶梯型的折线

绘制生存曲线、描述生存过程



生存曲线是一条下降的曲线，分析时应注意曲线的高度和下降的坡度。平缓的生存曲线表示高生存率或较长生存期；陡峭的生存曲线表示低生存率或较短生存期。


中位生存时间 (median survival time)

又称**半数生存期**、**生存时间中位数**，表示刚好有50%的个体其存活期大于该时间。

生存分析中最常用的概括性统计量

计算方法：图解法和线性内插法

图解法



中位生存时间越长，表示疾病的预后越好；
反之，预后越差。

线性内插法




表14-2 缓解的急淋患者在有巩固治疗时的生存率及标准误

第 <i>i</i> 生 存时点	生存 时间 t_i	t_i 时刻 死亡数 d_i	期内截 尾例数 c_i	期初 例数 n_i	条件 生存概率 $pi=(n_i-d_i)/r$	生存 率 $\hat{S}(t_i)$	生存率 标准误 $SE(\hat{S}(t_i))$
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
1	7.6	2	0	14	12/14=0.8571	0.8571	0.0935
2	8.33	1	0	12	11/14=0.9167	0.7857	0.1097
3	13.16	2	0	11	9/11=0.8182	0.6429	0.1281
4	19.16	1	3	9	8/9=0.8889	0.5714	0.1323
5	23.77	1	0	5	4/5=0.8000	0.4571	0.1471
6	26.00	2	0	4	2/4=0.5000	0.2286	0.1359
7	66.83	1	1	2	1/2=0.5000	0.1143	0.1056

$$M=19.16 + \frac{0.5714 - 0.5}{|0.4571 - 0.5714|} \times (23.77 - 19.16) = 22.04(\text{月})$$

即：有50%的患者在有巩固治疗的情况下，生存不足两年。⁴²

二、寿命表法 (Life-table method)

大样本资料时数据太多或有的观察对象可能得不到确切的数据，可以把生存时间资料进行分组、计数，从而得到分组的频数表资料。表17-6

生存率的估计：寿命表法

寿命表法：用编制队列寿命表的原理来计算生存率，用概率论的乘法定理计算出一定时期的生存率。

寿命表：又称生命表，是根据某一人群的年龄别死亡率计算出来的一种统计表，根据编制目的和资料来源不同，可分为现时寿命表和队列（定群）寿命表，前者用于分析横断面资料，后者用于队列资料的分析。

期内死亡概率 = 期内死亡人数 / **期初校正人数**

标准误的计算：

$$SE(S(t_i)) = S(t_i) \sqrt{\sum_{i=1}^{t_i} \frac{q_i}{p_i n_i}}$$

期初观察人数
- 1/2截尾人数

例17-3 某研究者收集了男性心绞痛患者2418例，经随访将有关资料整理后列于表17-6，其中生存时间是以年计算的，试计算其生存率及其标准误。

寿命表法与PL的区别

- 1.寿命表法计算在 (t_{i-1}, t_i) 时间段的生存率。
如0-1年、1-2年，时间段组距相等。
- 2.寿命表法计算死亡概率，用校正观察人数计算。假定有截尾事件的人在各时间组内平均生存为1/2时间。

死亡概率=某时间组内死亡人数/校正观察人数

(校正观察人数=期初观察人数 - 截尾人数/2)

第四节 生存率的比较

比较不同方法的生存率，常进行生存率曲线间的比较。

1.时序检验 (Log-Rank test)，又称对数秩检验(非参数法)，是1996年Mentel等人提出的，可用于两组或多组生存率的比较。

基本思想：假设各组总体的生存率(曲线)相同，由合计死亡概率计算得到每组的预期死亡数(T),再与每组实际死亡数进行比较 (χ^2 检验)，从而根据P值得出结论。(近似法；软件:精确法)

检验假设：

H_0 ：两总体的生存率曲线相同

H_1 ：两总体的生存率曲线不同

$\alpha=0.05$

如 $P \leq \alpha$ ，拒绝 H_0 ，接受 H_1 。

Log-rank检验

检验统计量:

$$\chi^2 = \sum \frac{(A_i - T_i)^2}{T_i}$$

该 χ^2 服从自由度=组数 - 1

A_i 为某组各时点实际死亡频数合计.

T_i 为某组各时点期望死亡频数合计

i 表示比较组, $i=1, 2, \dots, k$ 组

Log-rank检验的基本思想

表17-7部分数据

时 间 t	甲 法 手 术 组			乙 法 手 术 组			合 计	
	n_{1i}	d_{1i}	T_{1i}	n_{2i}	d_{2i}	T_{2i}	n_i	d_i
1	23	1	1.605	20	2	1.395	43	3
2	22	0	0.550	18	1	0.450	40	1

$$T_{11} = n_{1i} \frac{d_i}{n_i} = 23 \times \frac{3}{43} = 1.605$$

$$T_{21} = n_{2i} \frac{d_i}{n_i} = 20 \times \frac{3}{43} = 1.395$$

按两组合计
死亡率计算
各组理论频
数(T)。

两组生存率曲线的检验

$$H_0: s(t_1) = s(t_2)$$

$$\chi^2 = \frac{(A_{\text{甲}} - T_{\text{甲}})^2}{T_{\text{甲}}} + \frac{(A_{\text{乙}} - T_{\text{乙}})^2}{T_{\text{乙}}}$$

$$\chi^2 = \frac{(16 - 23.809)^2}{23.809} + \frac{(20 - 12.191)^2}{12.191} = 7.56$$

$$v = \text{组数} - 1 = 2 - 1, \chi^2 = 7.56 > \chi^2_{0.01, 1} = 6.63, p < 0.01$$

结论:两生存率曲线差别有统计学意义, 甲手术方法后生存率高于乙法。

Survival Functions




图17-2 两种手术治疗方式术后病人生存曲线的比较₅₁

2.Breslow检验

对观察早期差别敏感

Log-rank检验的注意事项

- 1.除了生存资料的基本要求之外，还要求各组生存曲线不能交叉；这种交叉提示可能存在混杂因素，应采用多因素方法来校正混杂作用或分层分析。
- 2.当假设检验有统计意义时，可从以下几方面来考察效果的好坏：生存曲线图判断、半数生存期比较、相对危险度比较。

第五节 Cox比例风险回归模型

- **Cox比例风险回归模型** (*Cox's proportional hazards regression model*)，简称Cox回归模型。用于分析多个协变量 (x) 与观察结果即生存函数之间的关系。
- 该模型由英国统计学家D.R.Cox于1972年提出，主要用于肿瘤和其它慢性病的预后分析，也可用于队列研究的病因探索。其优点：
 - 多因素分析方法
 - 不考虑生存时间分布
 - 利用截尾数据

COX模型用于分析生存事件与多个危险因素 (x) 的回归关系，以确定 X 对预后的重要性。

生存数据 (y) 的特殊性：

- ✓ 事件结局 $y=1$ 或 0 ，同时结局经历的时间 (t) 。
- ✓ 有截尾数据。

不能单用时间 (t) 做多元线性回归或用结局做 Logistic 回归。

一、Cox模型的基本形式

$$h(t, \mathbf{X}) = h_0(t) \exp(\beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_m X_m)$$

- $h(t, \mathbf{X})$ — t 时刻风险函数、风险率 (*hazard function*)
- $h_0(t)$ —基准风险函数，即所有变量都取0时 t 时刻风险函数。是未知的，是模型中的非参数部分，所以Cox模型称为半参数模型
- $X_1, X_2, \dots, X_m$ —与生存时间可能有关的协变量或交互项
- $\beta_1, \beta_2, \dots, \beta_m$ —回归系数
- $\exp(\beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_m X_m)$ ：参数部分

Cox回归模型又称为比例风险率模型 (proportion hazard model, PH)

模型的另一表达方式

$$PH = \frac{h(t, x)}{h_0(t)} = \exp(\beta_1 x_1)$$

$$PH = \frac{h(t, x)}{h_0(t)} = \exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m)$$

或 $\ln\left[\frac{h(t, x)}{h_0(t)}\right] = \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m$

二、参数估计与假设检验

1. 参数估计

英国生物统计学家 D.R. Cox 于 1972 年通过条件死亡概率建立偏似然函数 L_p ，使对数似然函数 $\log L_p$ 最大，通过最大似然法的 Newton-Raphson 迭代得到参数 $\beta_1, \beta_2, \dots, \beta_p$ 的估计值 $b_1, b_2, \dots, b_p$ 。

2.假设检验

借助似然原理，用最大似然估计法来估计回归系数 β_i 。

■ β_i 的假设检验：可选下列三种方法之一

- 1.似然比检验：用于剔除或选入变量及包含不同变量数的各模型比较。
- 2.*Wald*检验：用于剔除变量。
- 3.计分检验：用于新变量的引入及变量间的交互作用能否影响生存时间。

三、参数的意义及其解释

β_m : 流行病学含义是在其他协变量不变的情况下, 协变量 X_m 改变一个单位时所引起的**相对危险度(RR)**的自然对数的改变量。

β_m 与RR的关系:

$$RR = \exp[\beta_j(X_j - X_j^*)]$$

回归系数与相对危险度 (RR) 的关系:

当协变量 x_j 取值为0,1时, 则 $RR = \exp(\beta_j)$

当协变量 x_j 取值为连续变量 x_i, x_i^* 时, 则 $RR = \exp[\beta_j(x_i - x_i^*)]$

- $\beta_j > 0$, $RR > 1$, 说明变量 X_j 水平增加时, 危险率增加, 即 X_j 是危险因素。
- $\beta_j < 0$, $RR < 1$, 说明变量 X_j 水平增加时, 危险率下降, 即 X_j 是保护因素。
- $\beta_j = 0$, $RR = 1$, 说明变量 X_j 水平增加时, 危险率不变, 即 X_j 是危险无关因素。

例：为探讨胃癌患者的预后，对是否施行手术治疗(X_1 ，是取值为1，否为0)、是否接受放疗(X_2 ，是取值为1，否为0)的效果进行分析，得到：

Cox 回归方程： $h(t / x_1.x_2) = h_0(t) \exp(-0.360x_1 - 0.333x_2)$

接受手术治疗和放疗患者的风险率（危险度）为：

$$h(t, x_i) = h_0(t) \exp((-0.360) \times 1 + (-0.333) \times 1) = 0.5h_0(t)$$

未接受手术治疗和放疗患者的风险率（危险度）为：

$$h(t, x_j) = h_0(t) \exp((-0.360) \times 0 + (-0.333) \times 0) = h_0(t)$$

则

$$RR = \frac{h(t, x_i)}{h(t, x_j)} = \frac{0.5h_0(t)}{h_0(t)} = 0.5$$

即经过两种方法治疗的病人其死亡的风险是未治疗病人的一半。

得Cox模型：

$$h(t, x) = h_0(t) \exp(-0.360x_1 - 0.333x_2)$$

$$\beta_1 = -0.360 \quad e^{(-0.360)} = RR_1 = 0.697$$

$$\beta_2 = -0.333 \quad e^{(-0.333)} = RR_2 = 0.716$$

四、因素的初步筛选与最佳模型的建立

变量筛选方法:

向前引入法（前进法） Forward

向后剔除法（后退法） Backward

逐步引入-剔除法（逐步法） Stepwise

采用逐步回归法筛选有统计意义的变量。

逐步回归检验水准:

进入方程的检验水准为0.05或0.10

变量保留在方程的水准为0.1或0.15

以上计算在统计软件（SAS、SPSS等）均可完成。

五、比例风险假定的检验

COX比例风险回归模型的**主要前提条件**：

协变量对生存率的影响不随时间的改变而改变

检验方法：

分类协变量分组绘制生存曲线不能交叉

连续协变量与对数生存时间无交互作用

...

COX回归方程在生存分析中的主要应用

1. 筛选对死亡风险预后的危险因素
估计危险因素(x)的回归系数 (β) , 得到相对危险度 (RR) 和可信区间。
2. 校正混杂因素, 评价处理的效应
例: 探讨胃癌患者的预后因素
3. 计算预后指数 (PI) , 对个体预后风险做评价。

$$PI = \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_m X_m$$

个体预后指数 (PI)

$$PI' = \beta_1' X_1' + \beta_2' X_2' + \dots + \beta_m' X_m'$$

X' 为标准化变量值 $X'_1 = \frac{X_1 - \bar{X}_1}{S_1}$

β' 为标准化回归系数

$PI' = 0$, 表示个体危险度为平均水平。


$PI' > 0$, 表示个体危险度大于平均水平。

$PI' < 0$, 表示个体危险度小于平均水平。

六、应用实例（例17-5）

表 18-2 某恶性肿瘤的影响因素及量化值

变量	含义	量化值	
X_1	病人的年龄	岁	
X_2	性别	男 1	女 0
X_3	组织学类型	高分化 1	低分化 0
X_4	治疗方式	传统治疗方式 1	新治疗方式 0
X_5	淋巴结是否转移	是 1	否 0
X_6	肿瘤的浸润程度	突破浆膜层 1	未突破浆膜层 0
T	病人的生存时间	月	
Y	病人的结局	死亡 0	截尾 1



1 : no															
	no	x1	x2	x3	x4	xx5	x6	t	y	var	var	var	var	var	var
1	1	54	0	0	0	1	0	52	1						
2	2	57	0	1	1	0	0	51	1						
3	3	58	0	0	1	1	1	35	0						
4	4	43	1	1	0	1	0	103	1						
5	5	48	0	1	1	0	2	7	0						
6	6	40	0	1	1	0	2	60	1						
7	7	44	0	1	1	0	2	58	1						
8	8	36	0	0	1	1	1	29	0						
9	9	39	1	1	0	0	1	70	1						
10	10	42	0	1	1	0	1	67	1						
11	11	42	0	1	1	0	0	66	1						
12	12	42	1	0	0	1	2	87	1						
13	13	51	1	1	0	0	0	85	1						
14	14	55	0	1	1	0	1	82	1						
15	15	49	1	1	0	0	1	76	1						
16	16	52	1	1	0	0	1	74	1						
17	17	48	1	1	0	0	2	63	1						
18	18	54	1	0	0	1	1	101	1						
19	19	38	0	1	1	0	0	100	1						
20	20	40	1	1	0	0	1	66	0						
21	21	38	0	0	1	1	2	93	1						
22	22	19	0	0	1	1	2	24	0						
23	23	67	1	0	0	1	0	93	1						
24	24	37	0	0	0	1	0	90	1						
25	25	43	1	0	1	1	2	15	0						
26	26	49	0	0	1	1	2	3	0						
27	27	50	1	1	0	1	1	87	1						
28	28	53	1	1	0	0	2	120	1						
29	29	32	1	1	0	0	0	120	1						
30	30	46	0	1	1	0	1	120	1						

原始数据



	Name	Type	Width	Decimals	Label	Values	Missing	Columns	Align	Measure
1	no	Numeric	8	0	编号	None	None	8	Right	Scale
2	x1	Numeric	8	0	年龄 (岁)	None	None	8	Right	Scale
3	x2	Numeric	8	0	性别	{0, 女}...	None	8	Right	Scale
4	x3	Numeric	8	0	组织学类型	{0, 低分化}...	None	8	Right	Scale
5	x4	Numeric	8	0	治疗方式	{0, 传统治疗	None	8	Right	Scale
6	xx5	Numeric	8	0	淋巴结是否转移 (原变量x5的重新编码)	{0, 否}...	None	8	Right	Scale
7	x6	Numeric	8	0	浸润程度	{0, 未突破浆	None	8	Right	Scale
8	t	Numeric	8	0	生存时间(月)	None	None	8	Right	Scale
9	y	Numeric	8	0	结局	{0, 死亡}...	None	8	Right	Scale
10										
11										
12										

变量的定义

使用SPSS软件进行Cox回归

Analyze → Survival → Cox Regression:

Time:t (生存时间)

Status:y(0) (终点事件)

Covariate: x_1 x_2 x_3 x_4 x_5 x_6 (影响因素)

OK



15 : x2 1

	no	x1
1	1	54
2	2	57
3	3	58
4	4	43
5	5	48
6	6	40
7	7	44
8	8	36
9	9	39
10	10	42
11	11	42
12	12	42
13	13	51
14	14	55
15	15	49
16	16	52
17	17	48
18	18	54

- Reports
- Descriptive Statistics
- Tables
- Compare Means
- General Linear Model
- Mixed Models
- Correlate
- Regression
- Loglinear
- Classify
- Data Reduction
- Scale
- Nonparametric Tests
- Time Series
- Survival**
- Multiple Response
- Missing Value Analysis...
- Complex Samples

- Life Tables...
- Kaplan-Meier...
- Cox Regression...**
- Cox w/ Time-Dep Cov...

**Cox回归
分析模块**

	xx5	x6	t	y	var
0	1	0	52	1	
1	0	0	51	1	
1	1	1	35	0	
0	1	0	103	1	
1	0	2	7	0	
1	0	2	60	1	
1	0	2	38	1	
1	1	1	29	0	
			70	1	
			67	1	
			66	1	
			87	1	
			85	1	
			82	1	
			76	1	
			74	1	
			63	1	
			101	1	



Cox Regression

Time:

Status:

Define Event...

Block 1 of 1

Previous Next

Covariates:

Method:

Strata:

OK Paste Reset Cancel Help

Categorical... Plots... Save... Options...

生存时间

定义终点事件

协变量 (影响因素)

逐步回归法

16	16	52	1	1	0	0	1	74	1
17	17	48	1	1	0	0	1	63	1
18	18	54	1	0	0	0	1	101	1



Output
Cox Regression
Title
Notes
Case Processing Summary
Block 0: Beginning Block
Title
Variables not in the Equation
Block 1: Method = Forward Stepwise (Likelihood Ratio)
Title
Omnibus Tests of Model Coefficients ^{a,d}
Variables in the Equation
Variables not in the Equation
Model if Term Removed
Covariate Means
Cox Regression
Title
Notes
Case Processing Summary
Block 0: Beginning Block
Title
Variables not in the Equation
Block 1: Method = Forward Stepwise (Likelihood Ratio)
Title
Omnibus Tests of Model Coefficients ^{a,d}
Variables in the Equation
Variables not in the Equation
Model if Term Removed
Covariate Means

Block 1: Method = Forward Stepwise (Likelihood Ratio)

Omnibus Tests of Model Coefficients^{a,d}

Step	-2 Log Likelihood	Overall (score)			Change From Previous Step			Change From Previous Block		
		Chi-square	df	Sig.	Chi-square	df	Sig.	Chi-square	df	Sig.
1 ^a	187.690	13.040	1	.000	14.304	1	.000	14.304	1	.000
2 ^b	182.777	17.594	2	.000	4.913	1	.027	19.217	2	.000

a. Variable(s) Entered at Step Number 1: x4

b. Variable(s) Entered at Step Number 2: xx5

c. Beginning Block Number 0, initial Log Likelihood function: -2 Log likelihood: 201.994

d. Beginning Block Number 1. Method = Forward Stepwise (Likelihood Ratio)

引入回归方程的自变量。如何评价 x_4 、 x_5 对肿瘤预后的影响？

Variables in the Equation

		B	SE	Wald	df	Sig.	Exp(B)	95.0% CI for Exp(B)	
								Lower	Upper
Step 1	x4	1.751	.546	10.265	1	.001	5.758	1.973	16.800
Step 2	x4	1.762	.548	10.337	1	.001	5.822	1.989	17.039
	xx5	.931	.445	4.389	1	.036	2.538	1.062	6.066

Variables not in the Equation^{a,b}

		Score	df	Sig.
Step 1	x1	.018	1	.894
1	x2	.937	1	.333

采用逐步回归计算

表17-9 Cox模型筛选危险因素

变量	β	S_b	p	RR	95%可信区间	
X_4	1.762	0.547	0.0013	5.822	1.98	17.03
X_5	0.931	0.444	0.0362	2.538	1.06	6.06

Cox模型表达

$$h(t, x) = h_0(t) \exp(1.761X_4 + 0.931X_5)$$

X_4 : 传统法=1,新法=0, X_5 : 淋巴结转移=1,未转移=0

结论:传统法和淋巴结转移是影响肿瘤生存的不利因素。

分析结果（结果解释）

- 与生存相关的因素
- 因素作用大小及方向：保护因素还是危险因素、相对危险度的大小。
- 因素作用大小排序：标准化回归系数的绝对值。

$$h(t, X) = h_0(t) \exp(b_1 X_1 + b_2 X_2 + \cdots + b_p X_p)$$

- 个体的预后指数及预后分组：

预后指数（prognostic index, PI）

预后指数越小，预后越好；

预后指数越大，预后越差。

Cox模型的注意事项

1.设计阶段应注意的问题

- (1) 研究资料的代表性和可靠性;
- (2) 协变量在研究对象中分布适中;
- (3) 应将可能因素都包括在调查之中;
- (4) 生存时间的始末要有一个明确规定;
- (5) Cox回归应用上灵活, 但注意受时间影响的变量:
伴时协变量的Cox回归;
- (6) 样本含量一般为协变量的的15-20倍, 两比较组例数基本一致, 尽量避免失访 (截尾值 $<20\%$) 。

2.模型配合时应注意的问题

- (1) 多元共线性——主成分分析法或R型聚类分析法消除多元共线性的影响。
- (2) 用单因素 χ^2 检验、log-rank检验等进行变量筛选。
- (3) 生存资料还要求因素对生存时间的作用不随时间变化(比例风险假定)。如观察年限超过10年时,癌症手术后放疗的治疗作用可能逐渐消失,从而不满足这一要求。
- (4) 选入模型的变量不一定都与生存时间有因果关系,某些变量可能只是伴随关系

Cox模型与Logistic模型的比较

logistic回归模型可以作多因素分析，并可进行相对危险度估计，但不考虑生存时间的长短，不能处理随访中常见的截尾数据。

Cox比例风险回归模型具有logistic回归模型的所有优点；同时考虑生存结局和生存时间的长短，可处理截尾数据，更多的利用了资料的信息，且不受事件发生率的限制。

Cox回归与多元线性回归、logistic回归的比较

	多元线性回归	logistic回归	Cox回归
数据类型	Y数值变量	Y分类变量	Y二分类变量+时间
	X数值变量、分类变量、等级变量		
删失	不允许	不允许	允许
模型结构			
变量筛选	前进法；后退法；逐步法		
参数估计	最小二乘法	最大似然法	偏似然函数法
参数检验	F-test t-test	似然比检验 Wald检验 score检验	最大似然比检验 Wald检验 score检验
参数解释	回归系数b	优势比OR	RR
样本含量	至少变量数的10倍	至少变量数的15-20倍	至少变量数的15-20倍
应用	因素分析 预测预报 Y	因素分析 预测、判别 $P(Y = 1)$	因素分析 生存预测 $S(t)$

小 结

1.随访资料主要特点:

个体的结局资料包含两项内容：生存时间和终点事件是否发生；数据中可以有删失值。

2.生存时间一般不服从正态分布。这些使得生存过程的统计描述、单因素统计检验、多因素分析方法有其自身特点。

3.生存分析的多因素分析常用Cox模型，也称比例危险率回归，主要用于筛选影响生存率的因素和预测等。



Thank you!