


统计方法选择与结果解释



1

统计方法的正确选择

一、统计方法选择的基本思路

研究目的

设计类型

资料类型

数据特征

对比组数

样本含量



综合判断

1. 研究目的

- ◆一是通过比较, 回答观测指标的差别是否归因于处理因素或分组因素。
- ◆二是分析变量之间是否存在某种联系, 主要涉及相关分析和回归分析。

2. 设计类型

- 从实验研究设计来看，常见的设计类型为
 - 完全随机设计(成组设计)
 - 配对或配伍设计(随机区组设计)

对完全随机设计的数据，应选择相应的方法：

- 👉 两样本(成组) t 检验
- 👉 单因素(完全随机设计)方差分析
- 👉 卡方检验(独立样本)
- 👉 两样本 Wilcoxon 秩和检验或多样本 Kruskal-Wallis 秩和检验

对于配对或配伍设计的数据，应选择相应的方法：

- 👉 配对 t 检验
- 👉 配伍组(随机区组)设计方差分析
- 👉 配对卡方检验
- 👉 配对(符号秩和检验)或配伍设计的秩和检验(Friedman秩和检验)等。

3. 资料类型

- ▶ 对于定量变量，选择它所对应的统计方法？
- ▶ 对于定性变量，选择它所对应的统计方法？

4. 数据特征

对于同一设计类型和同一资料类型，仍然有许多方法可以选择。

- t 检验和方差分析属参数检验方法，对数据要求较高，通常要求数据服从正态分布和方差齐性。
- 如果服从该条件或经变量变换后服从条件，则采用参数检验方法，否则采用秩和检验这类非参数检验方法。

能否不考虑分布和方差齐性问题，直接采用非参数检验？

5. 对比组数

- ▶ 单组问题(样本与已知总体参数比较)
- ▶ 两组问题
- ▶ 多组(3组或以上)比较

注意，多组比较在差别有统计学意义时，需再进行两两比较。

6. 样本含量

👉 在样本较小时:

- ◆ 如果是一个样本率与总体率的比较, 可采用直接计算概率的方法如基于二项分布的确切概率法。
- ◆ 如果是四格表资料则采用Fisher确切概率法或校正卡方检验。
- ◆ 对于均数比较问题, 一般情况下采用 t 检验。

👉 在大样本时: 可考虑Z检验作近似。



在实际工作中，遇到的实际问题可能并非如此简单，须结合专业问题和所要分析的具体内容加以综合考虑和仔细判断，有时需对各种统计方法加以综合运用。

- ❏ 当分析目的是分析变量之间是否存在某种联系时，这就涉及到双变量的分析方法，即**相关关系**或**回归关系**的分析。
- ❏ 需注意相关分析和回归分析的**区别与联系**

关联性分析：

- ▶ 对于**定量变量**，需根据两个变量是否满足双变量正态分布，相应地采用Pearson积矩相关分析或Spearman秩相关分析。
- ▶ 对于**等级变量**则直接采用Spearman秩相关分析。
- ▶ 对**分类变量**，常计算列联系数进行分析
 - 对于 $R \times C$ 表资料，需注意区分是**单向有序**或者是**双向有序**
 - 对于一个二分类变量和一个等级变量之间的线性关联通常采用线性趋势卡方检验

生存分析：


- ▶ 是一类较为特殊的针对具有截尾数据的生存时间数据所进行的分析
- ▶ 针对分组和未分组资料，方法有所不同

多变量的数据分析：

- ▶ 多重线性回归是对反应变量为定量变量进行的多变量分析
- ▶ Logistic回归是对反应变量为分类变量所进行的多变量分析
- ▶ Cox比例风险回归是对反应变量为含有截尾数据的生存时间所进行的分析

二、统计分析需注意的若干问题

1. 数据分析通常的步骤



数据探测

- ✓ 数据分布特征、方差齐性、散点图绘制、离群值的发现，以及了解数据是否符合特定统计方法的应用条件等，必要时可进行变量变换或转换以满足分析的需要。
- ✓ 数据探测将增加对数据的基本了解，为进一步的分析奠定基础。

统计描述

- 统计描述内容？
- 注意首先要区分变量类型

统计推断

在数据探测和统计描述的基础上选择恰当的统计推断方法分析资料。

▶ 区间估计:

- 总体均数区间估计: 可采用 t 分布或正态分布原理进行估计
- 总体率区间估计: 可采用二项分布、Poisson分布或正态分布原理进行估计

2. 混杂因素的控制

- ▶ 非研究因素的“可比性”问题
- ▶ 可比性好，各组观测指标之间的差异只能归因于研究因素而不是其它原因

- ▶ 如果各组在研究因素之外的某种或某些因素有所不同，那么这个或这些其它因素的效应就可能同研究因素的效应混淆在一起
- ▶ 在这种情况下，通常的统计分析结论在进行因果推断时常常是不可靠的
- ▶ 对于非研究因素不具可比性的资料，应采用统计调整技术消除那些因素的影响
- ▶ 对于具有多个变量的复杂情况，则需采用多变量分析技术加以调整

分析阶段控制混杂因素可采用：

- 1) 分层分析
- 2) 标准化法
- 3) 协方差分析
- 4) 多重回归

1) 分层分析

Example: 研究吸烟与健康的关系

吸烟与非吸烟者死亡率的比较

吸烟者与不吸烟者死亡率的直接比较可能存在问题

因为：

- ☞ 吸烟者多为男性，而男性比女性更易患心脏病而发生死亡，吸烟者与未吸烟者之间死亡率的差异也许是因为**性别**的差异

- ▶ 为了排除这种可能性，可以性别因素分层，再比较吸烟与非吸烟者的死亡率：
- ▶ 男性人群中，吸烟与不吸烟者进行比较
- ▶ 女性人群中，吸烟与不吸烟者进行比较

👉 **年龄**可能又是另外一个混杂因素，这就需要
对年龄进行分层分析：

男 ≥ 40 岁
 < 40 岁

女 ≥ 40 岁
 < 40 岁

以上是通常的分层分析思路，但这并不能保证这样分析的结论一定是正确的

尤其当：调查设计存在严重问题，样本对总体代表性很差，
未能反映被调查总体的真实情况时

另需注意：

- 当一个事件的影响因素较多时，由于不断分层的结果致使某些层中样本含量太少；
- 采用这种简单的分层分析可能割裂多个因素之间的内在联系，难以真实揭示多个因素对观测结果的影响，从而导致错误的结论。

2) 标准化法

表1. 两种疗法治疗某病的病死率

病型	新疗法			一般疗法		
	治疗人数	死亡人数	病死率(%)	治疗人数	死亡人数	病死率(%)
普通型	75	15	20.0	25	5	20.0
重型	35	14	40.0	65	26	40.0
合 计	110	29	26.4	90	31	34.4

新疗法组的标准化病死率： $p' = \frac{60}{200} \times 100\% = 30.0\%$

一般疗法组的标准化病死率： $p' = \frac{60}{200} \times 100\% = 30.0\%$

标准化法解决了由于患者病型构成不同而导致的
合计病死率与分病型比较相矛盾的问题

3. 正确理解可比性问题

表2. 两班人数及百米跑优秀率统计

性别	甲班		乙班	
	人数	优秀率(%)	人数	优秀率(%)
男生	60	60.00	30	70.00
女生	10	10.00	30	20.00
合计	70	52.86	60	45.00

如果我们的目的是想了解“班级因素”，即分组因素对优秀率的影响或作用，同时知道还存在其它影响优秀率的因素在各组分布不一致(即存在混杂因素)，此时谈论“可比性”才是有意义的

正确做法：消除混杂因素的影响，揭示分组因素对研究指标的影响或作用

表3. 直接法计算标准化率

性别	标准班 级人数 (N_j)	甲班		乙班	
		优秀率 $P_{1j}(\%)$	期望优秀 人数(N_iP_j)	优秀率 $P_{2j}(\%)$	期望优秀 人数(N_iP_j)
男	90(N_1)	60.00	54	70.00	63
女	40(N_2)	10.00	4	20.00	8
合	130	---	58	---	71

- ◆ 但如果研究目的并非探讨分组因素对研究指标的影响或作用，谈论可比性没有意义，也没必要去调整混杂因素的影响
- ◆ 单纯描述谁高谁低无需进行调整，只是在进一步探究导致高低不同的归因(所谓因素分析)时才
对混杂因素进行控制或调整

4. 数据的分组问题

- 同质性问题
- 分组：就是将专业上认为性质相同的个体归在一起，将性质不同的个体区别开来，即试图在专业上反映出组内的同一性和组间的差异性

2

统计结果的正确解释

假设检验结果的正确理解

- ✓ P 值的意义
- ✓ I型错误与II型错误
- ✓ 统计学意义和专业意义
- ✓ 假设检验使用条件

不同研究类型数据分析结果的正确解释

1. 观察性研究

- ✓通常是在研究的初始阶段进行，为进一步研究提供线索。
- ✓只建立起某种关联性，如某一事物或现象与另一事物或现象相关联，但这种关联性不一定是因果联系。

2. 实验性研究

- ✓能够较好地控制各种混杂因素。对于严谨设计的实验性研究，结论通常较为可靠。
- ✓临床试验对象是人，存在诸多心理(如霍桑效应和安慰剂效应等)以及伦理问题的局限，下结论须谨慎。
- ✓社区干预试验，通常都不能进行随机化分配，常存在诸多混杂因素的干扰，如果在分析阶段不能有效消除其混杂效应，结论也有待进一步验证。

表1 单变量资料差异比较的分析方法小结

资料类型	数据特征	单组设计	完全随机设计		配对或配伍设计	
			两组	多组	两组	多组
定量资料	正态、方差齐	样本与总体均数比较的 t 检验	两样本 t 检验	单因素方差分析	配对 t 检验	随机区组设计方差分析
	非正态和/或方差不齐	Wilcoxon 符号秩和检验	t 检验、 Wilcoxon 秩和检验	Kruskal-Wallis H 秩和检验	Wilcoxon 符号秩和检验	Friedman 秩和检验
定性资料	无序	二项分布直接计算概率法、正态近似法(Z 检验)	χ^2 检验、 Fisher 确切概率法	$R \times C$ 表资料 χ^2 检验、 Fisher 确切概率法	配对四格表 χ^2 检验	配对 $R \times R$ 列联表 χ 检验
	有序	——	Wilcoxon 秩和检验	Kruskal-Wallis H 秩和检验	Wilcoxon 符号秩和检验	

表2 双变量(多变量)资料的关联性分析方法小结

	数据特征		分析方法
相关分析	定量资料	x 、 y 服从双变量正态分布	直线相关分析
		x 、 y 不服从双变量正态分布	Spearman秩相关
	定性资料 ($R \times C$ 表)	双向无序	χ^2 检验
		双向有序、属性不同	Spearman秩相关、线性趋势检验
		双向有序、属性相同	一致性检验(kappa系数的假设检验)
回归分析	应变量为连续型定量变量，服从正态分布		一个应变量，一个自变量：直线回归分析
			一个应变量，多个自变量：多重线性回归分析
	应变量为定性变量		Logistic回归分析
	应变量为含有截尾数据的生存时间		Cox比例风险回归分析